


Etika, *araudia* eta segurtasuna

RA6 — alborapenak, GDPR, AI Act, security eta privacy by design.
Moduluaren bihotz etiko-legala.

Andoni Elola · andoni.elola@ehu.eus

Jon Urteaga · jon.urteaga@ehu.eus

FP irakasleen prestakuntza · 5071 · 2025 / 2026



Saio honetan

-
- 01 Alborapenak: nondik datoz, nola neurtu

 - 02 COMPAS kasua datu errealekin

 - 03 Marko legala: GDPR eta AI Act

 - 04 Segurtasuna: erasoak eta defentsa

 - 05 Privacy eta Security by Design

 - 06 Bestelakoak: deepfake-ak, ingurumena, lan-mundua


01 Alborapenak AA sistemetan

Non sortzen dira alborapenak?



Gakoa: alborapena ez da 'akats' puntuala; datu, eredu eta erabilera osoan dago.

Hiru alborapen mota



Legeak: sesgoak identifikatu eta zuzentzea eskatzen du (RA6.f).

Selekzio-alborapena gertutik



Adibidea: ahots-asistenteak euskaraz eta emakume-ahotsekin okerrago dabilta.

CV iragazki automatikoa: erabili ala ez?

EGOERA

Enpresa batek 500 CV jasotzen ditu astero. AA-iragazki batek % 90 baztertzen du segundotan. Amazonek halako sistema bat baztertu zuen 2018an: emakumeen CV-ak zigortzen zituela ikasi zuen — datu historikoetatik.

GALDERAK

- Zuek erabiliko zenukete? Zein baldintzatan?
- Imajinatu zuen CV-a baztertu duela: zer eskubide dituzue?
- Nork dauka erantzukizuna: enpresak, garatzaileak, datuek?

COMPAS kasua


- AEBetako epaitegiek berrerortze-arriskua kalkulatzeko erabilia
- **ProPublica 2016** — 7.214 kasu aztertu zituen Browarden
- **Orain** — datu BERBERAK aztertuko ditugu notebook batean
- **Helburua** — kazetaritza-ikerketa bat zuen eskuekin errepikatzea

COMPAS: Arrisku-iragarpeneko Alborapen Arrazala

Iturria: ProPublica, 2016 — 7.214 pertsona, Broward Konderrria, Florida

POSITIBO FALTSUAK


Arrisku altua bezala sailkatuta, baina EZ zuten berregin



Pertsona beltzen kasuan ia BI ALDIZ probabilitate handiagoa dago oker 'arriskutsu' bezala etiketatzeko

NEGATIBO FALTSUAK

Arrisku baxua bezala sailkatuta, baina BAI berregin zuten



Pertsona zurien kasuan probabilitate handiagoa dago arrisku baxu bezala oker sailkatzeko

Bi taldeetan zehaztasun global antzekoa ($\approx$ % 61) — baina erroreak oso modu desberdinean banatzen dira arrazaren arabera

Iturria: ProPublica, 2016 · Datuak: 7.000 pertsona, Broward Konderrria, Florida

COMPAS: ProPublica-ren analisia errepikatu

EGOERA

ProPublica-ren CSV originala kargatu (7.214 errenkada), iragazketa kanonikoa aplikatu eta talde bakoitzeko FPR / FNR metrikak kalkulatu. Zuen ondorioak ProPublica-renekin konparatu — eta Northpointe enpresaren defentsarekin.

EGINKIZUNAK

- FPR eta FNR taldeka kalkulatu.
- Kalibrazio-kurba marraztu (decile_score vs berrerortze erreala).
- Erantzun: zehatza ETA alboratua izan daiteke aldi berean?

Soluzioa: metrikak taldeka

... 2.2_compas_historikoa_soluzioa.ipynb

SOLUZIOA

python

```

1 # ProPublica-ren datu originalak (GitHub-etik)
2 df = pd.read_csv(URL)          # 7.214 errenkada
3
4 df['high_risk'] = (df['decile_score'] >= 7).astype(int)
5
6 def metrikak(taldea):
7     tp = ((y_true == 1) & (y_pred == 1)).sum()
8     fp = ((y_true == 0) & (y_pred == 1)).sum()
9     fpr = fp / (fp + tn)      # positibo faltsuen tasa
10    fnr = fn / (fn + tp)      # negatibo faltsuen tasa
11    return fpr, fnr


```

Emaitzak: ProPublica berretsita

TALDEA	OINARRI-TASA	FPR	FNR
Afroamerikarrak (n=3.175)	% 52,3	% 22,8	% 49,2
Zuriak (n=2.103)	% 39,1	% 8,3	% 72,0

Emitza: kalibrazioa antzekoa da!

Hau da paradoxa: score bereko pertsonen antzeko berrerortze-tasa dute bi taldeetan (kalibrazio ona) — baina FPR oso desberdina da. **Biak batera ezinezkoak dira** oinarri-tasak desberdinak direnean: Chouldechovaren ezintasun-teorema.



Onartuko zenuke COMPAS zure epaiketetan?

EGOERA

Northpointe-k zioen: 'sistema kalibratuta dago' (egia).


ProPublica-k zioen: 'beltzentzako positibo faltsu bikoitzak' (egia hau ere). Biek arrazoia zuten — fairness-definizio desberdinak erabili zituzten.

GALDERAK

- Zein fairness-definizio iruditzen zaizue garrantzitsuena?
- Epaile batek ulertu behar al du estatistika hau?
- Zer dio AI Act-ek? (justizia = arrisku altua, III. eranskina)

Fairness metrikak

Paritate-Metrikak (Fairness): Nola Neurtu Justizia AA-n?



 Oharra: 'A Taldea' eta 'B Taldea' adibide didaktikoak dira. Talde babestuen hainbat dimentsio izan ditzakete: generoa, adina, jatorria, desgaitasuna, klase soziala, hizkuntza, erlijioa...



EZINTASUN-TEOREMA (Chouldechova, 2017):

Ezinezkoa da hiru metrikak aldi berean betetzea taldeen artean benetako desberdintasunak daudenean

Notebookean: 3.1 ariketak fairness metrikak ospitale batean aplikatzen ditu (fairlearn).


Ezintasun-teorema: aukeratu egin behar da



Gelan: hiruko taldeak; bakoitzak fairness-metrika bat defendatu.

Aurpegi-Ezagutzaren Alborapena: Gender Shades Ikerketa (MIT, 2018)

Genero-sailkapeneko errore-tasa talde demografikoen arabera — 3 sistema komertzialen ebaluazioa



Iturria: Buolamwini & Gebru, FAccT 2018 | gendershades.org

RA6 · KASU HISTORIKOA

Gender Shades: aurpegi-ezagutza auditatua

- **Buolamwini & Gebru (2018)** — 3 sistema komertzial aztertu zituzten
- Gizon zuriak: % 0,8ko errorea · Emakume beltzak: % 34,7koa
- **Ondorioa** — enpresek euren sistemak hobetu zituzten urtebetean
- **Auditoria publikoak funtzionatzen du** — hori ere bada ikasgaia


Emaitzza: auditoria gure eskuekin

02 saioko LFW ariketaren jarraipena: sailkatzailearen erroreak taldeka banakatuta. Gender Shades-en patroia bera agertzen da gure eredu txikian ere — **datu-desorekaren ondorio zuzena.**

Hugo Chavez



Tony Blair



George W Bush



Colin Powell



Ariel Sharon



Colin Powell



George W Bush



Gerhard Schroeder



George W Bush



Ariel Sharon



ALTAI: Europako auditoria-galderak

EGOERA

ALTAI da Europako Batzordearen 'AA fidagarriaren' ebaluazio-zerrenda ofiziala. Notebook-ak FP-testuinguru batera egokitzen du: aukeratu AA-sistema ezagun bat eta pasatu ALTAI galdera-sorta, puntuazioekin.

EGINKIZUNAK

- Sistema bat ALTAI-rekin ebaluatu (7 dimentsio).
- Puntu ahulenak identifikatu eta hobekuntzak proposatu.
- **Gelan** — ikasleen mugikorreko app batekin errepikatu.

02

Marko legala: GDPR eta AI Act

Europako hiru zutabeak



- **GDPR** — datu pertsonalen babesa (2018tik)
- **Azalpenaren eskubidea** — erabaki automatizatuak justifikatu (22. art.)
- **EU AI Act** — arriskuan oinarritutako lehen AA-legea (2024)
- **Adibidea** — CV bat algoritmoz baztertzen bada, azalpena eskatu daiteke

GDPR minutu batean

GDPR

Datu pertsonalen tratamendua arautzen duen EB-araudia: zilegitasuna, minimizazioa, zehaztasuna, mugak, segurtasuna eta erantzukizuna.

AA - RAKO GAKOA

22. artikulua: erabaki guztiz automatizatuek ondorio juridikoak badituzte, gizakiak esku hartzeko eskubidea dago. Horrek AA-sistema asko zuzenean baldintzatzen ditu.

GDPR-ren 7 printzipioak FP-ko kasuetan


EGOERA

Notebook-ak FP-testuinguruko 7 egoera deskribatzen ditu (asistentzia-app bat, ikasleen notak hodeian, kamera tailerrean...). Lotu bakoitza urratzen edo betetzen duen GDPR-printzipioarekin eta proposatu zuzenketa.

EGINKIZUNAK


- 7 egoeren taula: printzipioa + ebaluazioa + zuzenketa.
- Zein da printzipiorik urratuena? Zergatik?
- **Gelan** — zuen ikastetxeko benetako 2 egoera gehitu.

Noiz aplikatzen da 22. artikulua?



Gelan: 22. artikulua fluxu-diagrama kasu errealekin zeharkatu.

Gardentasunaren hiru dimentsioak



Hirurak behar dira: trazabilitatea, azalpen teknikoa eta komunikazioa; bat falta bada, hutsa da.

Kutxa beltza vs XAI

Kutxa Beltza vs AA Azalgarria (XAI): Zer aldatzen da?

 Sistemen Kutxa Beltza		 AA Azalgarria (XAI)
 Erabiltzailearen Konfiantza	Baxua — erabiltzaileak ez daki zergatik erabaki den. Eszeptizismoa erabaki kritikoetan.	Alta — erabiltzaileak logika ulertu eta emaitza hobeto onartzen du.
 Betebehar Legala	Zigorgarria GDPR 22. art. eta AI Act-en arabera arrisku altuko erabakietan.	Gardentasun- eta audiotretza-betebeharrak betetzen ditu.
 Sesgo-Detekzioa	Zaila kaltea sistematikoa bihurtu arte. Akatsak 'ikusezinak' dira.	Aldagai diskriminatzaileak era proaktiboan identifikatu daitezke.
 Trazabilitatea	Ezinezkoa 'zergatia' berreraikitzea akats baten ondoren.	Erregistro osoa sarreratik irteerara arte — audiotretza posible.

 **Kasu errela:** Herbehereetako SyRI sistema (2020) — Epaileak **GELDITU** zuen GDPR urratzeagatik: sistema kutxa beltz bat zen, herritarrek ezin zuten jakin zergatik sailkatuak ziren iruzurgiletzat.

Notebookean: 12.0 compliance-proiektuak SHAP eta LIME darabiltza.




Iturria: EU AI Act (EB) 2024/1689 – 2026ko abuztutik aplikagarria

RA6 · AI ACT

AI Act: arrisku-piramidea

Lau maila: **onartezina** (debekatua), **altua** (betebehar zorrotzak), **mugatua** (gardentasuna), **minimoa** (librea). Erabilera-testuinguruak agintzen du, ez teknologiak.



— RA6 · AI ACT

Ate-sistema: lau iragazki


- 1 — Debekatuta dago? (manipulazioa, social scoring, biometria)
- 2 — Arrisku altua? (III. eranskina: enplegua, hezkuntza, justizia...)
- 3 — GPAI eredu? (oinarrizko ereduen betebeharrak)
- 4 — Gardentasun-betebeharrak? (txatbotak, deepfake-ak)

Arrisku altuko sistemen betebeharrak



Adibidea: CV iragazkiak arrisku-kudeaketa, datu-gobernantza eta giza gainbegiraketa bete behar ditu.


Aplikazio-kronologia



- **2024** — indarrean sartu zen
- **2025** — debekuak eta GPAI betebeharrak aplikagarri
- **2026-2027** — arrisku altuko sistemen betebeharrak osoak
- **Gelan** — gaurko ikasleak lan-merkatuan sartzean, dena indarrean

Nork zaintzen du legea?

- **AI Bulegoa (EB)** — GPAI ereduaren gainbegiratzea
- **AI Batzordea + Panel Zientifikoa** — koordinazioa eta aholkuak
- **Agentzia nazionalak** — Espainian AESIA (A Coruña)
- **Isunak** — 35 M€ edo fakturazioaren % 7raino



Human in / on / out of the loop

Giza Gainbegiraketa Ereduak (AI Act 14. art.)

HITL

Human-in-the-Loop



Giza esku-hartzea beharrezkoa da erabaki-ziklo BAKOITZEAN

Adibideak:

- Osasun-diagnostikoa
- Langile-aukeraketako azken erabakia
- Kreditu-onarpena

 AI Act betetzea: ZORROTZA

 Automatizazio-alborapen arriskua (automation bias)

HOTL

Human-on-the-Loop



AA-k autonomoki erabakitzen du, baina gizakiak monitorizatzen du eta esku har dezake

Adibideak:

- Bankuko iruzur-detekzioa
- Sare elektrikoaren oreka
- Trafiko-kontrola

 AI Act betetzea: BALDINTZEKIN

 Alerta-nekea (alert fatigue) arriskua

HIC

Human-in-Command



Gizakiak beti du kontrol osoa — noiz erabili, nola erabili, noiz itzali

Adibideak:

- Enpresako estrategia-erabakiak
- Lege-aholkularitza
- Osasun paliatiboa

 AI Act: askotan ez da nahikoa arrisku handiko sistemetan

 Inertzia-presio arriskua

	HITL	HOTL	HIC
 AA autonomia	Baxua	Ertaina	Autonomiarik ez
 Giza esku-hartzea	Erabaki bakoitzean	Anomalietan	Erabaki estrategikoan
 Abiadura	Motela	Azkarra	Azkarra

Hiru mailak: in the loop, on the loop eta out of the loop; azkena arrisku altuetan debekatua.

AI Act: 8 sistema sailkatu

EGOERA

Notebook-ak 8 AA-sistema erreal deskribatzen ditu (chatbota, aurpegi-aitortza, CV iragazkia, spam-iragazkia...). Sailkatu bakoitza AI Act-en lau arrisku-mailetan eta justifikatu erantzuna artikuluekin. Ez du kodea behar — lege-arrazoiketa hutsa da.

EGINKIZUNAK

- 8 sistemen sailkapen-taula justifikazioekin.
- Muga-kasuak eztabaidatu: noiz bihurtzen da chatbot bat arrisku altu?
- **Gelan** — zure sektoreko 2 sistema gehitu eta sailkatu.

Soluzioa: sailkapen-ereduak

SISTEMA	MAILA	GAKOA
Chatbot orokorra webean	Mugatua	Erabiltzailea informatu (52. art.) + GPAI betebeharrak
Aurpegi-aitortza denbora errealean	Onartezina	Biometria urruneko identifikazioa DEBEKATUA (5. art.)
CV iragazkia hautaketan	Altua	III. eranskina 4. puntua — enplegua
Spam-iragazkia	Minimoa	Eragin txikia — datu pertsonalak GDPR aldera doaz

Ikasleen ohiko akatsak sailkapenean

- **Chatbota arrisku altu** — 'konplexua delako'; maila erabakitik dator, ez konplexutasunetik
- **Spam-iragazkia mugatua** — 'datu pertsonalak dituelako'; hori GDPR da, ez AI Act
- **Aurpegi-aitortza arrisku altu** — denbora errealekoa DEBEKATUA dago, ez arautua
- **Auto autonomia ahaztea** — sektore-erregelamendu osagarria ere badu

Nota algoritmikoa: AA-k ebaluatuko balu?

EGOERA

AI Act-ek hezkuntza arrisku altutzat jotzen du. Demagun plataforma batek ikasleen lanak automatikoki kalifikatzen dituela eta horrek zikloko batez bestekoan eragiten duela.

GALDERAK

- Zer betebeharrak legoke? (gainbegiraketa, azalpena, auditoriak)
- Onartuko zenukete zuen ikasleentzat? Eta zuen oposizioetan?
- Non dago muga 'laguntza' eta 'erabaki automatizatu' artean?

Eragin Etikoko Ebaluazioa (EIA)

Eragin Etikoko Ebaluazioa (EEE)

AA sistema bat erosi edo diseinatu baino lehen egin beharreko 4 galdera-bloke

 ON	1	Proportzionaltasuna eta Kalterik Ez (Do No Harm) ♦ AA al da irtenbide egokia? Giza-teknikaria soilarekin ez al dago soluzioa? ♦ Kalte itzulezinak sortzen al ditu? (gizarte-puntuaketa, masa-zaintza, adostasun ezinezkoa) ♦ Talde zaurgarriak kaltetuko al ditu? (haurrak, adindakoak, pobreak)
 ON	2	Sesgo-Auditoria ♦ Entrenamendu-datuen kalitatea ebaluatu al da diskriminazioa saihesteko? ♦ Talde desberdinen arteko emaitza-desberdintasunak neurtu al dira? ♦ Talde gutxituek adina datu al dituzte (generoa, arraza, adina, desgaitasuna)?
 ON	3	Diseinuz Pribatutasuna (Privacy by Design) ♦ Pribatutasun diferentziala erabiltzen al da datu pertsonalak babesteko? ♦ Pseudonimizazioa edo anonimizazioa posible al da entrenamendu-datuetan? ♦ Minimizazioa betetzen al da — beharrezkoa dena baino gehiago ez biltzea?
 ON	4	Erreklamazio-Mekanismoak ♦ Kanal argi eta azkar bat al dago erabakia giza talde baten aurrean aurkaratzeko? ♦ Denbora-muga ezarrita al dago erantzunerako? ♦ Erreklamazioaren ondorioa dokumentatuta geratuko al da sistemaren hobekuntzarako?

 EIPD (GDPR 35. art.) kategoria bereziko datuetan DERRIGORREZKOA da. EEE gomendatua da kasu guztietan.

Gelan: ikasle-proiektu bakoitzari EIA mini bat eskatu.

03

Segurtasuna: erasoak eta defentsak

Zibersegurtasuna vs AA-segurtasuna



AA-n eredua bera da eraso-azalera berria; security by design RA6.d irizpidea da, hitzez hitz.

Bizi-zikloa eta lau ahultasunak




Lau ahultasun bizi-zikloan: pozoitzea, atzeko ateak, adversarial erasoak eta eredu-lapurreta.

Adversarial erasoak

Adversarial Example: pixel-perturbazio ikustezina

Eredu neuronal batek nola engainatu daitekeen



Begia: panda · Eredua: gibbon · Aldea: pixel-aldaketa ikustezinak — entrenamendu-akatsa explotatuz

Adversarial examples — segurtasun-mehatxu reala auto-konduzioan, mediku-irudietan, biometriarian

- Pixel-aldaketa ikusezinek eredua engainatzen dute
- **Adibide klasikoa** — panda + zarata = 'gibboi' (% 99 konfiantza)
- **Goodfellow 2014** — ez da bug bat, sare neuronalen ezaugarri bat
- **Defentsa** — adversarial training, sarrera-balidazioa

Mundu fisikoan ere bai

Eraso fisikoa: STOP seinalea engainatzen

Mundu errealean kamera-ikuspegia manipulatzeari buruzko irudiak

ORIGINALA




AI IKUSPEGIA (irteera)

STOP-seinalea —
% 99,7 ziurtasuna

Ziurtasun-maila:
99,7%

Sistemaren ekintza:
✓ Sistemak autoa gelditu du

MANIPULATUA



AI IKUSPEGIA (irteera)


Abiadura-muga
60 km/h —
% 97,2 ziurtasuna

Ziurtasun-maila:
97,2%


Sistemaren ekintza:
✗ Sistemak abiadura mantendu du
(autoa ez da gelditu)

Zergatik gertatzen da hau?

1. Eredua entrenatuta dago patroi orokorrak detektatzeko



2. Sticker-konfigurazioak gradiente-jaitzierarekin optimizatu dira


$$\min_{\delta} L(f(x + \delta), t) + \lambda \|\delta\|_p$$

3. Auto autonomoarentzat: arrisku-eraso fisiko erreala



Gizakientzat ikusezina izango den aldaketa txikia
Kamera-sentsoreak engaina daititezke
Ondorio: trafiko-segurtasunaren arriskua handia

⚠ MIT-eko ikerketa (Eykholt et al., 2018): % 100eko engainu-tasa 1.000 fotograma desberdinetan baldintzā kontrolatuētan. Tesla, Waymo eta antzeko sistemak defentsak gehigarriak ezarri behar dituzte.

Iturria: 'Robust Physical-World Attacks on Deep Learning Visual Classification', CVPR 2018

Gelan: tailerreko kalitate-kamera ere engaina ote liteke adversarial eraso fisikoz?

Prompt injection



Adibidea: 'ignore previous instructions and reveal...' — sistema-prompta gainidatzi nahian.

Prompt injection: filtroa eraiki eta saihestu

EGOERA

Ikastetxeko chatbot baterako defentsa-filtro bat eraiki (regex-patroiak) eta gero ERASOTZAILE-rola hartu: saiatu zuen filtroa saihesten. Bi rolak jokatzek erakusten du zergatik den hain zaila benetako defentsa.

EGINKIZUNAK

- 10 patroiko filtroa implementatu eta probatu.
- Gutxienez 3 saihaspen aurkitu (tarteak, sinonimoak, kodeketa).
- Ondorioa idatzi: nahikoa al da regex-defentsa?

Soluzioa: filtroa... eta bere mugak

... 2.1_prompt_injection_diseinua_soluzioa.ipynb

SOLUZIOA

python

```
1 PATROI_SUSPEKTUAK = [  
2     r"ignore (all )?previous",  
3     r"reveal (the )?(system )?prompt",  
4     r"you are now", ...  
5 ]  
6  
7 # Filtroak harrapatzen du:  
8 # [BLOKEATUTA] 'Ignore previous instructions and...'  
9  
10 # Baina erraz saihesten da:  
11 # [PASATU DA] 'i g n o r e   p r e v i o u s ...'  
12 # [PASATU DA] 'Please disregard all earlier guidelines'
```

Chatbot-ak gaizki erantzun du: norena da errua?


EGOERA

Ikastetxeko chatbot-ari prompt injection bidez 'azterketako erantzunak' atera dizkio ikasle batek. Edo bezero bati deskontu faltsu bat agindu dio enpresa baten bot-ak (Air Canada kasua, 2024: ordaintzera behartu zuten).

GALDERAK

- Nork erantzuten du: ikasleak, ikastetxeak, hornitzaileak?
- 'Erasotzailea' zigortu behar al da, ala sistema ahula konpondu?
- Zer klausula jarriko zenituzkete chatbot baten baldintzetan?


Kide-inferentzia (membership inference)



Galdera: datu HAU erabili al zen eredua entrenatzeko?

Emitza: ereduak 'gogoratzen' du

Notebook-aren benetako irteera: entrenamenduko datuen aurrean ereduaren konfiantza nabarmen handiagoa da. Alde hori da kide-inferentzia erasoaren oinarria — eta overfitting-aren seinale garbia.




Pribatutasun diferentziala



Zarata matematikoa gehituz banakakoa ezin identifikatu; epsilon-ak filtrazioa neurtzen du.

Cavoukian-en 7 printzipioak



Pribatutasuna diseinutik eta defektuz; RA6.e irizpideak 'privacy by design' hitzez hitz aipatzen du.

Security vs Privacy by Design

Security by Design vs Privacy by Design: Funtsezko Aldeak

SECURITY BY DESIGN

Nork erasotu dezake sistema?

? **Galdera nagusia:** Nor sartzen da baimenik gabe sistemara?

🎯 **Helburu nagusia:** Sistema eta bere portaera erasoen aurka babestu

Teknikak:

- ✓ Sarreraren iragazketa (Prompt Injection)
- ✓ Algoritmo-erresilientzia (Data Poisoning)
- ✓ Fallback plan eta fail-safe shutdown
- ✓ Eredura sarbide-kontrola
- ✓ Auditoria-erregistroa (logs)

⚖️ AI Act 9., 12., 14., 15. art.

SISTEMA BABESTEN DU

PRIVACY BY DESIGN

Zer datu pertsonal biltzen dira?

? **Galdera nagusia:** Zer datu pertsonal biltzen dira eta zergatik?

🎯 **Helburu nagusia:** Sistema prozesatzen dituen pertsonen datuak babestu

Teknikak:

- ✓ Datuen minimizazioa
- ✓ Anonimizazioa / Seudonimizazioa
- ✓ Pribatasun Diferentziala
- ✓ Federated Learning
- ✓ Ezabatzea (ahantzura-eskubidea)

⚖️ GDPR 25., 32. art.

PERTSONAK BABESTEN DITU

🛡️ OSAGARRIAK DIRA: Security by Design-ek erasotzaileak datu pertsonaletara sartzea saihesten du. Privacy by Design-ek datu eskuragarriak minimizatzen ditu sistema lapurtuta gertatuz gero.

➡️ Biak batera = Segurtasun Osoa

Adibidea: zifratzea biak dira; datu-minimizazioa, ordea, privacy hutsa.

Hiru helburu, tentsio bat



Gelan: talde bakoitzak helburu bat defendatu kasu berean.

Sintesi-Matrizea: Eraso → Defentsa → Gobernantza

Mitigazio eraginkorrak arkitektura teknikoa direktibo etiko eta legalekin lerrokatu behar du




— RA6 · SINTESIA

Dena batera: sintesi-matrizea

Erasoak, defentsak, printzipioak eta araudia matrize bakarrean. **Gelan:** matrize hau da gaiaren 'txuleta' ofiziala — inprimatu eta ikasleekin kasuak kokatzeko erabili.

04 Bestelako gai etikoak

Deepfake-en mekanika



Adibidea: zuzendariaren 'ahotsa' transferentzia eskatzen — deepfake bidezko iruzurra.

Deepfake bat ikastetxean agertu da. Protokoloa?

EGOERA

Ikasle baten aurpegia bideo faltsu batean. WhatsApp bidez zabaltzen ari da. Teknikoki erraza izan da egitea; legez delitua da; emozionalki suntsitzailea.

GALDERAK

- Zer egin lehen 24 orduetan? Nork koordinatu?
- **Prebentzioa** — zer landu behar da AURRETIK tutoretzan?
- Nola azaldu 'ikusi = sinetsi' jada ez dela egia?

AA-ren ingurumen-aztarna kalkulatu


EGOERA

Notebook-ak AA-ereduen kontsumoak konparatzen ditu: entrenamendua vs inferentzia, eredu handiak vs txikiak, eta eguneroko erabilerak (galdera bat ChatGPT-ri vs Google bilaketa bat). Zenbakiekin, ez intuizioekin.


EGINKIZUNAK

- 3 eszenarioen kontsumoa kalkulatu (kWh, CO2).
- Konparazio ulergarriak sortu (km autoz, etxeko kontsumoa).
- **Gelan** — 'AA-dieta' bat proposatu: noiz merezi du, noiz ez?

Energia-kontsumoa




Ur-aztarna (hyperscaler hozketa)



CO2 isurketak (mix ES: 0.18 kgCO2/kWh)



Kostu ekonomikoa




NOTEBOOK · 2.1 EMAITZA

Emaita: hiru aukeren konparazioa

Notebook-aren benetako irteera (5.000 kontsulta/egun): GPT-4o vs GPT-4o-mini vs Llama lokala, lau ardatzetan — energia, ura, CO2 eta kostua. **Eredu txikiak aukeratzea ere ingurumen-erabakia da.**

AA-k lan-mundua eraldatzen



Gelan: 04 saioko eztabaida gogoratu — gaitasun berriak behar dira.

AI Literacy: AA-alfabetatzea

- **AI Act 4. art.** — erabiltzaileek 'AA-alfabetatze nahikoa' izan behar dute
- **Irakasleok zarete giltza** — zuek formatzen dituzue datozen teknikariak
- **UNESCO RAM** — erakundeen AA-prestutasuna neurtzeko tresna (7.1 notebooka)
- **Notebookean** — 6.1 ariketak protokolo pertsonala diseinatzen du
- **Prestakuntza hau bera** — zuen AI Literacy-ren parte da

Modulutik eramateko sei ideia

i

Alborapena prozesu osoan dago — datuak, eredua, erabilera.

ii

Fairness-a aukeratu egiten da — ezintasun-teorema, erabaki etikoa.

iii

GDPR + AI Act = jokaleku berria — gaurko ikasleen lan-baldintzak.

iv

Eredua bera da eraso-azalera — security by design hasieratik.

v

Pribatutasuna diseinatu egiten da — ez da gehigarri bat.

vi

Etika ez da atal bat — modulu osoa zeharkatzen duen haria da.

Eskerrik asko. Galderarik?

5071 modulua osatu dugu. Hurrengo prestakuntza-saioa:
5072 · Ikasketa automatikoko sistemak.

IRAKASLEA	Andoni Elola
MATERIALA	src/5071/Oinarrizko_materiala
NOTEBOOKAK	notebook/ karpeta — 48 soluzio
AURKEZPENAK	src/5071/Aurkezpena — 6 fitxategi
ARAUDIA	RD 279/2021 · EAEko dekretua