

1. ATALA

Datuak eta Aurreprozesamendua

EGILEA

ZENTROA

EDIZIOA

IKASTAROA

Laneki — FP Euskadi

v1.0

2026 — 2027

Datua eta Aurreprozesamenua

Ikasketa automatikoaren eta datu-analisi aurreratuaren testuinguruan, **datu-aurreprozesatzea fase metodologiko funtsezkotzat** jotzen da. Eredu prediktiboen errendimendua eta fidagarritasuna ez dira soilik erabilitako algoritmoaren aukeraren arabera, baizik eta neurri handi batean sarrerako **datuen kalitatearen eta tratamenduaren menpe** ere bai.

Aurreprozesatzearen helburua zera da: datu gordina formatu gordin, heterogeneo eta sarritan "zikinetik" analisi estatistiko eta modelizaziorako egokia den egitura bateratura eramatea. Horrek barne hartzen ditu: balio faltan tratamendua, kanpoko balioen identifikazioa eta zuzenketa, aldagaien eraldaketa eta eskalatzea, aldagai kategorikoen kodetzea eta klase-desoreken zuzenketa.

01.1 Datu-multzoaren egitura eta aldagai motak

Datu-multzo tipiko bat **ezaugarrien matrize** X ($n \times p$) moduan irudika daiteke, eta aurreikusi nahi dugun aldagaia **etiketa bektore** y -n gordetzen da:

$$X = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix} \quad y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

Non:

- n : errenkada kopurua $\rightarrow$ instantzia edo behaketa kopurua.
- p : zutabe kopurua $\rightarrow$ ezaugarri edo aldagai kopurua.
- x_{ij} : i -instantziako j -aldagaiaren balioa.
- y_i : i -instantziaren etiketa (adib. etxe-prezioa, edo $\{0,1\}$ sailkapenean).

Aldagaien tipologia:

Mota	Deskribapena	Adibidea
Kuantitatibo jarraia	Eskala jarraitu batean neurtuak	Altuera, prezioa
Kuantitatibo diskretua	Zenbaki osoetan neurtuak	Elementu kopurua
Kualitatiboa nominala	Kategoriatan sailkatuak, ordenarik gabe	Kolorea, herrialdea
Ordinala	Kategoriatan sailkatuak, ordena implizituarekin	Balorazio eskala 1–5

Aldagai motaren identifikazioa **lehen pauso sistematikoa** da: haren arabera izango da kodetze-estrategia, eskalatze beharra eta erabilgarriak diren neurri estatistikoak.

01.2 Aurreprozesatzearen aurretiko azterketa (EDA)

Datu-aurreprozesamendu arduratsua ezin da hasi datuaren lehen azterketa deskriptiborik egin gabe. **Azterketa esploratiboa (Exploratory Data Analysis, EDA)** datu-multzoaren egitura, banaketa eta balizko arazo nagusiak identifikatzeko erabiltzen da.

Aldagai kuantitatiboetarako estatistika deskriptibo klasikoak erabiltzen dira:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (\text{batezbestekoa}) \quad s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \quad (\text{desbideratze estandarra})$$


- Mediana, moda (banaketa asimetrikoetarako sendoagoak)
- Min / Max, kuartilak Q1 eta Q3
- Asimetria (*skewness*) eta kurtosia (*kurtosis*) — banaketaren forma neurtzeko

EDAREN tresna nagusiak:

- Histogramak (banaketaren forma ikusteko)
- Kutxa-diagramak / boxplot-ak (outlierrak eta IQR ikusteko)
- Balioen maiztasun-taulak (kategorikoetarako)
- Korrelazio-matrizea (aldagaien arteko erlazio lineala neurtzeko)

01.3 Erregresio Lineal Sinplea: aurreprozesatzearen motibazioa

Erregresio lineal sinplea ikasketa gainbegiratuaren oinarritzko eredu linealetako bat da, eta oso egokia da aurreprozesatzearen beharra justifikatzeko. Aldagai kuantitatibo baten (Y) eta beste aldagai prediktore baten (X) arteko erlazioa modelatzen du.



Eredu teorikoa (benetako erlazio ezezaguna):

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

Eredu estimatua (guk kalkulatutako iragarpen-lerroa):

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

Non:

- $\beta_0 / \hat{\beta}_0$ (moztunea): $X = 0$ denean Y -k duen balio estimatua.
- $\beta_1 / \hat{\beta}_1$ (malda): X unitate bat handitzean Y -n espero den aldaketa.
- ε_i (errorea/hondarra): Ereduak azaldu ezin duen zatia — **ezezaguna eta inoiz ezin kalkulatuzuzenean**.

△ Kontuz: $\hat{y}_i$ iragarpenaren estimazioa da eta ez du ε_i barnean hartzen. Hondarra ($e_i = y_i - \hat{y}_i$) ε_i -ren estimazioa da, baina ez dira gauza bera.

GUTXIENeko KARRATUEN METODOA (OLS)

β_0 eta β_1 parametroak kalkulatzeko, **Gutxieneko Karratuen Metodoa (Ordinary Least Squares – OLS)** erabiltzen da. Metodo honen helburua da datu-puntuen eta erregresio-lerroaren arteko distantzien karratuen batura minimizatzea.

Distantzia horiei **hondarrak** deitzen zaie:

$$e_i = y_i - \hat{y}_i$$

Hondarrak positiboak edo negatiboak izan daitezkeenez, karratura igotzen dira (akats guztiak batu daitezen, elkar deuseztatu gabe) eta horiek minimizatzen dituen lerroa da "egokiena".

DETERMINAZIO KOEFIZIENTEA (R^2)

Behin erregresio-lerroa lortuta, R^2 balioak ereduaren doitasuna neurtzen du:

- **SST (Aldakortasun Osoa):** Datuetan dagoen desberdintasun osoa.

$$SST = \sum_i (y_i - \bar{y})^2$$

- **SSR (Aldakortasun Azaldua):** Erregresio-lerroak azaltzen duen aldakortasun zatia.

$$SSR = \sum_i (\hat{y}_i - \bar{y})^2$$

- **R^2 :**

$$R^2 = \frac{SSR}{SST}$$

- $R^2 = 1 \rightarrow$ Eredu perfektua (aldakortasun guztia azalduta).
- $R^2 = 0 \rightarrow$ Ereduak ez du ezer azaltzen.

ADIBIDE PRAKTIKOA: PUBLIZITATEA ETA SALMENTAK

Enpresa batek hilabeteroko publizitate-gastua eta salmentak aztertu nahi ditu. Sei hilabeteko datuak aztertu ostean, erregresio-eredu hau lortzen da:

$$\widehat{Salmentak} = 5.2 + 2.1 \times Publizitatea$$

Interpretazioa:

- $\beta_0 = 5.2$: Publizitatean ezer gastatuko ez bagenu, oinarritzko salmentak **5.200 €** lirateke.
- $\beta_1 = 2.1$: Publizitatean gastatutako mila euro gehigarri bakoitzeko, salmentak batez beste **2.100 €** igotzen dira.
- Iragarpena ($X = 10$): $\hat{y} = 5.2 + 2.1 \times 10 = 26.2 \rightarrow$ **26.200 €** espero.

01.4 Ezaugarri Ingeniaritza (Feature Engineering)

Ezaugarri-ingeniaritza datu-multzo bateko aldagaiak sistematikoki definitu, eraldatu eta konbinatzeko prozesua da. Datu gordinek berez erakusten ez duten **informazio ezkutua "erauztea"** du helburu, ereduaren errendimendua eta interpretagarritasuna maximizatzeko.

Prozesu hau bi ardatz nagusitan oinarritzen da:

1. **Aldagai-hautaketa (Feature Selection)**: Hasierako aldagai-multzotatik zeintzuk mantendu eta zeintzuk baztertu erabakitzea — dimentsionaltasuna murriztu eta kolinealitatea kendu.
2. **Aldagai-eraldaketa (Feature Transformation)**: Jatorrizko aldagaiei funtzio matematikoak aplikatzea egitura hobetzeko — eskalan jarri, kodetu, logaritmoa aplikatu, konbinatu...

ALDAGAI-HAUTAKETA (FEATURE SELECTION)

Aldagai-hautaketa sarrerako aldagaien artean zeintzuk mantendu eta zeintzuk baztertu erabakitzekeo prozesu sistematikoa da. Bi helburu nagusi ditu:

1. **Dimentsionaltasunaren murrizketa**: Zenbat eta aldagai gehiago, orduan eta handiagoa da "dimentsionaltasunaren arazoa" arriskua (gaindoiketa). Aldagai gutxiagorekin, eredu arinagoak eta interpretatzeko errazagoak lortzen dira.
2. **Kolinealitatearen kudeaketa**: Aldagai independenteak sarritan elkarren artean korrelazionatuta daude, informazio erredundantea sartuz eredu.

MULTIKOLINEALITEA ETA VIF

Multikolinealitatea aldagai independenteen arteko korrelazioa handia denean gertatzen da. Adibidez: "Hezkuntza Maila" eta "Sarrera Ekonomikoak" oso korrelazionatuta egon daitezke.

Multikolinealitatea neurtzeko tresna nagusia **Variance Inflation Factor (VIF)** da:

$$VIF_j = \frac{1}{1 - R_j^2}$$

Non R_j^2 den X_j aldagaia gainerako ezaugarriekin erregresio linealean azaltzen duen determinazio koefizientea.

- **VIF < 5**: Onartua.
- **VIF 5–10**: Arreta beharrezkoa.
- **VIF > 10**: Kolinealitate arazoa; aldagaia kentzea gomendatzen da.

01.5 Balio Faltak: identifikazioa eta inputazio-estrategiak

Datu-multzo errealetan, **balio faltak (missing values)** ia beti agertzen dira. Hauen jatorria anitza da: erregistro-erroreak, inkestetan erantzun eza, sentsore-hutsegiteak...

Tratamendua aukeratu aurretik, balio falten **jatorria** ezagutzea funtsezkoa da:

Mota	Izena	Deskribapena	Ondorioa
MCAR	<i>Missing Completely At Random</i>	Ausaz falta diren datuak, beste aldagaiekin loturarik gabe	Errenkaden ezabaketa zilegizko aukera
MAR	<i>Missing At Random</i>	Falta izatea beste aldagai batzuekiko lotuta dago, baina ez balio propioarekiko	Inputazio eredua gomendatzen da
MNAR	<i>Missing Not At Random</i>	Balio bera da falta izatearen arrazoia (adib. soldata altua dutenek ez dute erantzuten)	Arazo larria — eredu berezi bat behar da

Tratamendu-estrategiak:

Estrategia	Deskribapena	Abantaila	Desabantaila
Errenkaden ezabaketa	Balio falta duten erregistroak kendu	Sinplea	Informazio-galera handia
Batezbestekoaren inputazioa	Aldagai kuantitatiboetarako: $\bar{x} = \frac{1}{n} \sum x_i$	Azkarra	Bariantza murrizten du
Medianaren inputazioa	Outlierrekiko sendoagoa	Sendoa	Banaketa deformatzen du
KNN-inputazioa	K auzokide hurbilenen balioen batezbestekoa: $\hat{x}_i = \frac{1}{N_K(i)} \sum_{j \in N_K(i)} x_j$	Zehatza	Konputazionalki garestia
Eredu prediktibo bidezko inputazioa	Balio falta beste aldagaiekin iragarri (erregresio bat)	Zehaztasun handia	Konplexutasun handia

01.6 Muturreko Balioak (Outliers)

Muturreko balioak gainerako behaketen banaketatik nabarmen aldentzen diren puntuak dira. Bi egoera bereizi behar dira: neurraketa-errore hutsak (kendu) eta muturreko gertaera errealean adierazleak (baliotsuak izan daitezke anomalia-detekzioan).

Z-SCORE METODOA

$$Z_i = \frac{x_i - \mu}{\sigma}$$

$|Z_i| > 3$ denean, balioa outlier potentzialtzat hartzen da (banaketa normala suposatuz).

IQR (INTERQUARTILE RANGE) METODOA


$$IQR = Q_3 - Q_1$$

Muturreko balioak:

$$\text{Muga baxua} = Q_1 - 1.5 \times IQR \quad \text{Muga altua} = Q_3 + 1.5 \times IQR$$

Metodo hau sendoagoa da banaketa ez-normala denean. Boxplot-ean bistaratzea intuitiboa da: bigote-mugetatik kanpo dauden puntuak outlierrak dira.

Boxplot eta IQR: Outlier Detekzioa



Boxplot eta IQR: Q_1 , Q_2 , Q_3 , mugak eta outlierrak

Tratamendu aukerak:

- **Ezabatu:** Argi bada neurketa-errore edo akats bat.
- **Mugatu (capping/winsorizing):** Balio muturrak kuartil-mugen balioekin ordezkatu.
- **Transformatu:** Logaritmoa, erro karratua... banaketaren asimetria murrizteko.

01.7 Aldagai Kategorikoen Kodetzea

Aldagai kategorikoen ezin dute zuzenean parte hartu zenbakizko kalkuluetan. Bi hurbilketa klasiko:

1. LABEL ENCODING

Kategoria bakoitzari zenbaki oso bat esleitzen dio:

- "Gorria" $\rightarrow 0$
- "Berdea" $\rightarrow 1$
- "Urdina" $\rightarrow 2$

□ **Arriskua:** Ordenazio artifizia sartzan du. Eredu linealek $2 > 1 > 0$ ulertuko dute, nahiz eta kategorien artean ordena semantikorik ez egon. Zuhaitz-ereduetan egokia.

2. ONE-HOT ENCODING

Kategoria bakoitzerako zutabe bereizi bat sortzen da:

Kategoria	Gorria	Berdea	Urdina
Gorria	1	0	0
Berdea	0	1	0
Urdina	0	0	1

Normalean kategoria bat "erreferentzia" gisa kentzen da (m kategoriatik $m - 1$ zutabe) multikolinealitatea saihesteko. Honi "**dummy variable trap**" deritzo: m zutabe sortzen badira, azkenak beti kalkula daiteke gainerakoetatik, informazio erredundantea sartuz. **Eredu lineal eta distantzian oinarritutakoetan gomendagarria.**

Aldagai Kategorikoen Kodetzea

Label Encoding

Kolorea	Kodea
Gorria →	0
Berdea →	1
Urdina →	2

⚠ **Arriskua:** Ordenazio artifiziala — ereduak 'Urdina > Berdea > Gorria' ulertzen du, baina hori ez da egia!

✅ **Egokia:** Zuhaitz-ereduetan (Decision Tree, Random Forest)

One-Hot Encoding

Kolorea	Gorria	Berdea	Urdina
Gorria →	1	0	0
Berdea →	0	1	0
Urdina →	0	0	1

ℹ $m-1$ zutabe erabili ($m=3 \rightarrow 2$ zutabe), 'Dummy Trap' saihesteko

✅ **Egokia:** Eredu linealetan eta KNN-n

Label Encoding vs One-Hot Encoding: alderaketa bisuala

01.8 Eskalatzea eta Normalizazioa

Ezaugarrien eskala desberdinek eragin zuzena dute algoritmo askoren jokabidean. Distantzian oinarritzen diren algoritmoetan (KNN, SVM) eta gradiente-bidezkoetan (sare neuronalak, erregresio logistikoa) ezinbestekoa da.

1. STANDARDSCALER (ESTANDARIZAZIOA)

$$z = \frac{x - \mu}{\sigma}$$

Aldagaiak $\mu = 0$ eta $\sigma = 1$ izango ditu. Banaketa normala denean eta gradiente-algoritmoetan gomendagarria.

2. MINMAXSCALER (0–1 NORMALIZAZIOA)

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Balioak $[0,1]$ tartean jartzen ditu. Outlierrek eragin handia dute min/max-ean.

3. ROBUSTSCALER (ESKALA SENDOA)

$$x' = \frac{x - Q_2}{IQR}$$

Non Q_2 **mediana** den ($Q_2 = P_{50}$). Mediana eta IQR-ean oinarritzen da — outlierrek ez dute eraginik hauetan. Outlier ugariko datuentzat egokia.

Zein algoritmo da eskalatze-sentikorra?

Sentikorra	Ez sentikorra
KNN, SVM, sare neuronalak	Decision Tree, Random Forest
Erregresio lineal/logistikoa (gradienteaz)	Gradient Boosting
K-Means	—

01.9 Klase-Desoreka eta Datu-Orekatzea

Klasifikazio-problema askotan, helburu-aldagaiaren banaketa desorekatuta dago (iruzur-detekzioa: %99 normal, %1 iruzur). Honek eredu desorekatuak sortzen ditu.

Imbalance Ratio (IR):

$$IR = \frac{\text{Gehiengo klasearen instantzia kopurua}}{\text{Gutxiengo klasearen instantzia kopurua}}$$

$IR > 3$ denean, desoreka nabarmena kontsideratzen da.

OVERSAMPLING SINPLEA

Gutxiengo klaseko erregistroak kopiatu, behar beste aldiz. Abantaila: sinplea. Desabantaila: gaindoiketa-arriskua (datu berdinak behin baino gehiagotan ikusi).


SMOTE (SYNTHETIC MINORITY OVER-SAMPLING TECHNIQUE)

SMOTE-k **instantzia sintetikoak** sortzen ditu, errepikapen mekanikoak baino informazio gehiago emanez:

1. Hautatu gutxiengo klaseko instantzia bat: x_i
2. Aurkitu bere K auzokiderik hurbilenenak
3. Aukeratu ausaz x_{nn} auzokidetako bat
4. Sortu puntu berri sintetiko bat lerroan:


$$x_{berri} = x_i + \lambda \cdot (x_{nn} - x_i), \quad \lambda \in [0,1]$$

Aurretik: Klase Desoreka



SMOTE
→

Ondoren: SMOTE aplikatu



SMOTE: klase-desoreka eta puntu sintetikoen sorkuntza

	Oversampling sinplea	SMOTE
Instantziak	Kopiak (berdinak)	Sintetikoak (berriak)
Overfitting arriskua	Altua	Baxuagoa
Konplexutasuna	Baxua	Ertaina
Informazio berria	Ez	Bai