

Datua eta *Aurreprozesatzea*

Datu-motak, balio faltak, outlierrak, kodetzea, eskalatzea eta klase-desoreka.

Zikloa Goi-mailako zikloa · Adimen Artifiziala eta Big Data

Ikasturtea 2025 / 2026



Saio honetan ikusiko duguna

01 Datu-multzoaren egitura eta aldagai motak

02 Azterketa esploratiboa (EDA)

03 Erregresio Lineal Sinplea eta R^2

04 Balio Faltak: identifikazioa eta inputazioa

05 Kanpoko Balioak (Outliers)

06 Aldagai Kategorikoen Kodetzea

07 Eskalatzea eta Normalizazioa

08 Klase-Desoreka eta SMOTE

Aurreprozesamenduak zergatik du garrantzi handia?

'**Garbage in, garbage out**' — Datu txar batekin algoritmo perfektuak ere huts egingo du.

Proiektu baten denboraren **%60–80** aurreprozesatzeak hartzen du, algoritmo aukeraketak baino askoz gehiago.

Amazon 2018 — CV hautatzaile automatikoak **emakumeak sistematikoki baztertu** zituen datu historiko desorekatuengatik.

Ereduaren **fidagarritasuna eta zehaztasuna** zuzenean datuen kalitatearen menpe daude.

Aurreprozesatzea = **fase metodologiko garrantzitsua**, ez urrats osagarri bat.

Lantzen dituen faseak: balio faltak → outlierrak → kodetzea → eskalatzea → desoreka.

Datu gordina sarritan: balio faltsuak, eskala desberdinak, kategoria kodetugabeak, klase desorekatuak.

Helburua — Datu gordina ereduak ulertzeko **formatu egoki eta homogéneo** batera bihurtzea.

Aldagai motak: identifikatu eta egoki tratatu

MOTA	DESKRIBAPENA	ADIBIDEA	TRATAMENDUA
Kuant. jarraia	Eskala jarraitu batean neurtuak; edozein balio har dezake	Altuera (1.72), prezioa (245.50€)	Eskalatu (StandardScaler / MinMaxScaler)
Kuant. diskretua	Zenbaki osoetan soilik; multzo finitu bat	Logela kopurua (1, 2, 3...)	Eskalatu edo kategorikotzat hartu
Kualit. nominala	Kategoriatan sailkatuak; artean ordena semantikorik ez	Kolorea, herrialdea, auzoa	One-Hot Encoding (ordena saihestu)
Ordinala	Kategoriatan sailkatuak; ordena inplizitua bai, distantzia ez	Balorazio 1–5, hezkuntza-maila	Label Encoding (ordena errespetatu)

Azterketa Esploratiboa (EDA): datu-multzoaren lehen begirada

- **Helburua** — Eredua eraiki aurretik datuak ezagutu: egitura, banaketa eta balizko arazo nagusiak.
- **Batezbestekoa eta desbideratze estandarra** — Datuen 'zentroa' eta 'zabalera' neurtzeko.
- **Mediana eta moda** — Banaketa asimetrikoetan batezbestekoak baino informazio gehiago (soldaten adibidea).
- **Histogramak** — Banaketaren forma ikusteko: normala, asimetrikoa, bimodala, uniformeak...
- **Boxplot-ak** — Outlierrak eta Q1·Q2·Q3 kuartilak bistaratzeko modu intuitiboa.
- **Korrelazio-matrizea** — Zein aldagaien artean dagoen erlazio lineala; multikolinealitatea detektatzeko.
- **Maiztasun-taulak** — Aldagai kategorikoen banaketa ikusteko; klase desorekak aurrez detektatzeko.


Inputazio-estrategiak: abantailak eta desabantailak

ESTRATEGIA	NOIZ ERABILI	ABANTAILA	DESABANTAILA
Errenkada ezabatu	MCAR eta datu asko (>10.000)	Sinplea eta azkarra	Informazio-galera handia klase minoritarioan
Batezbestekoaren inputazioa	MCAR, aldagai jarraia, banaketa normala	Azkarra, erraza	Bariantza murrizten du; outlierrekiko sentikorra
Medianaren inputazioa	Outlierrak daudenean	Outlierrekiko sendoa	Banaketa pixka bat deformatzen du
KNN inputazioa	Egitura konplexua mantendu nahi	Datu egitura errespetatzen du	Konputazio-kostu handia datu-multzo handian
Eredu prediktiboa	Zehaztasuna kritikoa denean	Zehaztasun handia	Konplexutasun handia; gaindoiketa-arriskua

Boxplot, IQR eta Z-Score: outlierrak identifikatu

- **IQR = Q3 - Q1** — Erdiko %50aren zabalera; outlierrekiko sendoa
- Muga baxua = $Q1 - 1.5 \times IQR$ · Muga altua = $Q3 + 1.5 \times IQR$
- Bigoteetatik kanpo → outlier potentziala; ez da beti akats bat
- **Z-Score** — $Z_i = (x_i - \mu)/\sigma$ · $|Z| > 3 \rightarrow$ outlier (banaketa normala suposatuz)
- **Z-Score vs IQR** — Z-Score banaketa normala behar du; IQR sendoagoa ez-normalentzat
- **Kontuz** — Outlier = akats? Ez beti: transakzio oso handia iruzurra izan daiteke BAINA baita etxe-erosketa ere

Boxplot eta IQR: Outlier Detekzioa



Outlier tratamendua: hiru estrategia nagusi

- **Ezabatu** — Soilik argi eta garbi dagoenean neurketa-errore edo idazketa-akats bat dela.
- **Mugatu (Capping/Winsorizing)** — Balio muturrak $Q1-1.5 \times IQR$ edo $Q3+1.5 \times IQR$ mugen balioekin ordezkatu.
- **Transformatu** — Logaritmoa edo erro karratua aplikatu banaketaren asimetria murrizteko: $x' = \log(x)$.
- **Mantendu** — Anomalia-detekzio sistemetan outlierrak dira ikasi nahi dugun gauza nagusia.
- **Araua praktikoa** — Kendu baino lehen galdera: '**Outlier honek informazio baliotsua al du?**'
- **Erregistratu beti** — Nola eta zergatik tratatu den dokumentatu: erreproduzibilitatea funtsezkoa.

Label Encoding vs One-Hot Encoding

Aldagai Kategorikoen Kodetzea

Label Encoding

Kolorea	Kodea
Gorria →	0
Berdea →	1
Urdina →	2

⚠ **Arriskua:** Ordenazio artifiziala — ereduak 'Urdina > Berdea > Gorria' ulertzen du, baina hori ez da egia!

✅ **Egokia:** Zuhaitz-ereduetan (Decision Tree, Random Forest)

One-Hot Encoding

Kolorea	Gorria	Berdea	Urdina
Gorria →	1	0	0
Berdea →	0	1	0
Urdina →	0	0	1

ℹ $m-1$ zutabe erabili ($m=3 \rightarrow 2$ zutabe), 'Dummy Trap' saihesteko

✅ **Egokia:** Eredu linealetan eta KNN-n


- **Label Encoding** — Kategoria bakoitzari zenbaki oso bat: Gorria=0, Berdea=1, Urdina=2
- **Arriskua** — Ordenazio artifiziala sartzen du: ereduak 'Urdina > Berdea > Gorria' ulertuko du
- **Noiz da egokia?** — Zuhaitz-ereduetan (Decision Tree, Random Forest): ez dute ordenazio problema
- **One-Hot Encoding** — Kategoria bakoitzeko zutabe berezia sortu (0 edo 1 bakarrik)
- **Dummy trap** — m kategoriatik $m-1$ zutabe soilik: azkenak beti kalkula daiteke gainerakoetatik
- **Noiz egokia** — Eredu lineal eta distantzian oinarritutakoetan (KNN, SVM, erregresio)

Eskalatzea eta Normalizazioa: zein algoritmo eta zein metodo

METODOA	FORMULA	NOIZ ERABILI	KONTUA
StandardScaler	$z = (x - \mu) / \sigma$	Banaketa normala · Sare neuronalak · Erregresio	Outlierrekiko sentikorra (μ eta σ aldatzen ditu)
MinMaxScaler	$x' = (x - x_{\min}) / (x_{\max} - x_{\min})$	[0,1] tartea behar denean · Irudi-datuak	Outlierrek min/max aldatu → balioak txikitu
RobustScaler	$x' = (x - Q_2) / IQR$	Outlier asko daudenean	Mediana eta IQR erabiltzen ditu: outlierrekiko immunea

SMOTE: instantzia sintetikoak sortuz klase-desoreka konpondu

- **Arazoa** — Iruzur-detekzioan: %99 normal, %1 iruzur → ereduak beti 'normal' iragartzen du eta %99 zehaztasuna lortzen du
- **Imbalance Ratio IR > 3** — Gehiengo/gutxiengo klase ratioa; desoreka nabarmena
- **Oversampling sinplea** — Kopiak egin: gaindoiketa-arriskua handia (datu berdinak behin baino gehiagotan)
- **SMOTE** — $x_{berria} = x_i + \lambda \cdot (x_{nn} - x_i)$ · Puntu sintetiko berriak bi auzokideren artean
- **Abantaila** — Kopiak ez, informazio errealista berria; overfitting-arriskua txikiagoa
- **Arau kritikoa** — SMOTE soilik train datuekin aplikatu, inoiz ez test multzoan



Gako-ideiak

-
- i* Aurreprozesamenduak proiektuaren %60–80 hartzen du — algoritmo aukeraketa baino garrantzitsuagoa.

 - ii* Aldagai mota identifikatu lehenik: nominala → One-Hot; ordinala → Label; jarraia → eskalatu.

 - iii* Balio falten jatorria aztertu (MCAR/MAR/MNAR): jatorriaren araberako tratamendua hautatu.

 - iv* Outlierrak ez dira beti akatsak — testuingurua ulertu eta dokumentatu erabakia.

 - v* Eskalatzea ezinbestekoa KNN, SVM eta sare neuronalarentzat; zuhaitzek ez dute behar.

 - vi* SMOTE klase-desoreka konpontzeko, baina inoiz ez test multzoan aplikatu — datu-ihesa sortzen du.

Galderarik?

MATERIALA	5072_1_Datua_eta_Aurreprozes amenua.md
HURRENGO SAIOA	3.2 · Ikasketa Gainbegiratua