


ADIMEN ARTIFIZIALA · IKASKUNTZA AUTOMATIKOA

Erregresio Logistikoa

(Logistic Regression)

Sailkapen bitarra, funtzio sigmoidea eta erabaki-muga — diagramekin azalduta



Zer da Erregresio Logistikoa?

Definizioa

Ikaskuntza automatikoko algoritmo gainbegiratua da, sailkapen bitarrerako (binary classification) erabiltzen dena: emaitza bi klasetako batean sailkatzen du (adib. bai/ez, 0/1).



Sailkapen bitarra

Bi klase bereizteko erabiltzen da (0 edo 1).



Irteera [0,1] tartean


Probabilitate gisa interpreta daiteke.



Kanpoko balioekiko erresistentea

Sigmoideak balio muturrekoak leuntzen ditu (tapering).

FUNTZIO SIGMOIDEA — IRTEERA BORNATUA




Kontuan izan: Testu-sailkapeneko hasierako algoritmo ona da; eskalatzeak (feature scaling) doitasuna hobetzen du.

Zergatik ez Erregresio Lineala Sailkatzeko?


Arazoa

Erregresio linealak edozein balio erreal itzul dezake $(-\infty, +\infty)$, baina sailkapenerako $[0,1]$ tarteko probabilitate bat behar dugu. Horregatik funtzio sigmoidea erabiltzen da, irteera beti $[0,1]$ artean mantentzeko.

Erregresio lineala (ez egokia)



Erregresio logistikoa (egokia)



Ondorioa: Lerro zuzenak $[0,1]$ mugak gainditzen ditu; sigmoideak, ordea, irteera beti tarte horretan mantentzen du.

Ereduaren Ekuazioa

Aurreikuspen-funtzioa

$$z = w \cdot x + b$$

$$g(z) = 1 / (1 + e^{-z})$$

g $g(z)$

Aurreikusitako probabilitatea

w w

Malda edo koefizientea

x x


Aldagai independentea(k)

b b

Konstantea edo ebaki-puntua

! **Atalasea:** $g(z) \geq 0.5$ bada, 1 klasea aurreikusten da; bestela, 0 klasea.

FUNTZIO SIGMOIDEAREN GRAFIKOA




Erabaki-muga (Decision Boundary)

Kontzeptua

$g(z) = 0.5$ betetzen duten puntuek erabaki-muga osatzen dute: alde batean 0 klasea aurreikusten da, bestean 1 klasea.

BI KLASEEN SAKABANAKETA ETA ERABAKI-MUGA



Galera-funtzioa (Loss Function)




Adibide bakarraren errorea

$$L(g, y) = -y \cdot \log(g) - (1-y) \cdot \log(1-g)$$

Zergatik funtzio hau?

- Erregresio linealeko MSE galera-funtzioa sigmoidearekin konbinatuz gero, ez-konbexua da (minimo lokal ugari).
- Entropia gurutzatuak, ordea, funtzio konbexu bakarra ematen du: optimizazioa errazagoa da.
- $y=1$ denean, g txikia bada zigor handia; $y=0$ denean, g handia bada zigor handia.

GALERA-KURBAK: $y=1$ ETA $y=0$



Kostu-funtzioa eta Gradiente Jaitsiera

Kostu-funtzioa

$$J(w, b) = (1/m) \sum [-y^{(i)} \log(g^{(i)}) - (1-y^{(i)}) \log(1-g^{(i)})]$$

Eguneratze-erregela

$$w := w - \alpha \cdot \partial J / \partial w$$


$$b := b - \alpha \cdot \partial J / \partial b$$



Eskalatzearen garrantzia

- Gradiente-jaitsieran oinarritutako algoritmoek (erregresio lineal/logistikoa, sare neuronalak) eta distantzian oinarritutakoek (kNN, K-means, SVM) eskalatzea behar dute, datuen tartearikiko sentikorrak baitira.

$J(w)$ KONBEXUA ETA GRADIENTE-JAITSIERAREN URRATSAK



Abantailak eta Desabantailak



Abantailak

- Sinpletasuna eta interpretagarritasuna
- Efizientea konputazio-kostuan
- Erregularizazioa (L1/L2)

Gainegokitzea eta kolinealtasuna kontrolatzen laguntzen du.

- Klase anitzera zabalgarria

One-vs-Rest edo One-vs-One tekniken bidez.




Desabantailak

- Linealtasun-hipotesia (log-odds)
- Kanpoko balioekiko sentikortasun partziala
- Eskalatzea behar du
- Gainegokitzea dimentsio altuan

Sigmoidea: outlierra apenas eragiten du



Erregresio lineala: outlierrak lerroa aldatzen du



Python Inplementazioa



sklearn.linear_model.LogisticRegression

Iris datu-multzoarekin adibide sinple bat, ereduaren doikuntza eta ebaluazioa erakusteko.

```
# Iris datu-multzoa eta erregresio logistikoa sklearn-etik inportatu
from sklearn.datasets import load_iris
from sklearn.linear_model import LogisticRegression

# datu-multzoa kargatu
X, y = load_iris(return_X_y=True)

# ereduaren entrenamendua
clf = LogisticRegression(random_state=0).fit(X, y)

# doitasuna neurtu
clf.score(X, y)
```

Erregresio Logistikoa, urratsez urrats

1

Eredua definitu: $z = w \cdot x + b$ eta $g(z) = 1/(1+e^{-z})$ (sigmoidea)

2

Erabaki-muga ezarri: $g(z) \geq 0.5 \rightarrow 1$ klasea; bestela 0 klasea

3

Kostu-funtzioa kalkulatu: entropia gurutzatua (log loss), funtzio konbexua

4

Gradiente jaitsierarekin w eta b optimizatu, aurretik datuak eskalatuta