

ADIMEN ARTIFIZIALA · IKASKUNTZA AUTOMATIKOA

K Auzokide Hurbilenak

(K-Nearest Neighbors — KNN)

Distantzian oinarritutako sailkapena eta erregresioa — diagramekin azalduta



Zer da K-NN Algoritmoa?

Definizioa

Ikaskuntza automatikoko algoritmo gainbegiratua da; puntu berri bat sailkatzeko edo balio bat aurreikusteko, datu-espazioko auzokide (neighbor) hurbilenetan oinarritzen da.



Sailkapena eta erregresioa

Bi ataza motatan erabil daiteke, ez sailkapenean bakarrik.



Eskalatzea beharrezkoa


Distantzian oinarritua denez, aldagaiak eskalatu behar dira.



Datu desorekatuekiko sentikorra

Klase nagusiaren alde okertzen da datu-multzo desorekatuetan.

BI KLASEEN SAKABANAKETA



Kontuan izan: Datu-multzo txikietarako oso egokia da, azaltzeko erraza da, eta oinarritzko eredu (baseline) gisa erabiltzen da.

K-NN Algoritmoaren Urratsak

1

K auzokideen kopurua aukeratu

2

Auzokide hurbilenen distantzia kalkulatu

3

Puntu hurbilenak zenbatu auzokide bakoitzeko


4

Puntu berria gehien errepikatzen den kategoriari esleitu (sailkapena)

!

Erregresioan: Aurreikusitako balioa K auzokide hurbilenen balioen batez bestekoa da.

ADIBIDEA: $K = 3$



2 gorri + 1 urdin hurbilen → Gizonezkoa esleitzen da

Osagai Nagusiak

K

K (hiperparametroa)

- Kontuan hartu beharreko auzokide kopurua.
- Aldez aurretik aukeratu behar da.
- K txikiak zarata handitzen du; K handiak muga leuntzen du.

d

Distantzia-metrika

- Euklidearra da ohikoena.
- Beste aukerak: Manhattan, Minkowski, kosinuantzekotasuna.

✓

Erabaki-araua

- **Sailkapena**

Gehiengoaren botoa (majority voting).

- **Erregresioa**

Batez bestekoa (averaging).

Ohiko Distantzia-Metrikak

E Euklidear distantzia

$$d(p, q) = \sqrt{\sum (p_i - q_i)^2}$$

Bi puntuen arteko lerro zuzenaren luzera.

M Manhattan distantzia

$$d(p, q) = \sum |p_i - q_i|$$


Koordenatuen arteko diferentzia absolutuen batura (hiri-blokeak).

Minkowski eta kosinua

Minkowski: Euklidear (r=2) eta Manhattan (r=1) orokortzen ditu.

Kosinu-antzekotasuna: testu eta dimentsio-anitzeko datuetan erabilia.

EUKLIDEARRA vs MANHATTAN — BIDE BERA, NEURKETA EZBERDINA




K-ren Balioaren Eragina Erabaki-mugan


Zergatik da garrantzitsua?

K-ren balioak eredia zenbat egokitzen den (edo gainegokitzen den) datuetara zehazten du: K txikiak zarata jasotzen dute, K handiek muga leundu eta klase nagusira okertzen dute.

K = 1 → muga irregularra (gainegokitzea)



K = 15 → muga leuna (orokortze hobe)



Oreka: K egokia balidazio-multzo baten bidez aukeratzen da, gutxiegotzea eta gainegokitzea saihesteko.

Abantailak eta Desabantailak



Abantailak

- **Ulertzeko eta inplementatzeko erraza**
- **Entrenamendu-fase gabea (lazy learner)**

Online ikaskuntzarako eraginkorra.

- **Klase anitzak ondo maneiatzen ditu**
- **Ez-parametrikoa**

Edozein banaketa motatako datuekin funtziona dezake.

- **Zarataren aurrean sendoa**

Dimentsio gutxiko datu-multzoetan bereziki.



Desabantailak

- **Konputazio-kostu handia probaketan**

Test-puntu bakoitzeko distantzia guztiak kalkulatu behar dira.

- **K eta distantzia-metrikaren aukeraketarekiko sentikorra**
- **Dimentsio altuko datuetan ez oso egokia**

Dimentsionaltasunaren madarikazioa: kostua igo eta errendimendua jaisten da.

Python Inplementazioa



Sailkapena (Classification)

```
from sklearn.neighbors import KNeighborsClassifier

neigh = KNeighborsClassifier(n_neighbors=3)
X = [[0], [1], [2], [3]]
y = [0, 0, 1, 1]
neigh.fit(X, y)

print(neigh.predict([[1.1]]))
print(neigh.predict_proba([[0.9]]))
```



Erregresioa (Regression)

```
from sklearn.neighbors import KNeighborsRegressor

neigh = KNeighborsRegressor(n_neighbors=2)
X = [[0], [1], [2], [3]]
y = [0, 0, 1, 1]
neigh.fit(X, y)

print(neigh.predict([[1.5]]))
```

LABURPENA

K-NN, urratsez urrats

1

K aukeratu eta distantzia-metrika bat hautatu (Euklidearra ohikoena)

2

Puntu berriaren eta datu guztien arteko distantzia kalkulatu

3

K auzokide hurbilenak identifikatu

4

Gehiengoaren botoa (sailkapena) edo batez bestekoa (erregresioa) aplikatu