


ADIMEN ARTIFIZIALA · IKASKUNTZA AUTOMATIKOA

Erabaki Zuhaitza

(Decision Tree)

Entropia, informazio-irabazia eta gini ezpurutasuna — diagramekin azalduta



Zer da Erabaki Zuhaitza?

Definizioa

Ikaskuntza automatikoko algoritmo gainbegiratuak da: datuak modu jerarkikoan zatitzen ditu, galdera sinpleen segida baten bidez, sailkapen edo erregresio bat lortu arte.



Sailkapena eta erregresioa

Bi ataza motatarako erabil daiteke.



Ez du eskalatzerik behar

Ez-parametrikoa da; jatorrizko eskalan lan egiten du.




Zuhaitz sakonak ezegonkorak

Kanpoko balioekiko sendoa da, baina zuhaitz sakonetan eragina izan dezakete.



Kontuan izan: Oso azkarra da, bisualiza daiteke, eta erraz azaltzen da jende teknikoa ez denari ere.

ZUHAITZAREN EGITURA



Entropia eta Informazio-irabazia

H

Entropia — ezpurutasuna neurtzen du

$$H(S) = -\sum p_i \log_2(p_i)$$

p_i : i klaseko instantzien proportzioa S datu-multzoan.


IG

Informazio-irabazia (Information Gain)

$$IG(S, A) = H(S) - \sum (|S_v|/|S|) \cdot H(S_v)$$

- Ezaugarri batek klaseari buruz zenbat informazio ematen digun neurtzen du.
- Informazio-irabazi handiena duen ezaugarria hautatzen da zatiketarako.

ENTROPIA (H) SAILKAPEN BITARREAN



Gini Ezpurutasuna eta Bariantza

G Gini ezpurutasuna

$$\text{Gini} = 1 - \sum p_i^2$$

Entropiaren antzekoa da, baina konputazio-denbora laburragoa behar du.


σ^2 Bariantza (Erregresioa)

Datuen barreiatzearen neurri estatistikoa.

Erregresio-arazoetan, entropia/gini ordeztu bariantzaren erabilten da zatiketa hautatzeko.

! **Praktikan:** Scikit-learn-en, Gini da CART algoritmoaren balio lehenetsia, azkarragoa delako.

ENTROPIA vs GINI — BIEK GORENA $p=0.5$ -EAN



Zuhaitzaren Ikaskuntza-prozesua

1

Adibide guztiekin hasi sustraiko nodoan

2

Ezaugarri bakoitzaren informazio-irabazia kalkulatu; onena hautatu

3

Datu-multzoa zatitu hautatutako ezaugarriaren arabera (adar ezkerra/eskuina)

4

Prozesua errepikatu geldialdi-irizpideak bete arte



Geldialdi-irizpideak

- Nodoa % 100 klase bakarrekoa denean
- Zatiketa berri batek gehieneko sakonera gaindituko lukeenean
- Zatiketa gehigarrien informazio-irabazia atalasetik behera dagoenean
- Nodo bateko adibide kopurua atalasetik behera dagoenean

Adibide Praktikoa: Sailkapena

Kontestua

Belarri-forma, aurpegi-forma eta bibotearen presentzia erabiliz, animalia bat katua den ala ez erabakitzeko zuhaitza eraikitzen da. Informazio-irabazi handiena duen ezaugarria (belarri-forma) hautatzen da sustraiko nodo gisa.

ERABAKI-ZUHAITZA: KATUA ALA EZ?



Belarri-forma zorrotza + aurpegi biribila → Katua | Belarri biribila + bibotea → Katua

Abantailak eta Desabantailak



Abantailak

- Sinpletasuna eta interpretagarritasuna
- Normalizazio beharrik ez
- Erlazio ez-linealak harrapatzeko gaitasuna
- Datu-garbiketa gutxiago behar du

Datu numeriko eta kategorikoak zuzenean maneiatzen ditu.

- Ezaugarri-hautaketa inplizitua
- Sailkapena eta erregresioa



Desabantailak

- Gainegokitzeko joera

Bereziki zuhaitz sakon eta konplexuetan.

- Datuen aldaketekiko sentikorra

Aldaketa txikiek egitura oso ezberdina sor dezakete (Random Forest edo Gradient Boosting-ek arintzen dute).

- Klase-desoreka arazoak
- Konputazio-konplexutasuna

Python Inplementazioa



Sailkapena (Iris)



```
from sklearn.datasets import load_iris
from sklearn.model_selection import cross_val_score
from sklearn.tree import DecisionTreeClassifier

clf = DecisionTreeClassifier(random_state=0)
iris = load_iris()
cross_val_score(clf, iris.data, iris.target, cv=10)
```



Erregresioa (Diabetes)



```
from sklearn.datasets import load_diabetes
from sklearn.model_selection import cross_val_score
from sklearn.tree import DecisionTreeRegressor

X, y = load_diabetes(return_X_y=True)
regressor = DecisionTreeRegressor(random_state=0)
cross_val_score(regressor, X, y, cv=10)
```

LABURPENA

Erabaki Zuhaitza, urratsez urrats

1

Ezpurutasuna neurtu: entropia edo Gini (saillapena), bariantza (erregresioa)

2

Ezaugarri bakoitzaren informazio-irabazia kalkulatu eta onena hautatu

3

Datu-multzoa adar ezker/eskuinetan zatitu, geldialdi-irizpideak bete arte

4

Zuhaitza ebaluatu: interpretagarria bai, baina gainegokitzeari kontuz erreparatu