


ADIMEN ARTIFIZIALA · IKASKUNTZA AUTOMATIKOA

Boosting

AdaBoost · Gradient Boosting · XGBoost

Ikasle ahulen segida bat eredu sendo bihurtzen — diagramekin azalduta




Zer da Boosting?

Definizioa


Ikasketa ensemble sekuentziala da: ikasle ahul (weak learner) bat baino gehiago segidan entrenatzen dira, bakoitzak aurrekoaren akatsak zuzentzeko helburuarekin, azkenean eredu sendo bat lortu arte.

BAGGING (PARALELOA)



Zuhaitz independenteak, aldi berean entrenatuak.

BOOSTING (SEKUENTZIALA)




Zuhaitzak elkarren segidan, aurrekoen akatsetatik ikasiz.



Ezaugarri komunak: Zuhaitzetan oinarritutako algoritmoetan, oro har, ez da eskalatzerik behar; sailkapenean eta erregresioan erabil daitezke.

Boosting Algoritmoen Familia



AdaBoost: Oinarrizko Kontzeptuak



Ikasle Ahula (Weak Learner)

Ausaz asmatzea baino apur bat hobeto egiten duen eredua; zurtoinak (stumps) erabili ohi dira.



Pisuak (Weights)


Lagin bakoitzari pisu bat esleitzen zaio; sailkapen okerrekin pisua handitzen dute.



Alpha (Amount of Say)

Ikasle bakoitzaren fidagarritasuna adierazten du azken botoan.

ZURTOINA (STUMP) — ADABOOST-EN OINARRIZKO ZUHAITZA



Node bat eta bi hosto besterik ez: "zurtoina" deitzen zaio.



Boosting: Segidan datorren zurtoin bakoitzak aurrekoak huts egindako laginetan jartzen du arreta.

AdaBoost: Nola Funtzionatzen Duen

1. Pisuak hasieratu ($w=1/N$)

2. Ikasle ahula entrenatu

3. Errorea kalkulatu


4. Alpha kalkulatu

5. Pisuak eguneratu

6. Ikasleak agregatu


OKER SAILKATUTAKO LAGINAK PISU HANDIAGOA HARTZEN DUTE

1. Zurtoina




gorria: oker sailkatua (pisua handitzen ari da)

2. Zurtoina



gorria: oker sailkatua (pisua handitzen ari da)

3. Zurtoina



gorria: oker sailkatua (pisua handitzen ari da)

Gradient Boosting: Nola Funtzionatzen Duen

1

Hasieratzea

Eredua balio konstante batekin hasten da (adib. batez bestekoa).

2

Hondakinak kalkulatu

Benetako balioaren eta uneko iragarpenaren arteko diferentzia.

3

Zuhaitz berria doitu

Zuhaitz berri bat hondakinak iragartzeko entrenatzen da, jatorrizko helburua ordez.

4

Eguneratu (ikasketa-tasarekin)

$F_m(x) = F_{m-1}(x) + v \cdot h_m(x)$, non v ikasketa-tasa den.

HONDAKINAK ITERAZIOZ ITERAZIO TXIKITZEN DIRA

1. iterazioa



2. iterazioa



3. iterazioa



berdea: benetako balioa | gorria: iragarpena (hurbiltzen doa)

XGBoost: Zer da?

Definizioa

Gradient Boosting-en bertsio azkar, eskalagarri eta erregularizatua da; hutsune-balioak berez kudeatzen ditu eta eskalatzerik behar ez duen zuhaitz-oinarriko algoritmoa da.



Azkartasuna

Paralelizazioa eta optimizazio hardwarea aprobetxatzen ditu.



Balio galduak

Berez maneiatzen ditu, inputaziorik gabe.



Antzekotasun-puntuazioa

Zatiketa bakoitzaren kalitatea neurtzeko formula berezia du.

Formula giltzarriak


$$\text{Antzekotasun-puntuazioa} = (\sum \text{hondakinak})^2 / (\sum [\text{aurreko probabilitatea} \cdot (1 - \text{aurreko probabilitatea})] + \lambda)$$

$$\text{Gain} = \text{ezkerreko } S + \text{eskuineko } S - \text{sustraiaren } S$$

Gain handiena duen atalasea hautatzen da zatiketa bakoitzean.

XGBoost: Gain eta Inaustea (Pruning)

ZATIKETAREN AUKERAKETA: GAIN HANDIENA IRABAZLE



Gain (Dosia<15) = 1.33 ← beste atalaseek (Dosia<5, Dosia<10...) irabazi txikiagoa dute
Zenbat eta Gain handiagoa, orduan eta hobeto banatzen ditu hondakinak talde antzekoetan.



Inaustea (Pruning)

γ (gamma) balio bat finkatzen da; adar bakoitzeko (Gain – γ) kalkulatu da. Emaiz negatiboa bada, adarra kentzen da; positiboa bada, mantendu egiten da. Horrek gehiegizko doikuntza saihesten laguntzen du.

Hiru Algoritmoen Konparaketa

Ezaugarria	AdaBoost	Gradient Boosting	XGBoost
Zuzentzeko mekanismoa	Lagin-pisuak	Hondakinak (gradienteak)	Hondakinak + erregularizazioa
Oinarrizko ikaslea	Zurtoinak (stumps)	Erabaki-zuhaitzak	Erabaki-zuhaitzak optimizatuak
Abiadura	Azkarra	Motelagoa entrenatzeko	Oso azkarra (paralelizatua)
Balio galduak	Ez ditu kudeatzen	Ez ditu berez kudeatzen	Berez kudeatzen ditu
Kanpoko balioekiko	Sentikorra	Ez oso sentikorra	Ez oso sentikorra

Abantailak eta Desabantailak



Abantailak

- **Doitasun handia**

Zuhaitz bakar edo bagging ereduak baino errendimendu hobea lortzen dute askotan.

- **Datu heterogeneoak maneiatzen ditu**
- **Ezaugarrien garrantziari buruzko informazioa**
- **Kanpoko balioekiko sendoa (GB/XGBoost)**
- **Datu desorekatuekin ondo funtzionatzen du**



Desabantailak

- **Konputazio-kostu handia**

Entrenamendu sekuentziala denez, ezin da erraz paralelizatu (AdaBoost/GB).

- **Parametroen doikuntza zaila**
- **Zarataekiko sentikorra**

Datu zaratatsuetan gainegoki dezake.

- **Interpretagarritasun mugatua**

Python Inplementazioa I



AdaBoost (Sailkapena)



```
from sklearn.ensemble import AdaBoostClassifier
from sklearn.tree import DecisionTreeClassifier
from sklearn.datasets import make_classification
from sklearn.model_selection import train_test_split

X, y = make_classification(n_samples=1000, n_features=20,
                          random_state=42)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42)

weak = DecisionTreeClassifier(max_depth=1)
ada = AdaBoostClassifier(estimator=weak,
                        n_estimators=50, random_state=42)
ada.fit(X_train, y_train)
```



Gradient Boosting (Erregresioa)



```
from sklearn.datasets import make_regression
from sklearn.ensemble import GradientBoostingRegressor
from sklearn.model_selection import train_test_split

X, y = make_regression(random_state=0)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, random_state=0)

reg = GradientBoostingRegressor(random_state=0)
reg.fit(X_train, y_train)
reg.score(X_test, y_test)
```

Python Inplementazioa II — XGBoost



XGBoost (Sailkapena)

```
import xgboost as xgb
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score

iris = load_iris()
X, y = iris.data, iris.target
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42)

model = xgb.XGBClassifier()
model.fit(X_train, y_train)
y_pred = model.predict(X_test)
accuracy_score(y_test, y_pred)
```



XGBoost (Erregresioa)

```
from sklearn.datasets import load_diabetes
from sklearn.metrics import mean_absolute_error
import xgboost as xgb

X, y = load_diabetes(return_X_y=True)
reg = xgb.XGBRegressor(
    tree_method="hist",
    eval_metric=mean_absolute_error,
)
reg.fit(X, y, eval_set=[(X, y)])
```

Boosting, urratsez urrats

1

AdaBoost: lagin-pisuak moldatzen ditu, oker sailkatutakoei arreta handiagoa emanez

2

Gradient Boosting: zuhaitz berri bakoitzak aurreko hondakinak (erroreak) iragartzen ditu

3

XGBoost: Gradient Boosting azkar eta erregularizatua, gain eta inautrea erabiliz

4

Hirurek eredu ahulak segidan konbinatzen dituzte eredu sendo bat sortzeko