

2. ATALA

Ikasketa Gainbegiratua

EGILEA

ZENTROA

EDIZIOA

IKASTAROA

Laneki — FP Euskadi

v1.0

2026 — 2027

Ikasketa Gainbegiratua (Supervised Learning)

Ikasketa gainbegiratua (supervised learning) ikasketa automatikoaren eredu-multzo nagusietako bat da, non datu bakoitzari bere helburu-balioa (etiketa) emanda entrenatzen den. Ereduan erabiltzen den datu-multzoa bi osagaitan banatzen da:

- **Ezaugarriak (features):** X — sarrera-aldagaiak
- **Etiketak (labels):** Y — aurreikusi nahi den aldagaia

Eredu gainbegiratuaren helburua da funtzio bat aurkitzea:

$$\hat{Y} = f(X)$$

Non funtzio honek sarrera-ezaugarriekin erlazio eredu sortzen duen helburu-balioarekin.

Bi eremu nagusi:

- **Erregresioa:** Helburu-aldagai **jarraitua** (etxe-prezioa, tenperatura, irabaziak).
- **Sailkapena:** Helburu-aldagai **diskretua/kategorikoa** (gaixo/osasuntsu, spam/ez-spam).

02.1 Errore-funtzioa: Batezbesteko Errore Karratua (MSE)

Ikasketa gainbegiratuan erabiltzen den errore-funtzio nagusia **Batezbesteko Errore Karratua (Mean Squared Error – MSE)** da:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Erroreak karratu egiteak bi helburu nagusi ditu:

1. **Deuseztapena saihestea:** Errore positibo eta negatiboak elkarrekin ez deuseztatzea bermatzen du. Errore guztiek balio positiboa ekartzen diote baturari.
2. **Errore handiak penalizatzea:** Errore handiei pisu handiagoa ematen zaie. Ereduak errore handiak minimizatzen jotzen du, outlierrekiko sentikorra bihurtuz.

MSEren erabilerak:

- **Optimizazio-funtzioa:** Gradientearen Jaitsiera bezalako algoritmoek MSE erabiltzen dute parametro optimoak iteratiboki aurkitzeko.
- **Ereduen arteko konparaketa:** MSE baxuena duen ereduak datuetara hurbilketa onena lortu du.

02.2 Erregresio Lineala

Erregresioa da ikasketa gainbegiratuaren artean eredu-mota ezagunenetako bat. Aldagai jarraitu baten balioa aurreikusten du beste aldagai batzuen arabera.

ERREGRESIO LINEAL SINPLEA

$$\hat{y} = \beta_0 + \beta_1 x$$

Non:

- β_0 (moztunea): $X = 0$ denean Y -k duen balio estimatua.
- β_1 (malda): X unitate bat handitzean Y -n espero den batezbesteko aldaketa.

ERREGRESIO ANIZKOITZA (MULTIPLE REGRESSION)

Helburu-aldagaia (Y) azaltzeko aldagai bat baino gehiago erabiltzen da:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$$

Ereduaren helburua $\beta_0, \beta_1, \dots, \beta_p$ parametroen balio optimoak aurkitzea da, MSE minimizatuz.

ERREGULARIZAZIOA: PARAMETROEN KONTROLA

Aldagai gehiegi ditugunean, ereduak β parametroei balio altuegiak eman diezazkieke datu-multzo espezifiko batera behartuta egokitzeko $\rightarrow$ **gaindoiketa (overfitting)**. Erregularizazioak zigor-termo bat gehitzen dio MSERI, β koefizienteak txikiagoak izatea bultzatuz.

Ridge Erregresioa (L_2)

Parametroen karratuen batura zigortzen du:

$$\text{Kostua}_{\text{Ridge}} = \text{MSE} + \lambda \sum_{j=1}^p \beta_j^2$$

$\lambda > 0$ parametroak erregularizazioaren indarra kontrolatzen du. Ridge-k inoiz ez ditu koefizienteak guztiz zero bihurtzen — aldagai guztiak eredian mantentzen dira, baina haien pisua mugatua da.

Lasso Erregresioa (L_1)

Parametroen balio absolutuaren batura zigortzen du:

$$\text{Kostua}_{\text{Lasso}} = \text{MSE} + \lambda \sum_{j=1}^p |\beta_j|$$

Lassok efektu berezia du: **garrantzirik ez duten koefizienteak guztiz zero bihurtzen ditu**, beraz automatikoki aldagaien hautaketa egiten du. Eredua sinpleagoa eta interpretatzeko errazagoa bilakatzen da.

	Ridge (L_2)	Lasso (L_1)
Zigorra	$\lambda \sum \beta_j^2$	$\lambda \sum \beta_j $
Koefizienteak	o-rantz hurbiltzen ditu	Batzuk guztiz o bihurtzen ditu
Aldagaien hautaketa	Ez (denak mantentzen)	Bai (automatikoa)

Egokia	Aldagai asko, denak garrantzitsuak	Aldagai asko, gutxi batzuk garrantzitsuak
--------	------------------------------------	---

02.3 Erregresio Logistikoa (Logistic Regression)

Erregresio logistikoa **sailkapeneko oinarritzko eredu lineala** da — izena nahasgarria den arren, ez du irteera jarraitua iragarriko, **klase bateko kide izateko probabilitatea** baizik. Bi klase dituzten arazoetan (sailkapen binarioa) erabiltzen da nagusiki: spam/ez-spam, gaixo/osasuntsu, iruzur/normal.


LOGIT FUNTZIOA ETA SIGMOID TRANSFORMAZIOA

Erregresio linealak $\hat{y} = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$ eman dezake edozein balio, $(-\infty, +\infty)$ tartean. Probabilitate bat lortzeko, ordea, $[0,1]$ tartean egon behar du. Horretarako **sigmoid funtzioa** erabiltzen da:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Non $z = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$ den konbinazio linealaren balioa. Funtzio honek edozein sarrera $[0,1]$ tarteko probabilitate bihurtzen du:

$$\hat{P}(Y = 1 | X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p)}}$$



Erregresio lineala vs erregresio logistikoa: sigmoid transformazioa eta erabaki-muga

ERABAKI-ARAU

Probabilitate-atalase bat ezarrita (normalean 0.5), sailkapena egiten da:

$$\hat{y} = \begin{cases} 1 & \text{if } \hat{P}(Y = 1) \geq 0.5 \\ 0 & \text{if } \hat{P}(Y = 1) < 0.5 \end{cases}$$

Atalasea aldatu daiteke arazoaren arabera: detekzio medikoan FN-ak gutxitzeko 0.3era jaitsi daiteke, adibidez.

KOSTUA: LOG-LOSS (BINARY CROSS-ENTROPY)

MSE ez da egokia probabilitateentzat. Erregresio logistikoak **log-loss** erabiltzen du optimizazio-funtzio gisa:

$$\mathcal{L} = -\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)]$$

- $y_i = 1$ eta $\hat{p}_i \approx 1$ denean $\rightarrow$ galera txikia ☒
- $y_i = 1$ eta $\hat{p}_i \approx 0$ denean $\rightarrow$ galera handia ☒

ERREGULARIZAZIOA

Ridge eta Lassoren antzera, erregresio logistikoak ere erregularizazioa onartzen du gaindoiketa saihesteko. **sklearn**-en **C** parametroak erregularizazioaren alderantzizkoa kontrolatzen du: **C txikia** $\rightarrow$ **erregularizazio handia**.

	Ridge (L2)	Lasso (L1)
Kostu funtzioa	$\mathcal{L} + \lambda \sum \beta_j^2$	$\mathcal{L} + \lambda \sum \beta_i $
sklearn	<code>LogisticRegression(penalty='l2')</code>	<code>LogisticRegression(penalty='l1')</code>

ERREGRESIO LINEALA VS ERREGRESIO LOGISTIKOA


Ezaugarria	Erregresio Lineala	Erregresio Logistikoa
Irteera	Balio jarraitua ($\mathbb{R}$)	Probabilitatea $[0,1]$
Erabilera	Erregresioa	Sailkapena
Funtzio aktibatzailea	Identitate funtzioa	Sigmoid funtzioa
Kostua	MSE	Log-Loss
Muga-forma	—	Hiperplano lineal bat

Oharra: Erregresio logistikoa **muga lineal** bat sortzen du espazio geometrikoan — SVMren antzera, baina probabilitate-interpretazioa gehituz. Ez-linealtasunerako, kernel trikimailua edo beste algoritmo batzuk behar dira.

02.4 KNN (K-Nearest Neighbors)

KNN edo K-Auzokide Hurbilenen metodoa **sailkapen-algoritmo simple eta eraginkorra** bat da. Eredu **ez-parametrikoa** da: ez du datuen banaketari buruzko alde aurreko suposiziorik egiten eta ez du parametro finkorik estimatzen entrenamendu-fasean.

Ikasketa alferra (lazy learning): Ez du eredu espliziturik eraikitzen entrenamendu-fasean; instantzia guztiak memorizatzen ditu eta kalkuluak iragarpen-unean egiten ditu.



KNN algoritmoa: K=3 adibidea eta sailkapen-mugak

ALGORITMOAREN FUNTZIONAMENDUA

Sarrera-puntu berri bat (x_q) sailkatzeko:

1. **Distantzien kalkulua:** x_q -ren eta entrenamendu-multzoko puntu guztien arteko distantzia kalkulatu.
2. **Ordenatzea eta hautaketa:** Distantziak txikienetik handienera ordenatu $\rightarrow k$ auzokide hurbilenak hautatu.
3. **Gehiengo-bozketa:** Hautatutako k auzokideen etiketak kontatu $\rightarrow$ gehien errepikatzen den etiketa (moda) esleitu.

Adibidea: $k=3$, auzokideak: $\{1. klasea, 1. klasea, 2. klasea\} \rightarrow 1. klasea$ esleituko da (gehiengo-bozketa).

Oharra: KNNk **erregresioan** ere funtzionatzen du. Kasu horretan, gehiengo-bozketa erabili beharrean, k auzokideen **batezbestekoa** kalkulatzen da iragarpen gisa: $\hat{y} =$

$$\frac{1}{k} \sum_{j \in N_k} y_j$$

DISTANTZIA-METRIKAK

$$\text{Euklidearra: } d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

$$\text{Manhattan: } d(x, y) = \sum_{i=1}^n |x_i - y_i|$$

K PARAMETROAREN HAUTAKETA


k balioa	Portaera	Arriskua
Txikia (1–3)	Sailkapen-muga oso irregularrak	Gaindoiketa — zaratarekiko sentikorra
Handia (≥ 11)	Sailkapen-muga leunagoak	Azpidoiketa — xehetasunak galdu

Kontuz: KNN distantziatan oinarritzen denez, **ezinbestekoa da datuak eskalatzea** (StandardScaler edo MinMaxScaler). Magnitude handieneko aldagaiak gainerakoen gainetik gailentzen dira bestela.

02.5 Erabaki-Zuhaitzak (Decision Trees)

Erabaki-zuhaitzak "**kutxa gardeneko**" (white box) eredutzat hartzen dira — iragarpen bat egiteko jarraitutako logika osoa modu grafikoan ikus daiteke. Datu-multzoa azpitalde txikiagoetan banatzen du, ezaugarri bakoitzaren balioak aztertuz, hostoetara (emaitzetara) iritsi arte.

Erabaki Zuhaitza: Kreditu-arriskua



Erabaki-zuhaitz baten egitura: erro-nodoa, barne-nodoak, hosto-nodoak

ZUHAITZAREN EGITURA

Elementua	Deskribapena
Erro-nodoa (Root)	Hasierako puntua; datu-multzo osoa hartzen du eta lehen banaketa egiten du
Barne-nodoak	Erabaki-puntuak: "Adina > 30?" bezalako galderak
Adarrak	Nodo batetik besterako bidea, erabakiaren emaitza irudikatuz
Hosto-nodoak	Amaierako puntuak; amaierako iragarpena ematen da hemen

BANAKETA-IRIZPIDEAK: ENTROPIA ETA INFORMAZIO-IRABAZIA

Entropia sistema baten ziurgabetasuna neurtzen du. Talde batean klase asko nahastuta badaude, entropia altua; talde purua bada, zero:

$$H(S) = - \sum_{i=1}^c p_i \log_2(p_i)$$

Adibidea: Bi klase berdin proportzioan ($p_1 = p_2 = 0.5$) $\rightarrow H = -(0.5 \log_2 0.5 + 0.5 \log_2 0.5) = 1$ bit (nahasmen maximoa). Klase bakarra ($p_1 = 1$) $\rightarrow H = 0$ (ziurtasun osoa).

Informazio-Irabazia (Information Gain) zatiketa egin aurreko eta ondorengo entropiaren arteko aldea:

$$IG(S, A) = H(S) - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} \cdot H(S_v)$$

Algoritmoak **informazio-irabazi handiena** ematen duen atributua hautatzen du nodo bakoitzean.

GINI INDIZEA

Nodo bateko elementu bat ausaz hartuta gaizki sailkatua izateko probabilitatea:

$$Gini = 1 - \sum_{j=1}^c p_j^2$$

- $Gini = 0 \rightarrow$ Nodoa guztiz purua.
- Konputazionalki azkarragoa da (ez du logaritmoa kalkulatu behar) $\rightarrow$ datu-multzo handietan lehenesten da.

ID3 vs CART: ID3 algoritmoak **Informazio-Irabazia** (Entropia) erabiltzen du; **CART** algoritmoak (scikit-learn-ek inplementatzen duena) **Gini Indizea** erabiltzen du lehenespenez moduan.

GAINDOIKETA ETA INAUSKETA (PRUNING)

Zuhaitza mugarik gabe hazten bada, entrenamendu-datuetakoz zarata eta xehetasun hutsalak ere "ikasiko" ditu → datu berriekin huts egingo du.

Estrategia	Deskribapena
Pre-pruning	Zuhaitza eraikitzen ari den bitartean gelditzea: gehienezko sakonera, gutxienezko lagin kopurua...
Post-pruning	Zuhaitza guztiz hazi ondoren, garrantzi estatistikorik ez duten adarrak kentzea

Abantailak:

- Ez du eskalatzerik behar (banaketak balio indibidualetan oinarritzen dira).
- Datu mistoak (numerikoak eta kategorikoak) onartzen ditu.
- Ez-linealtasuna: erlazio konplexuak identifikatzen ditu.


Desabantailak:

- Ezegonkortasuna: Datu-aldaketa txiki batek zuhaitzaren egitura guztiz aldatu dezake.
- Poda gabe, gaindoiketa oso erraza da.

02.6 SVM (Support Vector Machines)

Support Vector Machines edo **Euskarri-Bektoreen Makinak** ikasketa gainbegiratu algoritmo indartsuak dira, nagusiki sailkapen-lanetan erabiltzen direnak. Haien oinarritzko printzipioa: **klaseak bereizten dituen muga optimoa (hiperplanoa) bilatzea**, marjina maximizatuz.

SVM: Marjina Maximoaren Hiperplanoa



SVM: Hiperplanoa, marjina eta euskarri-bektoreak

HIPERPLANOA

SVMren helburua datuen espazioan klaseak banatzen dituen **hiperplano optimoa** aurkitzea da:

$$\mathbf{w} \cdot \mathbf{x} + b = 0$$

Non:

- **w**: Bektore normala (hiperplanoaren orientazioa definitzen du).
- **b**: Desplazamendua / bias terminoa (jatorriarekiko posizioa definitzen du).

MARJINAK ETA EUSKARRI-BEKTOREAK

- **Marjina**: Hiperplanoa eta klase bakoitzeko puntu hurbilenen arteko distantzia perpendikulara. Marjinaren zabalera:

$$\text{Marjina} = \frac{2}{\|\mathbf{w}\|}$$

Marjina maximizatzeko $\rightarrow \|\mathbf{w}\|$ minimizatu behar da.

- **Euskarri-Bektoreak**: Marjinaren mugan bertan kokatzen diren datu-puntuak. **Puntu kritikoenak** dira: beraiek hiperplanoaren posizioa eta orientazioa definitzen dute. Marjinatik urrun dauden puntuak ez dute eraginik ereduaren eraikuntzan.

Soft Margin (Marjina Biguna)

Datuak partzialki gainjarrita badaude, **slack variables** (ξ_i) sartzen dira, puntu batzuk marjinaren barruan edo alde okerrean egotea onartuz. C parametroak erregulatzen du tolerantzia.

Kernel Trikimailua ("Kernel Trick")

Datuak ez-linealak direnean, SVM-k kernel-funtzioak erabiltzen ditu datuak jatorrizko espaziotik **dimentsio handiagoko espazio batera** inplizituki proiektatzeko. Espazio berri horretan datuak linealki banagarriak dira.

Kernel	Formula	Erabilera
Lineala	$K(x, y) = x \cdot y$	Datu linealki banagarriak
Polinomiala	$K(x, y) = (x \cdot y + c)^d$	Kurba-mugak
RBF (Gaussiarra)	$K(x, y) = e^{-\gamma \ x - y\ ^2}$	Muga ez-lineal konplexuak

Abantailak: Orokortze-gaitasun bikaina, oso eraginkorra dimentsio handiko espazioetan, soluzioa bakarra (optimizazio konbexoa).

Desabantailak: Konputazio-kostu handia datu-multzo oso handiekin; interpretagarritasun baxua (kernel konplexuak erabiltzean).

02.7 Ensemble Metodoak: Random Forest eta Boosting

Ensemble metodoek banakako ikasketa-ereduen mugak gainditzen dituzte, hainbat **"eredu ahul" konbinatuz "eredu sendo" bakarra** osatzeko. Oinarrian dago: banakako zuhaitz batek overfitting-erako joera arren, ensemble metodoek errore horiek orekatzen dituzte.

"Taldearen Adimena" (Wisdom of the Crowd): Banakako eredu baten akatsa taldearen iragarpen bateratuarekin zuzentzen da.

RANDOM FOREST

Random Forest-ek **Bagging (Bootstrap Aggregating)** teknika erabiltzen du. Bi ausazkotasun-maila aplikatzen ditu:

1. Datu-multzoaren **lagin desberdinak** hartzen ditu zuhaitz bakoitzarentzat (bootstrap lagin).
2. Nodo bakoitzean **aldagai-multzo mugatu** bat baino ez du aztertzen zatiketa egiteko.

Horri esker, **zuhaitzen arteko korrelazioa apurtzen da**: zuhaitz bakoitzak datuen "ikuspegi" desberdin bat ikasten du. Guztien arteko batezbestekoa (edo bozketa) egitean, banakako erroreak diluitzen dira.

Ezaugarriak:

- Oso sendoa outlierren aurrean.
- Orokortze-maila handia; gaindoiketa saihesten du.
- Ez du eskalatzerik behar.
- Aldagaien garrantzia (feature importance) kalkulatu du.
- Sailkapenean: `RandomForestClassifier`; erregresioan: `RandomForestRegressor`.

BOOSTING

Boosting metodoek **ikuspegi gehitzailea (additive)** jarraitzen dute: ereduak sekuentzialki eraikitzen dira, zuhaitz berri bakoitzak **aurrekoek egindako akatsetan zentratuz**.

Iterazio bakoitzean, algoritmoak gaizki iragarritako datu-puntuen pisuak handitzen ditu, hurrengo ereduak puntu "zail" horiek hobeto prozesatu ditzan.

	Random Forest	Boosting
Zuhaitzak	Paraleloan eraikitzen dira	Sekuentzialki eraikitzen dira
Helburua	Bariantza murriztu (overfitting saihestea)	Alborapena (bias) murriztu
Datu-laginketa	Bootstrap (ausazkoa)	Akatsen arabera (pisuak)
Hiperparametroak	Errazago doitu	Zainduagoa eskatzen du
Liburutegiak	<code>sklearn.ensemble.RandomForestClassifier</code>	XGBoost, LightGBM, CatBoost

Industria-estandarra: Ensemble metodoak dira datu tabularren analisisan zehaztasun handiena lortzen dutenak. "Kaggle" bezalako mundu mailako txapelketetan garaipen gehienak XGBoost, LightGBM eta CatBoost bidez lortzen dira.

Aplikazio-sektoreak:

- **Sektore finantzarioa:** Iruzurra detektatzeko eta kreditu-kalifikazioak.
- **Medikuntza:** Diagnostiko-ereduak.
- **Industria:** Mantenimendu prediktiboa.