

Ikasketa

Gainbegiratua

Erregresio lineala eta logistikoa, KNN, erabaki-zuhaitzak,
SVM eta ensemble metodoak.

Zikloa Goi-mailako zikloa · Adimen Artifiziala eta Big Data

Ikasturtea 2025 / 2026



Saio honetan ikusiko duguna

01 Ikasketa gainbegiratua: sarrera eta kontzeptuak

02 Errore-funtzioa: MSE

03 Erregresio Lineala eta Erregularizazioa

04 Erregresio Logistikoa

05 KNN (K-Auzokide Hurbilenak)

06 Erabaki-Zuhaitzak

07 SVM (Euskarri-Bektoreen Makinak)

08 Ensemble Metodoak: Random Forest eta Boosting

Zer da ikasketa gainbegiratua?

Datu bakoitzak bere **etiketa** (erantzun zuzena) darama entrenamenduan.

Helburua — Funtzio bat garatu: $\hat{y} = f(X) \rightarrow$ sarreratik irteera aurreikusi.

Erregresioa — Irteera jarraitua iragarri: etxe-prezioa, tenperatura, salmentak.

Sailkapena — Irteera kategorikoa iragarri: spam/ez-spam, gaixo/osasuntsu, iruzurra.

Analogia — Irakasle baten modura: ereduak adibide etiketatuekin ikasten du.

Etiketak — Entrenamendurako **ezinbestekoak**, baina eskuratzea garestia da.

Gmail spam detekzioa — Milioika mezu eskuz etiketatu behar dira hasieran.

Medikuntza — Radiologoek irudi bakoitza eskuz sailkatu behar dute.

Gakoa — Etiketa gehiago = eredu hobe, baina denbora eta kostua gehiago ere bai.

Ez-gainbegiratua (5072_4) — Etiketarik gabe lan egiten duten algoritmoak.

Erregresioa vs Sailkapena: alderaketa praktikoa


EZAUGARRIA	ERREGRESIOA	SAILKAPENA
Irteera	Balio jarraitua (€, °C, kg...)	Kategoria (0/1, A/B/C...)
Adibidea	Etxe-prezioa, salmentak, temperatura	Spam, gaixotasuna, iruzurra
Errore-neurria	MSE, RMSE, MAE, R²	Accuracy, F1, ROC-AUC
Algoritmo tipikoa	Erregresio lineala, Random Forest	KNN, SVM, Decision Tree, Erregresio logistikoa
Galdera mota	'Zenbat?' — balio zehatz bat	'Zein?' — klase bat

MSE: zergatik erabiltzen dugu errore-funtzio gisa?

- **MSE = $(1/n) \cdot \Sigma(y_i - \hat{y}_i)^2$** — Errore guztien karratuen batezbestekoa
- **Zergatik karratu?** — Errore positibo eta negatiboak elkar ez deuseztatzeko
- **Errore handiak penalizatu** — 10€-ko akatsak 100 puntu ekartzen du; 1€-koak 1 soilik
- **Optimizazio-funtzioa** — Gradientearen Jaitsiera bezalako algoritmoek MSE minimizatzen dute iteratiboki
- **Konparaketa** — MSE baxuena duen ereduak datuetara hurbilketa onena lortu du
- **RMSE** — MSEren erro karratua: jatorrizko unitate beretan (€, °C...) interpretatzen errazagoa

Erregresio lineala: sinpletik anizkoitzera


- **Sinplea** — $\hat{y} = \beta_0 + \beta_1 x$ · Aldagai prediktore bakarra
- **Anizkoitza** — $\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$ ·
Aldagai prediktore asko
- **β_0 (moztunea)** — $X=0$ denean Y -k duen balio estimatua
- **$\beta_1 \dots \beta_p$ (maldak)** — Aldagai bakoitzak Y -n duen eragin estimatua, besteak konstanteki
- **OLS helburua** — β parametroak aurkitu MSE minimizatuz



Ridge vs Lasso: gaindoiketa kontrolatzeko erregularizazioa

	RIDGE (L2)	LASSO (L1)
Kostu funtzioa	$MSE + \lambda \cdot \sum \beta_j^2$ (karratuak)	$MSE + \lambda \cdot \sum \beta_j $ (balio absolutuak)
Koefizienteak	0-rantz hurbiltzen ditu, baina inoiz ez 0	Batzuk guztiz 0 bihurtzen ditu
Aldagaien hautaketa	Ez — aldagai guztiak mantentzen ditu	Bai — automatikoki garrantzirik gabekoek 0
λ parametroa	$\lambda=0 \rightarrow$ erregularizaziorik ez · λ handia $\rightarrow \beta$ txikiak	Berdin — λ handiak aldagai gehiago 0 bihurtu
Egokia	Aldagai asko, denak garrantzitsuak	Aldagai asko, gutxi batzuk garrantzitsuak
Adibidea	Genomika (milaka gene aktibo)	Irudi-prozesatzea (pixel hautaketa)

Erregresio Logistikoa: sigmoid funtzioa eta probabilitatea




- **Arazoa** — Erregresio linealak edozein balio eman dezake; probabilitateak $[0,1]$ tartean egon behar
- **Sigmoid** — $\sigma(z) = 1 / (1 + e^{-z}) \rightarrow$ edozein sarrera $[0,1]$ tarteko probabilitate bihurtu
- $P(Y=1|X) = \sigma(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p) \rightarrow$ klase positiboko kide izateko probabilitatea
- **Erabaki-araua** — $P \geq 0.5 \rightarrow$ Klase 1 · $P < 0.5 \rightarrow$ Klase 0 (atalasea aldatu daiteke)
- **Log-Loss** — MSE ez da egokia probabilitateentzat; log-loss erabiltzen da optimizaziorako
- **Muga lineala** — Hiperplano lineal bat sortzen du; SVMren antzekoa baina probabilitate-interpretazioarekin

— K-NEAREST NEIGHBORS

KNN: puntu berriak auzokideen arabera sailkatu

- **Ez-parametrikoa** — Ez du aldez aurretik datuen banaketari buruzko suposiziorik egiten
- **Ikasketa alferra** — Entrenamendurik ez; guztia iragarpen-unean kalkulatzen da
- **1. urratsa** — Distantzia kalkulatu puntu berriaren eta entrenamendu-puntu guztien artean
- **2. urratsa** — k auzokide hurbilenak hautatu distantziaren arabera
- **3. urratsa** — Gehiengo-bozketa: klase nagusiena esleitu (sailkapena) edo batezbestekoa (erregresioa)
- **Arau garrantzitsua** — **Beti eskalatu datuak** KNN aurretik: magnitude handieneko aldagaiak nagusitzen dira bestela




k parametroa: nola aukeratu eta zergatik du eragina

K BALIOA	PORTAERA	ARRISKUA	NOIZ ERABILI
k=1	Puntu hurbilena soilik erabiltzen da	Gaindoiketa larria — zaratarekiko oso sentikorra	Inoiz ez (salbuespen gutxi)
k=3–5	Sailkapen-muga irregularrak, malgutasun handia	Gaindoiketa ertaina	Datu asko eta garbi daudenean
k=11–15	Sailkapen-muga leunagoak	Azpidoiketa: xehetasun garrantzitsuak galdu	Datu zaratatsuak edo gutxi daudenean
k bikoitia	Berdinketa posiblea bi klasetan	Erabaki-arazoa — ez dago gehiengorik	Saihestu beti bi klaseko sailkapenean
k = $\sqrt{n}$	Hasierako estimazio praktikoa	Beti egiaztatu cross-validation bidez	Lehen proba gisa

— DECISION TREES — KUTXA ZURIKO EREDUA

Erabaki-zuhaitza: galdera baten ondoren galdera

Erabaki Zuhaitza: Kreditu-arriskua



- **Erro-nodoa** — Datu guztiekin hasten da; informazio-irabazi handiena duen banaketa aukeratzen du
- **Barne-nodoak** — Erabaki-puntuak: 'Adina > 30?', 'Soldata > 25.000€?', 'Kreditu-historia > 3 urte?'
- **Hosto-nodoak** — Amaierako iragarpena: 'Mailegua onartu' / 'Ukatu'
- **Abantaila nagusia** — ****Kutxa zuriko**** eredua: erabaki bakoitza azal daiteke (GDPR, medikuntza)
- **Ez du eskalatzerik behar** — Banaketak balio indibidualetan oinarritzen dira, ez distantzietan
- **Arriskua nagusia** — Poda gabe, entrenamendu-datuen zarata memoriza dezake → gaindoiketa


Entropia, Informazio-Irabazia eta Gini: banaketa-irizpideak

- **Entropia** — $H(S) = -\sum p_i \cdot \log_2(p_i)$ · Talde baten ziurgabetasuna neurtzen du
- $H=0 \rightarrow$ Talde purua (klase bakarra) · $H=1 \rightarrow$ Nahasmen maximoa (50%/50%)
- **Informazio-Irabazia** — $IG = H(S) - \sum (|S_v|/|S|) \cdot H(S_v)$ · Banaketa egin aurreko eta ondorengo entropiaren aldea
- **Algoritmoak** — IG handiena duen atributua hautatzen du nodo bakoitzean
- **Gini Indizea** — $Gini = 1 - \sum p_j^2$ · Konputazionalki azkarragoa (logaritmorik gabe)
- **ID3 vs CART** — ID3 algoritmoak Entropia; sklearn-eko CART algoritmoak Gini lehenespen moduan

SVM: marjina maximoa duen muga bilatu

- **Hiperplanoa** — $w \cdot x + b = 0$ · Klaseak banatzen dituen muga optimoa espazio n-dimentsionalean
- **Marjina** — $2/||w||$ · Hiperplanoaren eta puntu hurbilenen arteko distantzia; maximizatu behar
- **Euskarri-bektoreak** — Marjinaren mugan dauden puntu kritikoak soilik; beste guztiek ez dute eraginik
- **Soft Margin (C)** — C handiak: marjina txikiagoa, akats gutxiago
· C txikiak: marjina handia, akats gehiago onartzen
- **Kernel trikimailua** — Ez-lineal datuak dimentsio altuagoko espazio batera proiektatu, bertan linealki banatzeko
- **Abantaila** — Orokortze-gaitasun bikaina; dimentsio handiko espazioetan oso eraginkorra

SVM: Marjina Maximoaren Hiperplanoa



Kernel funtzioak: zein eta noiz erabili

KERNEL	FORMULA	ERABILERA	KONTUA
Lineala	$K(x,y) = x \cdot y$	Datu linealki banagarriak	Azkarrena eta sinpleena; hemen hasi beti
Polinomiala	$K(x,y) = (x \cdot y + c)^d$	Kurba-mugak behar direnean	d handiek gaindoiketa eragin dezakete
RBF/Gauss	$K(x,y) = e^{-\gamma x-y ^2}$	Muga konplexuak — erabiliena	γ handiek gaindoiketa; txikiek azpidoiketa

Ensemble metodoak: eredu ahul asko → eredu sendo bat

'**Talde ezagutza**' printzipioa — Banakako akatsak taldean diluitzen dira.

Random Forest — Ehunka zuhaitz paraleloan entrenatu, gehiengo-bozketa bidez erabaki.

Bagging — Bootstrap: zuhaitz bakoitzak datu-lagin desberdin bat jasotzen du ausaz.

Zuhaitzen arteko korrelazioa apurtu — Nodo bakoitzean aldagai-multzo mugatu bat soilik aztertu.

Emitza — Banakako zuhaitz batek overfitting-a duen bitartean, ensembleak errore horiek orekatzen ditu.

Boosting — Zuhaitzak sekuentzialki eraiki; bakoitzak aurreko akatsetan zentratzen da.

Iterazio bakoitzean — Gaizki iragarritako puntuen pisuak handitu, hurrengo ereduak hobe dezan.

XGBoost, LightGBM, CatBoost — Industriako estandarrak datu tabularretan.

Kaggle txapelketetan — Garaipen gehienak ensemble metodo bidez lortzen dira.

Aplikazioak — Iruzur-detekzioa, medikuntza-diagnostikoa, mantenimendu prediktiboa.

Random Forest vs Boosting: alderaketa zehatza

	RANDOM FOREST	BOOSTING (XGBOOST, LIGHTGBM...)
Zuhaitzak	Paraleloan eraikitzen dira	Sekuentzialki eraikitzen dira
Helburua	Bariantza murriztu (overfitting saihestu)	Alborapena murriztu (bias)
Laginketa	Bootstrap — ausazko lagin independenteak	Pisuak — akatsen arabera handitu
Hiperparametro-doitze	Errazagoa — robustoa defektuz	Zainduagoa — learning rate, sakonera...
Outlierrekiko	Sendoa — bozketa diluitze akatsen	Sentikorra — akatsak handiagotzen ditu
Liburutegiak	sklearn RandomForest{Classifier,Regressor}	XGBoost, LightGBM, CatBoost, sklearn GBM

Gako-ideiak

-
- i* Ikasketa gainbegiratuan etiketak behar dira — horiek lortzea da askotan proiektuaren zatirik garestiena.

 - ii* Erregresioa (balio jarraitua) vs sailkapena (kategoria): arazoaren arabera aukeratu eta metrika egokia erabili.

 - iii* Erregresio logistikoak probabilitatea ematen du sailkapenean; atalasea arazoaren arabera doitu daiteke.

 - iv* KNN sinplea baina eskalatzea derrigorrezkoa du; k parametroa cross-validation bidez doitu.

 - v* Erabaki-zuhaitzak azalgarriak dira (GDPR, medikuntza); poda gabe gaindoiketa-joera dute.

 - vi* SVMk marjina maximoko muga bilatzen du; kernelak ez-linealtasuna kudeatzeko; beti eskalatu.

 - vii* Ensemble metodoek (Random Forest, Boosting) banakako ereduen mugak gaitzen dituzte — industria-estandarra.

Galderarik?

MATERIALA	5072_2_Ikasketa_Gainbegiratua.md
HURRENGO SAIOA	3.3 · Balidazio Metodologia