

Balidazio *Metodologia*

Train/test banaketa, datu-ihesa, cross-validation,
errendimendu-metrikak eta bias-variance dilema.

Zikloa Goi-mailako zikloa · Adimen Artifiziala eta Big Data

Ikasturtea 2025 / 2026



Saio honetan ikusiko duguna

01 Datuen partizio estrategikoa: Train / Validation / Test

02 Datu-ihesa (Data Leakage): sorrera eta prebentzioa

03 Balidazio Gurutzatua (Cross-Validation): K-Fold eta aldaerak

04 Nahaste-matrizea eta metrika eratorriak

05 Multi-klase estrategiak: macro, micro eta weighted

06 ROC kurbak eta AUC

07 Alborapena eta Bariantza: Bias vs Variance dilema

08 Ikasketa-kurbak diagnostiko tresna gisa


Zergatik hiru multzo eta ez bi?

Datu Banaketa Sinplea

Train / Validation / Test Split



K-Fold Balidazio Gurutzatua (K=5)



Azken emaitza: 5 iterazioaren batezbestekoa

- **Train (%70)** — Ereduaren parametroak ikasteko (β , zuhaitzaren adarrak, pisuak)
- **Validation (%15)** — Hiperparametroak doitzeko eta gaindoiketa detektatzeko
- **Test (%15)** — Azken ebaluazio alboragabea; behin bakarrik eta prozesuaren amaieran erabili
- **Arau kritikoa** — Test multzoa ezin da inoiz erabili eredua hobetzeko edo hiperparametro aldaketak egiteko
- **Zergatik hiru?** — Balidazioan hainbat arkitektura probatuta, eredua 'zeharka' egokitu da; test-ak orduan zerotik baieztatzen du
- **Banaketa tipikoa** — 70/15/15 edo 80/10/10 lagin-bolumenaren arabera
- **Analogia** — Azterketa: ikasten (train), barne-proba (validation), azterketa ofiziala (test)

Datu-ihesa: metodologiaren etsai nagusia

- **Zer da?** Test-multzoko edo etorkizuneko informazioa entrenamenduan modu desegokian sartzea
- **Ondorioa** — Metrika oso onak baina erabat faltsuak: ereduak 'bidea ikasi' du, ez patroi orokorra
- **Ihes-mota 1: eskalatzea gaizki** — datu guztiak batera eskalatzea; test-eko μ eta σ entrenamenduan eragiten du
- **Ihes-mota 2: subjektu beraren laginak banatu gabe** — ereduak pazientearen pertsonalitate-datuak memorizatzen ditu
- **Ihes-mota 3: denbora-serieetan** — 2020ko datuak erabiltzea 2019a iragartzeko ('look-ahead bias')
- **Ihes-mota 4: data augmentation gaizki** — fit-en aurretik augmentatu eta lagin beraren bertsioak bi multzoan
- **Konponbidea** — sklearn Pipeline: fit() soilik train datuekin; transform() biei aplikatu

K-Fold Cross-Validation: datuen erabilera maximoa

Arazoa: datu-multzo txikian, test multzo bakar batek bariantza handia du banaketa ausazkoaren arabera

K-Fold: datu-multzoa k zati berdinetan banatu; k aldiz entrenatu eta ebaluatu

Iterazio bakoitzean: $k-1$ fold $\rightarrow$ entrenamendu $\cdot$ 1 fold $\rightarrow$ balidazioa

CV Score: fold guztien batezbestekoa: $CV = (1/k) \cdot \sum \text{Score}_i$

k estandarra: $k=5$ edo $k=10$ — oreka ona kalitate eta denbora-kostuaren artean

Stratified K-Fold: klaseen proportzioa fold bakoitzean mantentzen du — funtsezkoa datu desorekatuekin

LOOCV (Leave-One-Out): $k=n$; lagin bat test gisa erabili — zehatza baina n handirako motelegi

Group K-Fold: talde osoa (adib. pazienteak) fold berera — subjektu-ihesa saihesteko

k txikia (2-3): entrenamendu-multzoa txikia $\rightarrow$ alborapena handia, gaitasuna azpiestimatu

k handia (20+): bariantza handia fold-en artean eta denbora-kostu oso altua

Cross-Validation teknikak: zein aukeratu?

TEKNIKA	TESTUINGURU OPTIMOA	MEKANISMOA
K-Fold	Datu orekatuak eta independenteak	Ausazko partizioa k taldetan
Stratified K-Fold	Sailkapen desorekatua (iruzurra, minbizia)	Klaseen proportzioa mantentzen du fold bakoitzean
LOOCV	Lagin oso gutxi ($n < 50$)	$k=n$; lagin bat test, beste guztiak train
Group K-Fold	Datu taldekatuak (medikuntza, sentsores)	Talde osoak fold berera → subjektu-ihesa saihestu

— CONFUSION MATRIX

Nahaste-matrizea: errore motak bereizi

Nahaste-Matrizea eta Metrika Nagusiak

	Iragarria: Positiboa	Iragarria: Negatiboa
Benetakoa: Positiboa	TP Egiazko Positiboa ✓	FN Detektatu gabeko kasua ✗
Benetakoa: Negatiboa	FP Alarma faltsua ✗	TN Egiazko Negatiboa ✓

$$\text{Zehaztasuna} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{Doitasuna} = \frac{TP}{TP + FP}$$

$$\text{Sentikortasuna} = \frac{TP}{TP + FN}$$

$$\text{F1} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN}$$

- **TP (True Positive)** — Positiboa zen, positibo iragarri: gaixoa zuzen antzeman
- **TN (True Negative)** — Negatiboa zen, negatibo iragarri: osasuntsua zuzen sailkatu
- **FP (False Positive)** — Negatiboa zen, positibo iragarri: alarma faltsua (spam garrantzitsua)
- **FN (False Negative)** — Positiboa zen, negatibo iragarri: gaixoa galdu (klinikoki larrienena)
- **Accuracy bakarrik erabiltzeak engainua ekar dezake** — %99ko datu desorekatuekin ereduak beti klase nagusia iragarritz lortzen du
- **Testuinguruak erabakitzen du** — spam iragazkian FP txarra da; minbizian FN txarra da
- **Diagnosticoko egokia** — matrizea erabiltza zehazki ikus daiteke non huts egiten duen ereduak

Precision, Recall eta F1: nola aukeratu?

METRIKA	FORMULA	NOIZ MAXIMIZATU	ADIBIDEA
Accuracy	$(TP+TN)/(TP+TN+FP+FN)$	Datu orekatuak eta testuinguru orokorra	Irudi-sailkapena orokorra
Precision	$TP/(TP+FP)$	FP kostu handikoa — ez galdu mezu garrantzitsuak	Spam detekzioa
Recall	$TP/(TP+FN)$	FN kostu handikoa — ez galdu gaixorik	Minbizi diagnostikoa
F1-Score	$2 \cdot TP/(2 \cdot TP+FP+FN)$	Bi metrikak orekatu nahi, datu desorekatuak	Iruzur-detekzioa

Klasa anitzeko metrikak: agregazio estrategiak

ESTRATEGIA	KLASEEN PISUA	NOIZ ERABILI	ADIBIDEA
Macro-averaging	Berdina klase guztientzat (klase txikiak garrantzitsuak)	Klase gutxiko detekzioa kritikoa	Minbizi mota arraroak diagnostikatu
Micro-averaging	Berdina lagin guztientzat (klase handiagoak nagusitzen)	Errore kopuru totala minimizatu	Dokumentu-sailkapen orokorra
Weighted-averaging	Lagin kopuruaren proportzionala (banaketa naturala islatu)	Datu-banaketa errealista islatu nahi	Sentimenduen analisisa datu errealarekin

ROC-AUC: atalasearekiko independentea den neurria

- Sailkatzaile gehienek probabilitate bat ematen dute (adib. 0.73), ez etiketa bat
- ROC kurbak TPR (Recall/Sentikortasuna) vs FPR (1-Espezifikotasuna) irudikatzen du atalase guztietan
- $AUC = \text{area under curve} = 0$ eta 1 arteko balioa: $AUC = \int_0^1 TPR d(FPR)$
- $AUC = 1.0 \rightarrow$ Sailkatzaile perfektua · $AUC = 0.5 \rightarrow$ Ausazko iragarlea (baliogabea)
- **$AUC < 0.5 \rightarrow$ Ereduak alderantziz iragartzen du** — etiketa trukatzuz $AUC > 0.5$ lortzen da
- **Abantaila nagusia** — Klaseen banaketarekiko eta atalasearen hautaketarekiko sendoa da
- **Multi-klasea** — OvR (One-vs-Rest): klase bakoitza gainontzekoen aurka; OvO (One-vs-One): pare guztiak

Azpidoiketa vs Gaindoiketa: diagnostikoa eta konponbidea

DIAGNOSTIKOA	TRAIN ERROREA	BALIDAZIO ERROREA	TARTEA	KONPONBIDEA
Azpidoiketa (Underfitting)	Altua	Altua	Txikia	Eredu konplexuagoa, ezaugarri gehiago, polinomiala
Gaindoiketa (Overfitting)	Oso baxua	Altua	Handia	Datu gehiago, erregularizazioa (L1/L2), pruning
Eredu Optimoa	Baxua	Baxua	Txikia	Oreka egokia — hau da helburu nagusia

Gako-ideiak

-
- i* Hiru multzo behar dira: train (ikasi), validation (doitu), test (ebalatu) — test multzoa behin bakarrik, prozesuaren amaieran.

 - ii* Datu-ihesa: eskalatzea fit() soilik train datuekin; sklearn Pipeline-ak hori bermatzen du automatikoki.

 - iii* K-Fold CV datu-multzo txikietan ezinbestekoa da estimazio fidagarria lortzeko — k=5 edo k=10 estandarra.

 - iv* Accuracy bakarrik ez da nahikoa — Precision, Recall eta F1 testuinguruaren arabera aukeratu.

 - v* AUC metrika sendoa da: klaseen desorekari eta atalasearen hautaketari ez die eragiten.

 - vi* Multi-klase metrikak: macro klase txikiak babesteko, micro lagin totala minimizatzeko, weighted banaketa errealista.
-

Galderarik?

MATERIALA	5072_3_Balidazio_Metodologia. md
HURRENGO SAIOA	3.4 · Ikasketa Ez-gainbegiratua