

Clasificación con KNN

Orange Data Mining - tarea 63321

Autor: Unai Urzainqui Perez

Fecha: 5 de octubre de 2026

1. Objetivo y datos elegidos

Aplicar KNN a un conjunto de datos real y explicar cómo sus medidas permiten clasificar una flor. Iris permite trabajar con cuatro variables continuas, tres clases equilibradas y errores fáciles de revisar. El modelo utiliza las cuatro medidas, sin reducir la dimensión.

Se utilizan **150 flores**, 50 por especie: setosa, versicolor y virginica. Las variables son longitud y anchura del sépalo y del pétalo, en centímetros. **iris** es el objetivo; no existen valores ausentes en la copia evaluada.

The screenshot shows the 'File' widget in Orange Data Mining. The 'Source' section has 'File: datos/iris.csv' selected. A tooltip states: 'This widget loads only tabular data. Use other widgets to load other data types like models, distance matrices and networks.' The 'File Type' dropdown is set to 'Determine type from the file extension'. The 'Info' section displays: '150 instances', '4 features (no missing values)', 'Classification; categorical class with 3 values (no missing values)', and '0 meta attributes'. The 'Columns (Double click to edit)' table is as follows:

	Name	Type	Role	Values
1	sepal_length	numeric	feature	
2	sepal_width	numeric	feature	
3	petal_length	numeric	feature	
4	petal_width	numeric	feature	
5	iris	categor...	target	setosa, versicolor, virginica

At the bottom, there are 'Reset' and 'Apply' buttons, and a 'Browse documentation datasets' button. The status bar at the very bottom shows '150' instances.

Figura 1. Widget File nativo de Orange: datos cargados y papel de las columnas. Captura de la misma tabla usada en la evaluación.


2. Configuración del modelo y evaluación

Modelo: kNN con **k=3**, distancia euclídea y voto uniforme. No se aplica normalización. Los preprocesadores predeterminados de Orange gestionan variables categóricas y datos ausentes; aquí todas las entradas ya son numéricas y completas. Un cambio de escala puede cambiar qué vecinos resultan más próximos.



Figura 2. Parámetros del learner en su widget nativo.

Evaluación: validación cruzada estratificada de 10 folds, barajada y con semilla 42. Cada fila se evalúa exactamente una vez con un modelo entrenado sin esa fila. La semilla 42 es la que utiliza Test & Score en Orange 3.40.0.



Model	AUC	CA	F1	Prec	Recall	MCC
kNN	0.979	0.960	0.960	0.960	0.960	0.940

Compare models by: Area under ROC curve	
kNN	

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

Figura 3. Test & Score ejecutado de forma nativa. Las columnas F1, precisión y recall muestran el promedio ponderado por soporte de las clases.

3. Salidas y análisis de los errores

La evaluación fuera de muestra obtiene **144/150 aciertos**, exactitud **0.9600** y AUC 0.9786. La referencia de predecir siempre una clase mayoritaria alcanza 0.3333.




Figura 4. Confusion Matrix nativa. Filas: clase real; columnas: clase predicha. Los números corresponden a las predicciones OOF exportadas, sin mezclar el orden de los folds con el de las filas originales.

Clase	Precisión	Recall	F1	n
setosa	1.0000	1.0000	1.0000	50
versicolor	0.9400	0.9400	0.9400	50
virginica	0.9400	0.9400	0.9400	50
Ponderado	0.9600	0.9600	0.9600	150

Setosa se clasifica correctamente en las 50 filas. Tres versicolor se confunden con virginica y tres virginica con versicolor. Las dos clases comparten regiones de medidas próximas; estos seis errores concentran toda la pérdida de exactitud. No se han seleccionado k ni escalado después de observar el resultado.

4. Conclusiones y límites

Fila original	Fold	Real	Predicho
71	5	versicolor	virginica
73	6	versicolor	virginica
84	6	versicolor	virginica
107	4	virginica	versicolor
120	10	virginica	versicolor
134	5	virginica	versicolor

KNN obtiene 0,9600 de exactitud en este protocolo fijo. El buen resultado se explica por la cercanía entre flores de la misma especie; los errores se concentran entre versicolor y virginica. KNN conserva ejemplos y decide por vecinos, de modo que sus resultados dependen de k, la distancia, la escala y la cobertura de los datos.

Los 150 casos constituyen una muestra pequeña y clásica. La CV no prueba el resultado en nuevas poblaciones, mediciones con otras unidades o flores ajenas a estas tres especies. No se ha hecho búsqueda de hiperparámetros ni comparación estadística. Una probabilidad de 1 significa unanimidad de los tres vecinos, **no certeza garantizada**.

Reproducción y trazabilidad

El paquete incluye **Flujo_Orange.ows**, la tabla en **datos/**, **reproducir.py**, **predicciones_oof.csv**, **resultados.json** y las capturas nativas en **evidencias/**. El workflow utiliza una ruta relativa a sus propios datos. El README explica cómo abrirlo o repetir la evaluación.

Se comprobaron la matriz, los totales por clase, una evaluación por fila, la alineación entre datos y etiquetas y las particiones de los diez folds. La salida de Test & Score coincide con una segunda evaluación por la API de Orange (incluidas las probabilidades, tolerancia 1e-10). Los hashes SHA-256 permiten detectar modificaciones de los archivos.

Entorno verificado: Orange 3.40.0; scikit-learn 1.9.1; NumPy 2.3.5; Python 3.13.13.

Fuentes de los datos

Fisher, R. A. (1936). *Iris*. UCI Machine Learning Repository. DOI: [10.24432/C56C76](https://doi.org/10.24432/C56C76). CC BY 4.0. Se usa la copia Iris del ejercicio, contrastada con load_iris de scikit-learn.

Los enlaces de procedencia se consultaron el 05/10/2026. Las métricas proceden de la ejecución local documentada; no de ejemplos de la fuente.