

Regresión logística

Orange Data Mining - tarea 63320

Autor: Unai Urzainqui Perez

Fecha: 5 de octubre de 2026

1. Objetivo y datos elegidos

Aplicar un modelo de regresión logística a un conjunto de datos real, explicar su preparación y analizar sus salidas. Se utiliza WDBC porque combina una variable numérica interpretable con un objetivo binario. Se restringe el modelo a **texture_mean** para estudiar la relación entre textura y diagnóstico; las otras 29 variables del conjunto original no intervienen.

WDBC contiene **569 muestras**: 357 B (benignas) y 212 M (malignas), sin valores ausentes. **texture_mean** resume la textura de los núcleos mediante la desviación de los niveles de gris. **diagnosis** es el objetivo; **sample_id** se conserva solo como metadato.

Source

File: datos/wdbc_texture_mean.tab

URL:

This widget loads only tabular data. Use other widgets to load other data types like models, distance matrices and networks.

Ok, got it

...

Reload

File Type

Determine type from the file extension

Info

569 instances

1 feature (no missing values)

Classification; categorical class with 2 values (no missing values)

1 meta attribute

Columns (Double click to edit)

	Name	Type	Role	Values
1	texture_m...	N numeric	feature	
2	diagnosis	C categor...	target	B, M
3	sample_id	S text	meta	

Reset

Apply

Browse documentation datasets

569

Figura 1. Widget File nativo de Orange: datos cargados y papel de las columnas. Captura de la misma tabla usada en la evaluación.

Unai Urzainqui Perez | Orange Data Mining | 05/10/2026

1

2. Configuración del modelo y evaluación

Modelo: regresión logística con regularización Ridge (L2), C=1, intercepto y sin ponderación de clases. La textura se estandariza a media 0 y desviación 1 **dentro del entrenamiento de cada fold**, mediante Preprocess conectado al Learner. El solver es lbfgs; el widget usa max_iter=10000 y random_state=0.





Figura 2. Parámetros del learner en su widget nativo.

Evaluación: validación cruzada estratificada de 10 folds, barajada y con semilla 42. Cada fila se evalúa exactamente una vez con un modelo entrenado sin esa fila. La semilla 42 es la que utiliza Test & Score en Orange 3.40.0.



Model	AUC	CA	F1	Prec	Recall	MCC
Logistic Regression	0.774	0.707	0.690	0.699	0.707	0.340

Compare models by: Area under ROC curve	
Logistic Regression	Logistic Regression
Logistic Regression	1.0

Figura 3. Test & Score ejecutado de forma nativa. Las columnas F1, precisión y recall muestran el promedio ponderado por soporte de las clases.

3. Salidas y análisis de los errores

La evaluación fuera de muestra obtiene **402/569 aciertos**, exactitud **0.7065** y AUC 0.7745. La referencia de predecir siempre una clase mayoritaria alcanza 0.6274.




Figura 4. Confusion Matrix nativa. Filas: clase real; columnas: clase predicha. Los números corresponden a las predicciones OOF exportadas, sin mezclar el orden de los folds con el de las filas originales.

Clase	Precisión	Recall	F1	n
B	0.7209	0.8683	0.7878	357
M	0.6619	0.4340	0.5242	212
Ponderado	0.6989	0.7065	0.6896	569

Hay **120 M clasificadas como B** y 47 B clasificadas como M. El recall de M es $92/212 = 0,4340$: la exactitud global de 0,7065 oculta un comportamiento mucho peor para esa clase. La balanced accuracy es 0,6512. Este ejemplo de una sola variable deja amplio solapamiento entre clases.

4. Curva del modelo y diagnósticos observados




Figura 5. Figura explicativa generada con el modelo ajustado sobre las 569 filas. Los puntos representan **diagnósticos observados**, B=0 y M=1, frente a la textura real. La línea representa la probabilidad calculada por el modelo; no son probabilidades observadas.

La logística transforma el score lineal z en una probabilidad: $p(M)=1/(1+\exp(-z))$. Al aumentar la textura, la probabilidad ajustada aumenta, pero ambas clases siguen apareciendo en una misma zona. Dibujar p frente a $\text{logit}(p)$ colocaría los puntos sobre la sigmoide por construcción; no demostraría concordancia con los diagnósticos.




Figura 6. ROC Analysis nativo con M como objetivo. La curva usa las probabilidades OOF; la sigmoide superior usa ajuste completo únicamente para explicar el modelo. AUC=0,7745 mide ordenación, no garantiza acierto ni seguridad de una decisión.

5. Conclusiones y límites

La textura media contiene información sobre el diagnóstico: su media es 17,9148 en B y 21,6049 en M. La logística de una variable supera la referencia mayoritaria, aunque produce 167 errores. La regularización y la normalización no compensan la información descartada al excluir las demás variables.

La validación cruzada estima el comportamiento dentro de esta muestra histórica. No se ha realizado validación temporal, externa ni prospectiva. No se ha estudiado calibración o incertidumbre individual y el umbral 0,5 no ha sido optimizado. **El modelo y este informe son educativos; no sirven para decisiones clínicas.**

Reproducción y trazabilidad

El paquete incluye **Flujo_Orange.ows**, la tabla en **datos/**, **reproducir.py**, **predicciones_oof.csv**, **resultados.json** y las capturas nativas en **evidencias/**. El workflow utiliza una ruta relativa a sus propios datos. El README explica cómo abrirlo o repetir la evaluación.

Se comprobaron la matriz, los totales por clase, una evaluación por fila, la alineación entre datos y etiquetas y las particiones de los diez folds. La salida de Test & Score coincide con una segunda evaluación por la API de Orange (incluidas las probabilidades, tolerancia 1e-10). Los hashes SHA-256 permiten detectar modificaciones de los archivos.

Entorno verificado: Orange 3.40.0; scikit-learn 1.9.1; NumPy 2.3.5; Python 3.13.13.

Fuentes de los datos

Wolberg, W.; Mangasarian, O.; Street, N.; Street, W. (1993). *Breast Cancer Wisconsin (Diagnostic)*. UCI Machine Learning Repository. DOI: [10.24432/C5DW2B](https://doi.org/10.24432/C5DW2B). CC BY 4.0. Se entrega la selección de `texture_mean` con las etiquetas originales.

Los enlaces de procedencia se consultaron el 05/10/2026. Las métricas proceden de la ejecución local documentada; no de ejemplos de la fuente.