

Iris: Regresión Logística frente a KNN

Unai Urzainqui Perez | 5072 | tarea 63325 | 5 de octubre de 2026

1. Objetivo y datos

Comparar las fronteras de un modelo lineal y uno basado en vecinos. Iris contiene 150 flores, 50 setosa, 50 versicolor y 50 virginica. Se utilizan las primeras dos variables: longitud y anchura del sépalo, en centímetros. Las medidas del pétalo no entran en los modelos.

El notebook completa la plantilla docente: carga de Iris, función de fronteras, Regresión Logística con `max_iter=200`, KNN con `k=3`, gráficos lado a lado y reflexión. Los datos se cargan desde `scikit-learn`, sin descargar CSV.

2. Método y resultados

Se entrenan los modelos con las 150 flores y se evalúan con esas mismas filas, sin escalado. Las cifras describen entrenamiento; no son resultados de test o validación cruzada.

Modelo	Accuracy entrenamiento	Aciertos / 150	Frontera
Regresión Logística	0.8200	123	Lineal
KNN, k=3	0.8533	128	Local e irregular

KNN tiene 5 aciertos más en entrenamiento (128 frente a 123). Eso no demuestra mejor rendimiento en flores nuevas. Los modelos tienen distinta flexibilidad y no se ha reservado una muestra de test.

3. Comparación visual

Iris · 150 flores · dos medidas del sépalo · ajuste en toda la muestra




Figura 1. Gráfico generado al ejecutar el notebook. Los puntos son clases observadas; el fondo muestra clases predichas en una malla. Ambos paneles tienen los mismos ejes. Color y forma distinguen las especies. No es un mapa de probabilidades.

Preguntas de reflexión

Setosa: ambos modelos aciertan las 50 setosa de esta muestra. Esa especie ocupa una región diferenciada del plano. Versicolor y virginica se solapan con estas medidas y no se separan perfectamente; no se asegura separación en flores nuevas.

Rectas y límites locales: LogReg dibuja fronteras rectas en el plano; KNN se adapta a la distribución local de vecinos. La flexibilidad de KNN permite seguir puntos aislados, pero también lo hace más sensible al ruido.

k muy pequeño o grande: con $k=1$ se espera más sensibilidad a puntos aislados y riesgo de sobreajuste. Con $k=50$ las fronteras se suavizan y pueden perder estructura, aumentando el riesgo de subajuste. Esta reflexión es hipotética: la ejecución utiliza solamente $k=3$.

4. Comprobación de resultados

Las filas de las matrices son clases observadas; las columnas son predicciones. Orden: setosa, versicolor y virginica. Cada matriz suma 150 y su diagonal reproduce los aciertos de la tabla.

Regresión Logística

Real / predicha	setosa	versicolor	virginica
setosa	50	0	0
versicolor	0	37	13
virginica	0	14	36

KNN, k=3

Real / predicha	setosa	versicolor	virginica
setosa	50	0	0
versicolor	0	37	13
virginica	0	9	41

5. Conclusiones y reproducción

La comparación ilustra dos formas de representar los mismos datos: una separación lineal sencilla y fronteras locales más flexibles. La mayor accuracy de entrenamiento de KNN no decide qué modelo generaliza mejor. Para comprobarlo haría falta holdout o CV y aprender cualquier transformación dentro de cada entrenamiento.

Archivos: iris_logreg_knn.ipynb (código y salidas), txostena_beteta.md (informe), erabaki_mugak.png (figura) y resultados.json (matrices y versiones). README.md explica cómo ejecutar desde un kernel limpio. El PDF acompaña al notebook y no lo sustituye.

Fuente docente: tarea Moodle 63325, plantillas ikaskuntza_gainbegiratua_ikaslea.ipynb y txostena_ikaslea.md. Dataset: sklearn.datasets.load_iris(), colección de tres especies de Iris.