

ORANGE DATA MINING

Heart Disease: CV erreproduzigarria

5072 Ikasketa Automatikoa | Tokiko exekuzio egiaztatua: 2026-10-02

1. Helburua, datuak eta ebaluazioa


Decision Tree eta Random Forest alderatzea da helburua, Logistic Regression eta k-NN erreferentziekin. Orange-ren Heart Disease lagina: **303 erregistro, 13 iragarle**; target: **diameter narrowing**. Klase 0: 164; klase 1: 139. **Klase positiboa: 1**. Iragarleetan 6 balio falta daude; erregistro guztiak mantendu dira.

Datuak Orange-ren lagin-fitxategitik kopiatuta daude; ez dira paziente berriak edo kanpo-balioztatze kohorte bat. Klase-etiketek dataseteko diameter narrowing sailkapena adierazten dute; ez dira diagnostiko kliniko berriak.

Split: 10-fold stratified CV, shuffle=True, random_state=42. Lau modeloek fold berberak erabiltzen dituzte. Erregistro bakoitzak bere entrenamendutik kanpoko iragarpen bakarra du modelo bakoitzeko. Inputazioa eta normalizazioa learner bakoitzaren training fold barruan doitzen dira.

Metrikak out-of-fold iragarpen guztiak elkartuta kalkulatzen dira, ez fold-metriken batezbesteko gisa. F1, Precision eta Recall bitarrak dira (klase 1). CA klase-iragarpenarekin kalkulatzen da; ROC/AUC klase 1 probabilitatearekin.

Orange Python API: preprocessing inside training folds



1. irudia: egiaztatutako Python API prozesuaren eskema; ez da Orange GUI pantaila-argazkia.

Exekuzio-ingurunea: python 3.13.13, Orange 3.40.0, sklearn 1.9.1, numpy 2.3.5

2. Ereduak eta emaitzak

Logistic Regression: {"C": 1, "penalty": "l2", "max_iter": 1000, "random_state": 42}. Aurreprozesamendua: Continuize(), Impute(), Normalize().


Random Forest: {"n_estimators": 100, "random_state": 42, "max_depth": null, "max_features": "sqrt"}. Aurreprozesamendua: Continuize(), Impute().

Decision Tree: {"max_depth": 5, "min_samples_leaf": 1, "min_samples_split": 2, "sufficient_majority": 0.95}. Aurreprozesamendua: Impute().

k-NN (k=5): {"n_neighbors": 5, "metric": "euclidean", "weights": "uniform"}. Aurreprozesamendua: Continuize(), Impute(), Normalize().

TreeLearner Orange-ren zuhaitza da; ez da sklearn CART gisa aurkezten. Random Forest sklearn bidezko Orange learner da. LR eta k-NN aldagai jarraitu normalizatuekin ebaluatu dira; konfigurazioa ez dator bat aurreko PDFko balio literalekin.

Model	AUC	CA	F1	Precision	Recall
Logistic Regression	0.9055	0.8317	0.8104	0.8385	0.7842
Random Forest	0.9009	0.8119	0.7897	0.8106	0.7698
Decision Tree	0.7993	0.7822	0.7574	0.7744	0.7410
k-NN (k=5)	0.8629	0.8185	0.8000	0.8088	0.7914




2. irudia: benetako CV metrikak; F1/Precision/Recall klase 1erako.

Decision Tree (63544): CA=0.7822, AUC=0.7993, Recall=0.7410. Arauak ikus daitezke, baina interpretazioa ez da kanpo-balioztatzea.

Random Forest (63386): CA=0.8119, AUC=0.9009, Recall=0.7698. Exekuzio honetako AUC handiagoa du zuhaitz bakarrak baino; ez da esangura estatistikorik edo populazio berrietako nagusitasunik frogatu.

3. Nahasketa-matrizeak eta ROC

Out-of-fold confusion matrices / positive class 1




3. irudia: errenkadak benetako klaseak; zutabeak iragarritako klaseak. Matrizeak 303 erregistro biltzen ditu modelo bakoitzeko.

Decision Tree: TN=134, FP=30, FN=36, TP=103.

Random Forest: TN=139, FP=25, FN=32, TP=107.

3.1 ROC enpirikoa



4. irudia: held-out probabilitateetatik sortutako ROC enpirikoak. Ez dago formula analitikorik edo atari optimo asmaturik.

AUCk sailkapen-gaitasuna laburbiltzen du atari guztietan. Ez du probabilitateen kalibrazioa edo erabaki klinikoaren erabilgarritasuna neurtzen. Atari bat CV emaitza hauetan aukeratuz gero, atari horren errendimendua beste datu independenteetan egiaztatu beharko litzateke.

4. Zuhaitzaren azalpena

Beheko arauak datu guztiekin entrenatutako max_depth=3 zuhaitz errearen print_tree irteera dira. Kopuruak training laginekoak dira; CV taulako zuhaitzak max_depth=5 erabiltzen du. Nodo baten %100 training proportzioak ez du ziurtasuna edo probabilitate kliniko kalibratua esan nahi.

Actual Orange tree rules / max_depth=3 / fitted on all rows
Illustration only; CV evaluates max_depth=5

```
Root counts [class 0 / class 1]: [164.0, 139.0]
[130. 38.] thal normal
[29. 25.] chest pain asymptomatic
[26. 8.] major vessels colored ≤ 0
[3. 17.] major vessels colored > 0
[35. 4.] chest pain atypical ang
[29. 0.] age ≤ 56
[6. 4.] age > 56
[57. 5.] chest pain non-anginal
[32. 0.] gender female
[25. 5.] gender male
[9. 4.] chest pain typical ang
[4. 0.] gender female
[5. 4.] gender male
[28. 89.] thal reversible defect
[7. 71.] chest pain asymptomatic
[7. 14.] ST by exercise ≤ 0.5
[0. 57.] ST by exercise > 0.5
[5. 4.] chest pain atypical ang
[3. 0.] cholesterol ≤ 221
[2. 4.] cholesterol > 221
[11. 11.] chest pain non-anginal
[11. 6.] ST by exercise ≤ 1.8
[0. 5.] ST by exercise > 1.8
[5. 3.] chest pain typical ang
[3. 0.] cholesterol ≤ 227
[2. 3.] cholesterol > 227
[6. 12.] thal fixed defect
[6. 2.] major vessels colored ≤ 0
[1. 2.] age ≤ 44
[5. 0.] age > 44
[0. 10.] major vessels colored > 0
```

5. irudia: zuhaitz errearen adarrak eta klase 0/1 kopuruak, inputazioaren ondoren.

5. Erreproduzigarritasuna eta mugak

Sarrerak eta irteerak: datos/heart_disease/heart_disease.tab; predicciones_cv.csv (row_index, fold, model, actual, predicted, probability_1); resultados_cv.json (hashak, bertsioak, hiperparametroak, metrikak, ROC eta zuhaitza). Exekuzio-komandoak eta egiaztapenak Heart_Disease_Evaluacion.md dokumentuan daude.

Datu-multzo bakarra eta split bakarra erabili dira; ez dago kanpo-testik, nested CVrik, kalibrazio edo justizia-ebaluziorik. Ez da ezaugarrien garrantziaren adostasunik egiaztatu, ezta eredu baten nagusitasun estatistikorik ere. Orange_Bihotza_Ereduak.ows ez da GUI bidez exekutatu eta bere konfigurazioa ez da exekuzio honen baliokidea. Emaitzak ikasketa akademikorako dira; ez erabilera klinikorako.

Dataset SHA-256: 954e44e3d93a97682b5466c7ea166e16f376f8dd93deef5855f511734e4d6224