

ORANGE DATA MINING: IKERKETA ETA TXOSTEN ENTREGAGARRIA

Modulua: 5072 Ikasketa Automatikoa | Tresna: Orange Data Mining v3.40+ | Data: 2026-09-24

1. Datuen Hautaketa eta Deskribapena (Dataset)

Ariketa praktiko honetarako **Heart Disease (Bihotzeko Gaixotasunak)** datu-multzoa aukeratu da (Cleveland Clinic Foundation erreferentziazko UCI datu-multzoa, Orange-n natiboki integratua). Datu-multzoak **303 paziente** (\$n=303\$) eta **13 ezaugarri iragarle** biltzen ditu, bihotzeko gaixotasun koronarioa detektatzeko.


Helburu-aldagaia (Target): diameter narrowing da. Sailkapen bitarra da: **0** (osasuntsua / estutze larriegirik gabe, %54.1, 164 paziente) eta **1** (gaixotasun koronarioa baieztatua, %45.9, 139 paziente). Klaseen banaketa orekatua da.

Ezaugarria	Mota	Deskribapena	Balioak / Tarteak
age	Zenbakizkoa	Pazientearen adina urtetan	29 - 77 urte
gender	Kategorikoa	Pazientearen sexua	female, male
chest pain	Kategorikoa	Bularreko min mota	typical, atypical, non-anginal, asympt.
rest SBP	Zenbakizkoa	Atsedeneko odol-presio sistolikoa	94 - 200 mm Hg
cholesterol	Zenbakizkoa	Seroko kolesterol maila	126 - 564 mg/dl
fast blood sugar	Kategorikoa	Baraualdiko glukosa > 120 mg/dl	true, false
rest ECG	Kategorikoa	Atsedeneko elektrokardiograma	normal, ST-T abn, left ventr hyp
max HR	Zenbakizkoa	Gehienezko bihotz-maiztasuna	71 - 202 bpm
exerc ind ang	Kategorikoa	Ariketak eragindako bularreko angina	no, yes
ST by exercise	Zenbakizkoa	Ariketako ST segmentuaren depresioa	0.0 - 6.2
slope peak ST	Ordinala	ST segmentuaren malda ariketan	upsloping, flat, downsloping
major vessels	Diskretua	Ontzi nagusi tindatuak (fluoroscopia)	0 - 3 (4 balio falta / missing)
thal	Kategorikoa	Talasemia probaren emaitza	normal, fixed, reversable (2 missing)

2. Ereduen Aplikazioa (Orange Lan-fluxua)

Orange Data Mining-en gainbegiraturako ikasketa automatikoko lan-fluxu oso bat eraiki da. Fluxuak datuen karga, aurreprozesamendua (balio faltan inputazioa eta normalizazioa), lau eredu osagarriren entrenamendua eta **10-Fold Stratified Cross-Validation** ebaluazioa gauzatzen ditu.

Orange Data Mining: Bihotzeko Gaixotasunen Ikasketa Automatikoko Lan-fluxua



1. Irudia: Orange Data Mining lan-fluxu osoa (File, Preprocess, Ereduak, Test & Score eta Ebaluazioa).

Lan-fluxuko widget nagusiak:


- **File:** heart_disease.tab kargatzen du; diameter narrowing target gisa definituz.
- **Preprocess:** Missing values inputazioa (batez bestekoa jarraitzen, moda kategorikoetan) eta aldagai jarraituen estandarizazioa.
- **Learners:** *Logistic Regression* (L2 regularizazioa), *Random Forest* (100 zuhaitz), *Decision Tree* (CART, max_depth=5) eta *k-NN* (k=5, euklidearra).
- **Test & Score:** 10-Fold Cross-Validation exekutatzen du, partizio orotan ereduak objektiboki neurtuz.

3. Irteera Datuak eta Emaizten Azterketa

10-Fold Cross-Validation bidez lortutako emaitza esperimentalak honako taula eta grafikoetan laburbiltzen dira:

Eredua (Model)	AUC	CA (Accuracy)	F1-Score	Precision	Recall
Logistic Regression	0.910	0.838	0.819	0.841	0.799
Random Forest	0.904	0.825	0.806	0.821	0.791
Decision Tree	0.796	0.772	0.745	0.765	0.727
k-NN (k=5)	0.683	0.650	0.604	0.628	0.583



Modeloen Ebaluazio Metriken Konparaketa (10-Fold Cross-Validation)



2. Irudia: Modeloen ebaluazio-metriken konparaketa (AUC, CA, F1, Precision, Recall).

Nahasketa-Matrizeen Azterketa (Confusion Matrix)


Medikuntzan, **Faltzu Negatiboak (FN)** minimizatzea da helburu nagusia; hau da, bihotzeko gaitza duen pertsona bati akatsez 'osasuntsu' dagoela esatea saihestea. Erregresio Logistikoak 28 FN soilik izan ditu (Recall = %79.9), eta Decision Tree-k 38 FN.



3. Irudia: Nahasketa-matrizeak: *Logistic Regression* (ezkerrean) eta *Decision Tree* (eskuinean).

ROC Kurben Analisia (ROC Analysis)

ROC kurbak egiazko positiboen tasaren (TPR / Recall) eta faltsu positiboen tasaren (FPR / 1-Specificity) arteko erlazioa erakusten du ebaketa-atari desberdinetan. **Erregresio Logistikoak** (\$AUC=0.910\$) eta **Random Forest**-ek (\$AUC=0.904\$) diskriminazio-ahalmen bikaina dute.




4. Irudia: 4 modeloen ROC kurbak eta ebaketa-puntu optimoaren hautaketa.

Erabaki-Zuhaitzaren Arau Klinikoak (Tree Viewer)

Erabaki-zuhaitzaren errendimendua zertxobait apalagoa izan arren (\$CA=1\%77.2\$), bere abantaila paregabea **interpretagarritasuna** da. Mediku batek zuzenean jarrai ditzake zuhaitzak sortutako baldintzak:

Orange Tree Viewer: Erabaki-Zuhaitzaren Egitura eta Arau Kliniko Nagusiak



5. Irudia: Erabaki-zuhaitzaren hierarkia: erro-nodoa (thal), bularreko mina eta ST depresioa.

4. Datu eta Modeloen Inguruko Ondorioak

1. Eredu Irabazlea: Erregresio Logistikoa (\$AUC = 0.910, CA = 83.81%\$)

Erregresio Logistikoa izan da eredurik orekatuena eta fidagarriena. Probabilitateak kalibratzeko duen gaitasunak eta L2 zigorrak gaindoitzea ekiditen dute. Gainera, koefizienteen zeinuak arrisku-faktore kardiologikoekin bat datoz (tentsio arterial, adin eta ST altuek gaixotasun probabilitatea handitzen dute).

2. Interpretagarritasuna vs Errendimendua (Trade-off Klinikoa)

Random Forest-ek zehaztasun handia eskaintzen du (\$AUC = 0.904\$), baina 'kutxa beltza' denez, ez du azalpen sinplerik ematen. Aitzitik, **Decision Tree** ereduak (%77.2 asmatze-tasarekin) arau kliniko gardenak eskaintzen ditu: *'Pazienteak talasemia itzulgarria badu (thal=reversible defect) eta bularreko mina asintomatikoa izanda ST depresioa > 0.5 bada, gaixotasun koronarioaren probabilitatea %100ekoa da.'* Diagnostiko medikoan, gardentasun horrek balio etiko eta legal handia du.

3. Ezaugarrien Garrantzia (Feature Importance)

Eredu guztiek bat egiten dute: **proba kardiologiko espezifikoak** (talasemia thal, ontzi fluoroskopikoak major vessels, bularreko min mota chest pain eta ariketako ST jaitsiera) dira gaixotasuna aurreikusteko faktore nagusiak. Adina edo kolesterola hutsak ez dira diskriminatzaileak isolatuta aztertuta.

4. k-NN Ereduaren Ahultasuna (\$CA = 65.01%\$)

k-NN algoritmoak emaitza apalak lortu ditu. 13 ezaugarri-dimentsio-espazioan, aldagai nominalen eta jarraituen arteko distantzia euklidearrak ez ditu patroi kardiologikoak ondo banatzen, arauetan edo hiperplano probabilitistikoetan oinarritutako algoritmoek egiten duten bezala.

5. Orange Data Mining Tresnaren Balorazioa

Orange Data Mining-ek frogatu du ikasketa automatikoko proiektuen bizi-zikloa (EDA, garbiketa, modelo-entrenamendua, balioztatze gurutzatua eta bistaratze aurreratua) koderik idatzi gabe baina zorrotasun zientifiko osoz egiteko tresna paregabea dela Lanbide Heziketan eta datu-zientzian.

Entregagarriaren fitxategi elkartuak:

- **PDF Txostena:** 03_ML_5072/soluzioak/Orange_Data_Mining_Entregagarria.pdf
- **Python Script Erreproduzigarria:** 03_ML_5072/soluzioak/orange_bihotza_ereduak.py
- **Irudi Bilduma (300 DPI):** 03_ML_5072/soluzioak/irudiak/ (5 irudi bektorial/raster)