

Orange Data Mining: regresión lineal

UCI Auto MPG · peso del vehículo y consumo urbano

Creador: Unai Urzainqui Perez Software: Orange Data Mining 3.40

1. Datos elegidos

Uso Auto MPG, conjunto publicado por UCI para tareas de regresión. Contiene 398 coches de los años modelo 1970-1982; el objetivo original es el consumo urbano en millas por galón. Para este ejercicio selecciono **weight** (peso, libras) como predictor y **mpg** como objetivo. Así estudio una relación concreta y puedo interpretar la pendiente con unidades.

Conservo las 398 filas. Los seis valores ausentes de horsepower no afectan porque esa variable no entra en este modelo. Excluyo car_name porque identifica el coche y no es una medida numérica adecuada para esta regresión. La tabla de Orange y el CSV de predicciones mantienen la trazabilidad.

Observaciones	Predictor	Objetivo	Peso	Consumo
398 coches	weight	mpg	1613-5140 lb	9.0-46.6 mpg

Flujo de trabajo aplicado en Orange



Unai Urzainqui Perez · Orange Data Mining · regresión lineal simple


La fuente de datos es el archivo relativo datos/auto_mpg/auto_mpg_weight.tab; el flujo se puede abrir sin depender de una ruta privada del equipo creador.

2. Modelo y evaluación

Aplico **regresión lineal simple por mínimos cuadrados ordinarios (OLS)**: $\text{mpg} = b + w \times \text{weight}$. Orange evalúa el modelo con validación cruzada de 10 particiones y semilla 42. Las métricas principales se calculan con predicciones fuera de muestra (cada coche se predice desde un modelo ajustado sin ese coche). La ecuación descriptiva se ajusta una vez sobre las 398 filas completas; no se usan sus errores de entrenamiento como métrica de generalización.

Métrica (10-fold CV)	Resultado	Interpretación
R ²	0.690	Variación explicada en predicción fuera de muestra
RMSE	4.35 mpg	Penaliza más los errores grandes
MAE	3.30 mpg	Error absoluto medio
MSE	18.88 mpg ²	Error cuadrático medio


La recta ajustada a todos los datos es **$\text{mpg} = 46.32 - 0.00768 \times \text{weight}$** . La correlación de Pearson es $r = -0.832$. En esta muestra, 1.000 libras más se asocian con aproximadamente 7.68 mpg menos, en promedio lineal.



La recta resume una tendencia media; la dispersión de los puntos muestra que el peso no explica por sí solo todo el consumo.

3. Salidas y análisis

El fichero `auto_mpg_cv_iragarpenak.csv` contiene una fila por coche: identificador, peso, consumo observado, predicción fuera de muestra y residuo (observado - predicho). El JSON complementario conserva las métricas completas. En validación cruzada, el error absoluto medio es 3.30 mpg y el RMSE 4.35 mpg. El percentil 95 del error absoluto es 8.68 mpg, por lo que hay coches para los que la recta se equivoca bastante más que el promedio.



Predicciones fuera de muestra (izquierda) y residuos CV según el peso (derecha). La línea ideal y el cero indican referencia, no ajuste adicional.

Ejemplos con mayor error absoluto

Coche	Peso (lb)	Observado mpg	Predicho mpg	Residuo mpg
mazda glc	2110.0	46.600	30.118	16.482
vw dasher (diesel)	2335.0	43.400	28.299	15.101
oldsmobile cutlass ciera (diesel)	3015.0	38.000	23.038	14.962
vw rabbit c (diesel)	2085.0	44.300	30.129	14.171
vw pickup	2130.0	44.000	30.005	13.995

4. Conclusiones y límites

Conclusión: en estos coches históricos, los vehículos más pesados tienden a registrar menos millas por galón. El modelo lineal con peso explica alrededor del 69.0% de la variación según validación cruzada. Su MAE de 3.30 mpg lo hace útil para ilustrar una tendencia, pero los residuos y errores grandes muestran que no basta para describir bien cada vehículo.

Límites: son datos urbanos antiguos de 1970-1982, no una muestra de coches actuales ni de todos los mercados. La asociación no demuestra que el peso por sí solo cause el cambio de consumo; motor, tecnología y año también pueden influir. El resultado es un ejercicio didáctico, no una herramienta para estimar vehículos actuales.

Procedencia: R. Quinlan (1993), [UCI Auto MPG](#), DOI [10.24432/C5859H](#). Licencia CC BY 4.0 según UCI. Datos originales, transformación, workflow Orange, salida CSV y métricas JSON incluidos junto al entregable.

Creador: Unai Urzainqui Perez