

Orange Data Mining: regresión logística


Wisconsin Breast Cancer Diagnostic - benigno o maligno

Creador: Unai Urzainqui Perez Herramienta: Orange Data Mining 3.40

1. Datos elegidos


Uso el conjunto **Breast Cancer Wisconsin (Diagnostic)** de UCI. Cada registro contiene medidas calculadas desde una imagen digital de una aspiración con aguja fina (FNA) de una masa mamaria. La etiqueta **B** significa benigno y **M** maligno. Hay 569 muestras: 357 benignas y 212 malignas, sin valores ausentes.

Para que el ejemplo muestre mayor solapamiento entre clases, el modelo usa solo **texture_mean**: la media de la desviación estándar de los niveles de gris en la imagen del núcleo celular. Este predictor separa menos las clases que otras variables de WDBC. Las otras 29 características originales no entran en este modelo univariable.



Distribución de las etiquetas del conjunto UCI.

Workflow reproducible en Orange



Puntos = diagnósticos reales; curva = $P(M)$ estimada. Las métricas se evalúan con validación cruzada.

Unai Urzainqui Perez


El archivo Orange conserva el identificador de muestra como meta, texture_mean como predictor y diagnosis como objetivo.

2. Aplicación y evaluación del modelo

Ajusto una **regresión logística binaria** con regularización L2 ($C=1$). La probabilidad de malignidad se calcula como $P(M|x) = 1 / (1 + \exp(-(b_0 + b_1 x)))$, donde x es `texture_mean`. Orange estandariza el predictor dentro del aprendizaje en cada partición y evalúa con validación cruzada estratificada de 10 folds, semilla 42. Las cifras siguientes usan predicciones fuera de muestra; la exactitud de entrenamiento no se usa como evaluación.

Métrica (CV 10-fold)	Resultado	Lectura
Accuracy	70.7%	Fracción total correcta
Balanced accuracy	65.1%	Media del recall de B y M
AUC ROC	0.774	Ordenación B/M fuera de muestra
Precision maligno	66.2%	Predicciones M que son M
Recall maligno	43.4%	Muestras M detectadas
F1 maligno	0.524	Media armónica precisión/recall


El AUC ROC de 0.774 indica que `texture_mean` ofrece una separación moderada entre las dos clases en esta muestra. Con el corte 0,5, el recall de malignos es 43.4%: algunos casos M no se detectan. La matriz de confusión y la curva de la página siguiente ayudan a ver ese intercambio.



Curva ROC calculada con las probabilidades de validación cruzada, no con las del ajuste completo.

3. Confianza asignada a cada muestra

Cada punto es una muestra real: X es su puntuación $z = b_0 + b_1 \cdot \text{texture_mean}$ calculada por el ajuste descriptivo y Y es su diagnóstico observado, exactamente $B=0$ o $M=1$. La curva azul muestra la probabilidad estimada $P(M)=\sigma(z)$, siempre entre 0 y 1. Si $z > 0$ ($P(M) > 0,5$) el modelo predice M ; si $z < 0$ predice B . Las regiones coloreadas muestran esas dos decisiones y sus límites $z=0$, $P(M)=0,5$.




Los puntos son diagnósticos observados, no probabilidades predichas; por eso solo ocupan $y=0$ o $y=1$ y no siguen necesariamente la curva. No se añade jitter. La sigmoide representa el ajuste completo solo para explicar la función; el rendimiento se mide aparte mediante validación cruzada out-of-fold. El corte 0,5 es didáctico, no un umbral clínico.

texture_mean por sí sola deja muchos casos ambiguos y no es un buen clasificador diagnóstico.

4. Salidas, análisis y conclusiones

El CSV contiene sample_id, texture_mean, scores z y probabilidades del ajuste completo y out-of-fold, diagnóstico observado y clase predicha por validación cruzada. La matriz siguiente resume las predicciones CV:

Matriz de confusión - validación cruzada



Cada celda indica el número de muestras y, debajo, el porcentaje dentro de su clase observada.

	Predicho B	Predicho M
Real B	TN 310	FP 47
Real M	FN 120	TP 92

De 212 muestras malignas, el modelo deja 120 como benignas; además, 47 benignas se clasifican como malignas. El predictor único permite explicar el mecanismo de la regresión logística, pero tiene señal limitada y pierde información que está en las otras características.

Conclusiones y límites

La relación entre texture_mean y la etiqueta B/M ofrece un ejemplo visual de clasificación logística con solapamiento entre clases. El conjunto contiene mediciones históricas de una colección concreta, no una muestra clínica universal. El modelo es exclusivamente educativo: no sirve para diagnosticar, descartar cáncer ni orientar decisiones de pacientes. Una aplicación real exigiría datos clínicos adecuados, validación externa, análisis de sesgos y supervisión profesional.

Fuente: Wolberg, Mangasarian, Street y Street (1993), [UCI Breast Cancer Wisconsin \(Diagnostic\)](#), DOI [10.24432/C5DW2B](#), licencia CC BY 4.0. Los datos originales, tabla Orange, scripts, predicciones y métricas acompañan al entregable.