



Big *Data*: Sarrera

Big Data-ren oinarriak, 7 V-ak, biltegitratze-sistemak eta lanbide-rolak.

Zikloa Adimen Artifiziala eta Big Data

Modulua Big Data Sistemak



Big Data: Sarrera

01 Zer da Big Data?

02 Big Data-ren 7 V-ak

03 Analitika motak

04 Biltegitratze Sistemak

05 Datu-biltegitratzeko soluzioak

06 Lanbide-rolak

07 Jarduerak

“

Badirudi denek ahalik eta datu gehienekin lan egin behar dutela, baina teknologia munduan ez da dena Big Data.

01 Zer da Big Data?

— DEFINIZIOA

Big Data

'**Big**' terminoak makina bakarrak ezin kudea ditzakeen datu-kantitate izugarriak adierazten ditu.

Konputazio distribuituak eta **cloud plataformak** behar dituzte: AWS, Azure, Google Cloud.

2020tik aurrera: datuak soilik ez dira nahikoa — **ezagutu eta zaindu** behar dira modu egokian.

Datuak XXI. mendeko **baliabide garrantzitsuena** dira.



Irudi 1 Big Data-ren kontzeptua eta aplikazioak.

02

Big Data-ren 7 V-ak

Big Data-ren 7 V



— THE EVOLVING SPECTRUM OF BIG DATA —

Hasieran 3 V ziren

(Variety, Volume, Velocity).

Geroago beste 4 gehitu

(Value, Veracity, Viability, Visualization).

Irudi 2 7 V-ak Big Data sistema bat deskribatzen duten ezaugarriak dira.

Jatorrizko 3 V-ak

V	EUSKERAZ	AZALPENA
Variety	Aniztasuna	Iturri askotarikoak: egituratuak (DB), erdi-egituratuak (JSON), egitura gabeak (irudiak, audioak)
Volume	Bolumena	TB eskala gainditzen duten datu-kopuruak; ez dira RAM-ean sartzen
Velocity	Abiadura	Denbora errealean edo muga-denboran prozesatzea eta biltzea

Geroago gehitutako 4 V-ak

V	EUSKERAZ	AZALPENA
Value	Balioa	Datuak informazio eta ezagutzara eraldatzea — 'garrantzitsuena datu garrantzitsuak dira'
Veracity	Zehaztasuna	Datuak errealak, errorik gabeak eta fidagarriak direla ziurtatzea
Viability	Bideragarritasuna	Erakundearen gaitasuna datuak modu eraginkorrean erabiltzeko
Visualization	Bistaratzea	Datuak grafikoen, KPlen eta formatu ulergarrien bidez irudikatzea

03

Analitika Motak

Analitika Motak · Konplexutasun Piramidea

Konplexutasuna eta balioa

Deskribatzailea

Zer gertatu zen?

Diagnostikoa

Zergatik gertatu zen?

Prediktiboa

Zer gertatuko da?

Preskriptiboa

Zer egin behar dugu?

Irudi 3 Konplexutasuna eta balioa eskuinetara handitzen dira.

Analitika Python-ekin

```
... analitika.py python

1 import pandas as pd
2
3 df = pd.read_csv("salmentak.csv",
parse_dates=["data"])
4
5 # DESKRIBATZAILEA: zer gertatu zen?
6 df.groupby("produktua")["zenbatekoa"].sum()
7
8 # PREDIKTIBOA: iragarpenak
9 from sklearn.linear_model import LinearRegression
10 modelo = LinearRegression().fit(X, y)
```

DESKRIBATZAILEA

groupby + sum: zein produktuk gehien saldu? Iraganari begira.

PREDIKTIBOA

LinearRegression-ekin datozen hilabeteak iragarri. Datuetatik eredua ikasi.

OHARRA

Kode berdina 4 analitika moten oinarria: aldatzen dena helburua da, ez teknika.

04

Biltegitratze- Sistemak

OLTP · Online Transaction Processing

OLTP


Linean dagoen transakzio-sistema, eragiketak denbora errealean prozesatzeko. Aldi berean transakzio kopuru handia kudeatzen du — txertatu, eguneratu, ezabatu.

Adibideak: MySQL, PostgreSQL, MongoDB.

ACID PROPIETATEAK

Atomikotasuna · Koherentzia · Isolamendua · Iraunkortasuna — transakzio bakoitza osoki exekutatzen da edo ez da exekutatzen.

OLAP · Online Analytical Processing



Irudi 4 OLAP sistemak datu historiko kopuru handiak prozesatzen ditu.

- Datu historiko kopuru handiak prozesatzen ditu
- **Kontsulta konplexu eta multidimentsionalak** — urteak, produktuak, eskualdeak
- Hainbat ikuspuntutatik analisia egiteko aukera
- Erabiltzaileak: negozio-analistak, datuen ingeniariak
- Adibideak: AWS Redshift, Snowflake, Google BigQuery

OLTP vs OLAP · Konparaketa


EZAUGARRIA	OLTP	OLAP
Erabilera-kasuak	Transakzioak	Datu-analisisia
Kontsulta motak	Sinpleak	Konplexuak
Datu motak	Unekoak	Historikoak
Erantzun-denbora	Milisegundoak	Segundoak-min
Profilak	Operadore-langile	Analistak

05

Datu-Biltegiratzeko Soluzioak


Data Warehouse

- **Datu egituratuak soilik** — ****schema-on-write****
- Analitika eta kontsultarako optimizatua (eguneroko CRUD eragiketak OLTP-n egiten dira)
- Analitika batch prozesuetarako
- Abantaila: analisi-denbora murriztu, informazio koherentea
- **Mugak: ez du datu egitura gaberik** — aldatzea zaila
- Soluzioak: AWS Redshift, Snowflake, Google BigQuery



Irudi 5 Enpresako datuak zentralizatzea analisi historikoen bidez balioa lortzeko.

Data Lake



Irudi 6 Datu-multzo handi eta anitzak jatorrizko formatuan gordetzen dituen biltegia.

- **Datu gordinak gordetzen ditu** — JSON, irudiak, audioa, bideo, PDF
- ****Schema-on-read****: forma sartu ostean definitzen da
- Biltegiatzea eskalagarria eta distributua
- On-premise: HDFS (Hadoop)
- Cloud: AWS S3, Azure Blob Storage
- Data Swamp arriskua: antolaketa gabe, erabilgaitza

Data Lakehouse · Bien Onena

Data Lake eta Data Warehouse-ren **abantailak konbinatzen** ditu.

Datu egitura gabeak eta agregatuak onartzen ditu —
malgutasuna.

Eskema sendoak, aldaketa inkrementalak eta datu-
ezabaketak.

Implementazioak: Databricks (Delta Lake), Snowflake.

Data Warehouse-tik hartzen du:

kontsulta optimizatuak, eskema sendoak, ACID propietateak.

Data Lake-tik hartzen du:

datu gordinak gordetzeko gaitasuna, kostu baxua, formato
anitza.

Gaur egungo arkitektura modernoan oinarria — **enpresa**
handiek erabiltzen dute.

06

Lanbide- Rolak

Datuen Munduko Rolak

ROLA	GAITASUNAK	ARDURA NAGUSIA
Datu-analista	SQL, bistaratzea, negozio-ezagutza	Datuak negozio-informazio bihurtu — dashboardak, KPlak
Datu-zientzialaria	IA, estatistika, matematika	Modeloak sortu eta ezarri — iragarpenak, sailkapenak
Datuen ingeniaria	Programazioa, sistemak, cloud	Datu-azpiegitura eraiki eta mantendu — pipeline-ak, ETL
Datu-arkitektoa	Diseinu estrategikoa	Eskalagarritasuna, gobernantza, linea eta segurtasuna

Erabilera-Kasu Errealak

- **Industria 4.0** — IoT sentsoeren datuak denbora errealean prozesatzea fabriketan
- **Streaming plataformak** — Netflix, Spotify: gomendio-motoreak eta nabigazioaren jarraipena
- **Mapa-aplikazioak** — Google Maps: bide-gomendioak trafiko historiko eta unekoan oinarrituta
- **Sare sozialak** — Sentimenduen analisia, eredu sortzaileen entrenamendua, iragarkiak

07

Jarduerak

Big Data Sarrera. Ariketak

MOODLE:

Ariketak: 1.1. Big Data Sarrera

Gaur ikasitakoa · Laburpena

i Big Data ≠ datu asko soilik — distribuzioa, variedad eta abiadura behar ditu

ii 7 V-ak: Variety, Volume, Velocity + Value, Veracity, Viability, Visualization

iii OLTP eta OLAP sistema osagarriak dira: ETL-k konektatzen ditu biak

iv Data Warehouse → egituratua · Data Lake → gordinak · Lakehouse → bien onena

v Datuen ingeniariak azpiegitura eraikitzen du: analisten eta zientzialarien oinarria

ESKERRIK ASKO

Galderak, iruzkinak.

IKASTAROA	01 DATU INGENIARITZA
GAIA	01 · Big Data Sarrera
JARDUERAK	Aula Virtualen entregatu
BALIABIDEAK	mad.firstmark.com · Fundamentals of Data Engineering