



Datuen *Ingeniaritza*

Bizitza-zikloa, biltegiatzea, arkitekturak, irenstea eta datu formatuak

Zikloa Adimen Artifiziala eta Big Data

Modulua Big Data Sistemak



Datuen Ingeniaritza

01 Datuen bizitza-zikloa

02 Biltegiatzea

03 Big Data Arkitekturak

04 Datuen irenstea eta ETL

05 Pentaho

06 Datu formatuak

07 Faker datu sintetikoak

08 Tresnak eta jarduerak

“


Datu gordinak berreskuratzen dituzten eta analitika eta machine learning bezalako erabilera-kasuetarako informazio koherente eta kalitate handiko datuak sortzen dituzten sistemen eta prozesuen garapena, inplementazioa eta mantentzea.

— FUNDAMENTALS OF DATA ENGINEERING · JOE REIS & MATT HOUSLEY

01

Datuen Bizitza-Zikloa


Datu ingeniartzaren bizi-zikloa



Datuen Bizitza-Zikloa

Bizitza-zikloa ez da lineala — iteratiboa da. Datuak sortu eta kontsumitu artean hainbat fase daude, guztiak arlo transbertsalek (segurtasuna, gobernantza) zeharkatzen dituztelarik.

Korronte-azpiak:



Sorrera → Biltegiatzea → [Irenstea, Eraldaketa, Zerbitzatzea] → Kontsumoa.

Bizitza-Zikloaren 3 Fase Nagusiak

01 Sorrera (Generation)

Nork, non, nola eta noiz sortzen diren datuak — analogikoak edo digitalak, fitxategiak, APIak, OLTP datubaseak, logak, IoT gailuak.

02 Biltegitratzea (Storage)

Datuak non eta nola gordetzen diren — HDD/SSD/RAM, datu-base erlazionalak, NoSQL, Data Lake/Warehouse/Lakehouse.

03 Kontsumoa (Serving)


Datuak nori eta nola entregatzen zaizkion — analitika, machine learning, dashboardak, aplikazioak.

02 Biltegiratzea

— HARDWARE FISIKOA

Biltegiratzeko Teknologia Fisikoak

- **HDD (disko magnetikoak)** — 200-300 MB/s · 500 IOPS ·
kostu baxua · artxibo hotzak
- **SSD (disko solidoak)** — hainbat GB/s · hamar milaka IOPS
· aktibo diren datuak
- **RAM** — ~100 GB/s · milioi bat IOPS · SSD baino 1000x
azkarragoa · cache
- **Cloud objektu-biltegiratzea** — S3, Blob Storage ·
eskalagarria · HDD antzeko kostua



Teknologia bakoitzak abiadura/kostu trade-off ezberdinak ditu.

Biltegiratzeko Abstrakzioak

SOLUZIOA	DATU MOTAK	GAITASUN NAGUSIA
Data Warehouse	Egituratuak soilik	OLAP kontsulta optimizatuak — AWS Redshift, Snowflake, BigQuery
Data Lake	Edozein mota — gordinak	Edozein formatu gordetzea — HDFS, AWS S3, Azure Blob Storage
Data Lakehouse	Egituratu + egitura gabe	Bien onena — Delta Lake (Databricks), Apache Iceberg, Snowflake
Cache/RAM	Sarri erabilitakoak	Latentzia minimoa — Redis, Memcached, aplikazio memorian

03

Big Data arkitekturak

Batch ala streaming?

Batch: hasiera eta amaiera duen datu-multzoa, multzoka (adib. gaueko karga). Bolumen handirako; latentzia ez kritikoa.


Streaming: datuak etengabe, iristen diren heinean (adib. iruzur-detekzioa). Latentzia kritikoa.

Pitfall: 'denbora erreala' $\neq$ 'berehalakoa' — tarte txiki batean erantzuten du.

Pitfall: 'streaming' askok barnean **micro-batch** erabiltzen dute.

Batch vs Streaming Prozesatzea

ALDERDIA	BATCH	STREAMING
Definizioa	Datu-multzoak periodikoki	Etengabe, iritsitakoan
Latentzia	Minutuak / Orduak	Segundoak / Milisegundoak
Bolumena	Oso handiak — GB/TB	Gertaera txikiak, jarraian
Adibidea	Hileko nomina, gaueko txostena, ML entrenamendu	Ordainketa iruzurrak, trafiko alertak, IoT sentsores
Tresnak nagusiak	MapReduce, Spark jobs, Python scripts	Kafka, Spark Streaming, Apache Flink, Storm



— LAMBDA ARKITEKTURA

LAMBDA Hiru Geruzen Egitura

- **Batch Geruza** — datu historikoak, aldaezinak, emaitza zehatzak, latentzia altua
- **Speed/Streaming Geruza** — denbora errealekoak, inkrementalak, latentzia baxua
- **Serving Geruza** — bi geruzatako emaitzak konbinatu eta kontsultei erantzun

Irudi 2 Batch + Streaming + Serving geruzak batera.

Lambda Arkitektura · Fluxua Urratsez Urrats

01 Datu berria bikoiztuta bidali

Informazio berria Batch Geruza eta Speed Geruza bietara bidaltzen da aldi berean.

02 Batch Geruzak historikoa kudeatzen du

Datu gordinak aldaezin gordetzen ditu eta periodikoki Batch Views sortzen ditu Serving Geruzarako.

03 Speed Geruzak latentzia konpentsatzen du


Batch-aren eguneraketa tardea betetzen du denbora errealeko ikuspegiak sortuz.

04 Serving Geruzak kontsultak erantzuten ditu

Batch Views eta Real-time Views konbinatuz kontsulten erantzunak eraikitzen dira.

KAPPA

Lau Zutabeak



Irudi 4 Streaming soilik — batch geruza desagertu.


- **Dena stream da** — batch eragiketak streaming-aren azpimultzo dira
- **Datu aldaezinak** — eraldatu gabe gordetzen dira jatorrizkoak
- **Prozesatze-fluxu bakarra** — kode eta mantentzea nabarmen murriztu
- **Berrabiarazte posiblea** — prozesatzea aldatu eta konfigurazioa aldatu emaitzak aldatzeko

Lambda vs Kappa · Konparaketa

ALDERDIA	LAMBDA	KAPPA
Prozesatze-bideak	Bi bide: batch + streaming	Bide bakarra: streaming
Konplexutasuna	Altua — bi sistema mantendu	Baxuagoa — sistema bakarra
Zehaztasuna	Altua (batch emaitzak)	Streaming kalitatearen araberakoa
Datu historikoak	Ondo — batch geruza dago	Berrabiarazte beharrezkoa
Erabilera egokia	ML entrenamendu, analisi osoa batch-ekin	Batch eta streaming algoritmo berdinak direnean

— SCV PRINTZPIOA

SCV printzipioa



- **Speed (S)** — datua jaso eta emaitza sortu arteko denbora
- **Consistency (C)** — emaitzaren zehaztasuna (guztiak vs lagina)
- **Volume (V)** — prozesatu daitekeen datu-kopurua
- **3-tik 2 bakarrik**

SCV · Hiru Trade-off Posibleak

S + C (Gabe V): Zehaztasun altuko emaitzak azkar lortu daitezke, baina datu-bolumen handiak ezin dira prozesatu. Erabilera-kasua: datu-base txiki baten kontsulta azkarra.

C + V (Gabe S): Datu-bolumen handia modu koherentean prozesatu, baina erantzun-denbora luzea. Erabilera-kasua: hileko salmenta-txostena osoa (batch).

V + S (Gabe C): Datu-bolumen handiak azkar prozesatu, baina lagin-teknikak behar dira — emaitza ez da guztiz koherentea. Erabilera-kasua: denbora errealeko sare sozialeko analisia.

Lambda-ren erantzuna: Bi geruza konbinatzeak S+C+V hurbiltzea ahalbidetzen du praktikan — ez perfektua, baina nahikoa.

04

Datuen irenstea eta ETL

Zer da ETL eta zertarako?

Arazoa: datuak iturri askotan daude, formatu eta kalitate desberdinekin — ezin dira zuzenean aztertu.

ETL: **E**xtract (atera) → **T**ransform (garbitu/eraldatu) → **L**oad (helmugan kargatu).

Pipeline: datuak iturritik helmugara eramaten dituen prozesua. ETL pipeline **mota jakin bat** da.

Printzipioa: diseinua negozio-arazotik abiatu, ez teknologiatik.

Datu-Pipeline-a



Iturri batetik informazioa hartu,
garbitu/eraldatu, eta helmuga berri batean
idatzi. Prozesua **iteratiboa** da.

Fase eta teknologia ezberdinez osatuta dagoen prozesu bat da Datu Pipelinea — datuen mugimendua edo prozesatzea definitzen duena.

Beharrezkoak dira datuak sortzen diren sistemetan datu hauek ezin direlako aztertu — **OLTP sistemak** (CRM, ERP) ez dira analitikako karga jasateko pentsatuak.

Prozesatze analitikoa konputazionalki garestia da — sistema bereizituetan egin behar da.

Pipeline-aren 4 Faseak

- **Ingesta** — datuak bildu eta norabait batera bidali
- **Biltegitratzea** — Nonon gorde
- **Prozesatzea** — datuak batch edo streaming teknologiarekin irakurri eta eraldatu
- **Analisia eta Bistaratzeta** — Spark bidez kalkuluak egin; emaitzak MongoDB, S3 edo dashboardetan



Irudi 2 Ingesta → Biltegitratzea → Prozesatzea → Analisia eta Bistaratzeta.


— DATU-PIPELINE · ITERAZIOA

Pipeline-a Prozesu Iteratiboa Da


Prozesua **iteratiboa** da: hipotesia → datuak egiaztatu → falta bada, datu berriak bildu.

Analisi fasean espero den emaitza lortzen ez bada, **ingestara itzuli** datuak lortu edo aldatzeko.

Data Wrangling: datu gordinetik azken egoerara iristeko ekintza guztiak — garbiketa, normalizazioa, eraldaketa.



Irudi 3 Behar diren datuak falta badira, pipeline osotik igaro behar da berriro.



— ETL · FASEAK

ETL: Erauzketa, Eraldaketa eta Karga

Big Data testuinguruan ETL tresnek honako ezaugarriak behar ditu:

1. formato ezberdinekiko malgutasuna (JSON, CSV, Parquet)
2. Eskalagarritasuna
3. Akats-tolerantzia
4. Iturri eta helmuga anizkoitzen konektoreak.

Irudi 4 Iturri anizkoitzeko datuak leku bakarrean biltzeko aukera ematen du.

ETL · Hiru Faseetan Zehar

Extract Transform Load (ETL)

01 Erauzketa (Extract)

Jatorrizko sistemetatik datuak bildu — fitxategi lauak, datu-base erlazionalak, REST APIak, sare sozialak.

Datuak egiazkoak direla egiaztatu. Jatorrizko sisteman inpaktua minimizatu behar da.

02 Eraldaketa (Transform)

Espero den formatua eta edukia lortzeko aldaketak egin — kodeketa-aldaketak, bikoiztuak ezabatu, iturri ezberrinak gurutzatu, adierazleak sortu. Ez du informazio garrantzitsua galdu behar.

03 Karga (Load)

Helmugako sistemara datuak gorde — Data Warehouse edo datu-base mota. Transakzio-denbora minimizatu.

Indizeak, partizioak eta commit tamainak kontuan hartu.


— ELT · FASEAK

ELT: Extract → Load → Transform

E – jatorriari gutxien eragin.

L – gordina kargatu, ezer galdu gabe (data lake-an, dagoen-dagoenean).

T – helmugan bertan hobetu, ez asmatu informazio berririk (indizeak, partizioak, formatuak hor sortzen dira).



ELT · ETL-ren Bilakaera

Extract Load Transform (ELT)

ELT

Erauzketa, Karga eta Eraldaketa — siglak ordenan aldatzen ditu. Iturri anizkoitzeko datuak eraldatu gabe zuzenean Data Lake edo hodeiko biltegitratze-sistemara kargatzen dira. Handik, datuak negozio-helburu ezberdinen arabera eraldatzen dira.

ZERGATIK ELT NAGUSITU DA?

Cloud-eko biltegitratze merkea + prozesatze-potentzia handiak ELT-ri abantaila eman dio: datuak berehala eskuragarri daude eta analisten eskuetan uzten da eraldaketa — ez soilik ingeniarietan.

ETL vs ELT

	ETL (TRADIZIONALA)	ELT (MODERNOA)
Eraldaketa	Kargatu AURRETIK	Kargatu OSTEAN (lake-n)
Nork	Ingeniariek, zentralizatua	Analistek SQL/Python
Datuak noiz prest	Eraldaketa amaitzean	Berehala (gordin)
Big Data-n	Gutxiago	Gehiago — merkeagoa

ETL Tresnen Ekosistema

- **Pentaho Data Integration (PDI)** — bisual, kode-gabekoa, hurrengko saioan
- **Talend Open Studio** — irekia, enpresa-inguruneetarako
- **Apache Airflow** — orkestrazioa Python DAGekin (egungo joera)
- **dbt (data build tool)** — ELT-rako SQL eraldaketak bertsio-kontrolekin
- **Pandas / PySpark / DuckDB** — Python-eko ikuspegi hibridoa pipeline berrietan



Irudi 5 ETL tresnak eraldaketa konplexutasunaren arabera sailkatzen dira.

ETL praktikan: Pandas eta DuckDB

```
●●● etl_duckdb.py python

1 | # DuckDB - SQL fitxategien gainean, zerbitzaririk
  | gabe
2 | import duckdb
3 | duckdb.sql("""
4 |     SELECT p.*, f.Manufacturer
5 |     FROM read_csv('pdi_product.csv') p
6 |     LEFT JOIN read_csv('pdi_manufacturer.csv') f
7 |     ON p.ManufacturerID = f.ManufacturerID
8 |     WHERE p.Category = 'Mix'
9 | """).to_df()
```

DUCKDB

"SQL fitxategien gainean", zerbitzaririk gabe; barnean Apache Arrow (oso azkarra).

E / T / L

read_csv (E) · JOIN + WHERE (T) · to_df / gorde (L).


SQL NAHIKOA

SQL dakienak ETL bat idatz dezake, Pandas ikasi gabe.

— INGESTA ESTRATEGIAK

Push, Pull, Poll


- **Push** — jatorriak helmugara bidaltzen du
- **Pull** — helmugak jatorritik hartzen du
- **Poll** — helmugak aldizka egiaztatzen du; aldaketa → pull
- 4 parametro: abiadura, tamaina, maiztasuna, formatua



— INGESTA TRESNAK

Datuen Irensterako Tresnen Sailkapena


- **ETL tresnak** — Sqoop (HDFS↔SQL), Flume (streaming egitura gabea), NiFi (bisual)
- **Mezularitza-sistemak** — Kafka, RabbitMQ, AWS Kinesis, Azure Event Hubs, GCP Pub/Sub
- **Datu-konektoreak** — Fivetran (300+ konektore), Airbyte (irekia, ELT)
- **Log ingesta** — Elastic Logstash (Elasticsearch-erako, hurrengoko gaian)



Irudi 11 ETL tresnak, mezularitza-sistemak eta datu-konektoreak.

05 Pentaho


Pentaho (PDI) — ETL bisuala



— PENTAHO · PITFALL

Ordenatu lehenik!

- Merge Join eta Group By → BETI Sort aurretik
- Gako berberaren bidez ordenatu bi fluxuak
- Ordenatzea ahaztea = akatsik ohikoena
- Spoon-ek abisatu ere egiten du



06

Datu formatuak

Zertarako datu-formatu bereziak?

Arazoa: CSV erraza da, baina **handia eta motela** datu-masa handietan; zutabe bat irakurtzeko, dena irakurri behar du.

Ideia: formatu trinko eta azkarrak (binarioak, zutabe-orientatuak) erabili.

Zertarako: **lekua aurreztu** (konpresioa) eta **kontsultak azkartu** (behar diren zutabeak soilik irakurri).

Parquet, Avro, ORC — formatu nagusiak Big Data-n.

Errenkada vs Zutabe

Row storage		Column storage	
Row 1	1	user_id	1
	US		2
	Free		3
Row 2	2	country	US
	UK		UK
	Paid		ES
Row 3	3	subscription_type	Free
	ES		Paid
	Paid		Paid

- **Errenkada (CSV, Avro)** — erregistro osoa elkarrekin → OLTP
- **Zutabe (Parquet, ORC)** — zutabea elkarrekin → OLAP
- Zutabe: konpresio hobe (mota bereko datuak)
- Zutabe: behar diren zutabeak soilik irakurri (I/O ↓)

DATO

\$5/ TB

Athena-k eskaneatutako TB bakoitzeko

Formatuak DIRUA
aurrezten du

1 TB CSV → **130 GB Parquet**. 4 zutabetik 1 behar
baduzu: CSV-k 4ak irakurtzen ditu; **Parquet-ek 1
soilik** → kostua ~%75 jaitsi.

Formatu nagusiak

Avro (Kafka, eskema-eboluzioa) · **Parquet** (Spark, Athena, biltegi luzea) · **ORC** (Hive) · **Arrow/Feather** (RAM, prozesu artean).


user_id	country	subscription_type
1	US	Free
2	UK	Paid
3	ES	Paid

Tamaina erreala — Alemania salmentak

FITXATEGIA	TAMAINA
ger_sales.csv	9.7 MiB
ger_sales.avro	6.9 MiB
ger_sales.parquet	2.3 MiB
ger_sales-gzip.parquet	1.6 MiB

Parquet barnetik

- Zutabe-formatua, auto-deskribatzailea (eskema barnean)
- Row groups + zutabe-chunk-ak + footer (metadatuak)
- Snappy/gzip konpresioarekin %75eraino
- Behar diren zutabeak soilik irakurtzen ditu



06

Faker datu sintetikoak

— TRESNA LAGUNTZAILEA

Faker — datu sintetikoak

- Artifizialki datuak sortzeko liburutegia
- Erabilera: proba/garapena, pribatutasuna
- **Faker.seed(42)** — erreproduzigarritasuna (gakoa!)
- Beste moduluetak ariketetarako datuak sortzeko

07

Tresnak eta jarduerak

BIG DATA ARKITEKTURAK

Lambda, Kappa eta SCV · Galderak

1. Lambda arkitekturan, nola lortzen du Speed Geruzak Batch Geruzak baino informazio azkarrago erakustea? Zer kostu dago abiaduraren truke?
2. Batch eta streaming prozesatzearen arteko desberdintasunak azaldu datu-bolumen eta denborari dagokienez.
3. Zergatik da Spark gaur egun batch eta streaming bietarako tresna nagusia?
4. IoT sistemetan segundoka datu asko bidaltzen dira. SCV-rekin nola konpontzen da koherentzia?

ENTREGA

- **4 galderaren erantzunak idatziz** — justifikatu

DATUEN IRENSTEA ETA ETL ETL, ELT eta Pipeline Galderak

Erantzun justifikatuz:

ENTREGA

■ **4 galderaren erantzunak idatziz** — justifikazioarekin

1. Datuen pipeline bat diseinatzerakoan, zein da kontuan hartu beharreko lehen urratsa?
2. Zer erlazio dago datu-pipeline eta ETL artean?
3. ETL eta ELT gauza bera al dira? Noiz egiten da bakoitza?
4. Big Data testuinguruan, zein da nagusi (ETL ala ELT)?

Zergatik?

DATUEN IRENSTEA ETA ETL

ETL Adibidea · Pandas eta DuckDB

ETL adibidea jarraituz, egizu prozesu bera baina produktuak salmenten fitxategiarekin lotuz (pdi_product.csv + pdi_sales.csv).

Emaitzak CSV fitxategi bat izan behar du:

kategoria jakin bateko produktuak + fabrikatzailearen izena + produktu bakoitzaren saldutako kantitate totala.

Bi inplementazio: Pandas eta DuckDB.

ENTREGA

- generaCSV_pandas.py fitxategia
- generaCSV_duckdb.py fitxategia
- Emaitzako CSV fitxategia

ESKERRIK ASKO

Galderak, iruzkinak.