

Apache *NiFi*

Datu-fluxuen ingestioa eta eraldaketa: FlowFile-ak, prozesadoreak, iragazketa, linaje-jarraipena eta MongoDB iraunkortasuna.

Zikloa Adimen Artifiziala eta Big Data

Modulua Big Data Aplikatua



01 DATAFLOW. Apache NiFi

01	Sarrera — Apache NiFi eta dataflow programazioa
02	Kontzeptu nagusiak — FlowFile, prozesadorea, ilara, linajea
03	Instalazioa — Docker bidez
04	1. kasua — fitxategiak GetFile/PutFile + gatazka-kudeaketa

05	2. kasua — CSV iragazketa SplitRecord + QueryRecord
06	3. kasua — atributuak ExtractText + linajea + PutHDFS
07	4. kasua — HTTP→MongoDB pipeline osoa
08	Prozesadore nagusien kategoriak eta jarduerak

00

DataFlow: datua mugimenduan

Datua geldirik vs mugimenduan


Big Data Sistemak: datua geldirik (*at rest*) — fitxategi bat, taula bat, lakua.

Hemen: datua mugimenduan (*in motion*) — etengabe sortzen ari da, iristen den heinean prozesatu.

Sentsoreak, transakzioak, klik-fluxuak: ez dago **amaierarik** zain egoteko.

Modulu hau bizitza-zikloaren **mugitu/eraldatu** fasea da, streaming ikuspegitik.

Pipeline baten lau rol



01

Apache NiFi sarrera

Apache NiFi

Apache NiFi NSAk jatorriz garatutako Apache proiektua, datu-fluxuen (dataflow) programazioan oinarrituta DATUEN INGESTIOA eta ERALDAKETA egiteko. Aplikazioak prozesu-grafo ZUZENDU AZIKLIKOAK (DAG) moduan definitzen dira, eta mezuak predefinitutako konexioen bidez trukutzen dituzte.

**FILOSOFIA
NAGUSIA**

ARRASTATU-ASKATU bidez egiten dira pipeline-ak — kode-lerro bakar bat ere ez. NiFi-ren motor grafikoak automatikoki bideratzen ditu datuak.

Ezaugarri nagusiak eta erabilera egokia

- **300+ KONEKTORE** — datu-fluxu eskalagarriak protokolo anitzentzat
- **DATU-GALERARIK GABEKO** entrega bermea (back-pressure, diskoko persistentzia)
- **ARRASTATU-ASKATU** interfaze grafikoa (web, plataforma anitzeko)
- **KLUSTER** bidezko eskalagarritasun horizontala
- **DATUEN LINAJEA** — jatorritik uneko egoerara arteko eraldaketak jarraituz
- **Erabilera EGOKIA**: sistemen arteko transferentziak, datu-aberastea, baldintzapeko bideraketa, formatu-bihurketak

02

Kontzeptu nagusia

FlowFile (FF)

FlowFile

NiFi-ren OINARRIZKO datu-unitatea, DISKOAN iraunkortua. Bi atal ditu: EDUKIA (benetako datuak — fitxategi-bytea, JSON, lerro bat...) eta ATRIBUTUAK (metadatu gako-balio bikoteak: UUID, timestamp, tamaina, filename...).

PERTSONA-
FITXATEGI
GISA

FF bat = inprimaki bat. Edukia INPRIMAKIAREN ATALAK; atributuak inguruko POSTAL ETIKETAK (bidalitako data, tamaina, bidaltzailea...).

Prozesadorea — eraldaketa-unitatea

- DATUETAN ERALDAKETA edo ARAU bat exekutatzeko ardura duen osagaia
- EXEKUZIO-HARI PARALELOEN bidez funtzionatzen du (eskala-handian)
- SARRERAKO FF-ETATIK IRTEERA BERRIAK sortzen ditu
- NiFi-k 300+ PROZESADORE INTEGRATUAK eskaintzen ditu
- PERTSONALIZATUAK ere sor daitezke (Java/Groovy script)

Konektorea — ilara prozesadoreen artean

- Prozesadoreen IRTEERA hurrengoaren SARRERAREKIN lotzen duen ILARA ZUZENDUA
- Konexio motaren arabera ETIKETATUA: success / failure / matched / unmatched...
- FF KOPURUA aldi berean konfiguragarria (back-pressure)
- Irteerako LEHENTASUNA doitu daiteke (FIFO / LIFO / pertsonalizatua)
- FF-en ITXAROTE-DENBORA muga (file age) konfiguratu daiteke

— DEFINIZIOA

Datuen Linajea (Data Provenance)

Data Provenance

JATORRITIK uneko egoerara arteko ERALDAKETA-HISTORIA OSOA. Kalitate-bermea eta gobernantza-betapena ahalbidetzeko ikusgarritasuna eskaintzen du — FF bakoitzaren BIDAIA OSOA ikusteko aukera emanez.

AUDITORETZA 'Nondik dator datu hau eta zer eraldaketa jasan du?' galderari erantzun.

03 Instalazioa

Docker bidez — komando bakar batean

```
... install-nifi.sh bash

1 # Apache NiFi-aren ofizialeko Docker irudia abiarazi
2 docker run --name nifi \
3     -p 8443:8443 -d \
4     -e SINGLE_USER_CREDENTIALS_USERNAME=nifi \
5     -e SINGLE_USER_CREDENTIALS_PASSWORD=nifinifinifi \
6     -e NIFI_JVM_HEAP_MAX=2g \
7     -v "C:\nifi\ariketak:/opt/nifi/ariketak" \
8     apache/nifi:latest
9
10 # Atzitzeko nabigatzailean:
11 #   https://localhost:8443/nifi
12 #
13 # Erabiltzailea: nifi
14 # Pasahitza:   nifinifinifi
15 #
16 # OHARRA: HTTPS lehenetsia da (ez HTTP) – autosinatutako ziurtagiriak, beraz nabigatzaileak abisua botaz
17 pasatu behar da'.
```

04

1. Kasua — Fitxategiak mugitu


— 1. KASUA

Fluxu osoa — GetFile → PutFile

- **GETFILE prozesadorea** — sarrera-karpetatik fitxategiak irakurri eta KENDU
- **PUTFILE prozesadorea** — irteera-karpetan idatzi

Gatazkak kudeatzeko (izen bereko fitxategiak):

- **UPDATEATTRIBUTE** — gatazketarako (timestamp-aurrizki berrikuntza)
- Bigarren **PUTFILE prozesadoreak** 'gatazkak' karpetan biltzen ditu *failure*-erako bideratutako fitxategiak



— GETFILE

GetFile — properties

- **INPUT DIRECTORY** — sarrera-karpeta absolutua.
adib: `/opt/nifi/ariketak/01-ariketa-getfile-putfile/sarrera`
- **KEEP SOURCE FILE** — **false** (lehenetsia): fitxategiak KENDU jatorriko karpetatik prozesatu ondoren
- **FILE FILTER** — regex (`.*` lehenetsia, fitxategi guztiak)
- **MINIMUM FILE AGE** — fitxategiek behar duten gutxieneko adina prozesatzeko (erdizka idaztea saihestu)

Edit Processor GetFile 2.11.0	
Settings	Scheduling
Properties	
Required field +	
Property	Value
Input Directory	<i>i</i> /opt/nifi/ariketak/01-ariketa-getfile-p...
File Filter	<i>i</i> [^\.]*
Path Filter	<i>i</i> No value set
Batch Size	<i>i</i> 10
Keep Source File	<i>i</i> false
Recurse Subdirectories	<i>i</i> true
Polling Interval	<i>i</i> 30 sec
Ignore Hidden Files	<i>i</i> true
Minimum File Age	<i>i</i> 2 sec
Maximum File Age	<i>i</i> No value set

— PUTFILE

PutFile — properties + auto- terminate

- **DIRECTORY** — helmuga-karpeta absolutua.
adib: `/opt/nifi/ariketak/01-ariketa-getfile-putfile/irteera`
- **CONFLICT RESOLUTION STRATEGY** — REPLACE, IGNORE, FAIL (lehenetsia)
- **AUTO-TERMINATE** — *success* eta *failure* 'amaituta' (terminate) markatu konexiorik gabe nahi dugun harremanetan
- Hutsago utziz, prozesadoreak 'invalid' egoeran geratuko dira

Edit Processor | PutFile 2.11.0

Settings

Scheduling

Properties

Required field



Property	Value
Directory	/opt/nifi/ariketak/01-ariketa-getfile-put...
Conflict Resolution Strategy	fail
Create Missing Directories	true
Maximum File Count	No value set
Last Modified Time	No value set
Permissions	No value set
Owner	No value set
Group	No value set

Edit Processor | PutFile 2.11.0

Settings

Scheduling

Properties

Relationships

Automatically Terminate/Retry Relationships

failure

☐ terminate ☐ retry

Files that could not be written to the output directory for some reason are transferred to this relationship

success

☒ terminate ☐ retry

Files that have been successfully written to the output directory are transferred to this relationship

— UPDATEATTRIBUTE

UpdateAttribute — gatazkak kudeatzeko

Edit Processor | UpdateAttribute 2.11.0

Settings

Scheduling

Properties

Required field +


Property	Value
Delete Attributes Expression	<i>No value set</i>
Store State	Do not store state
Stateful Variables Initial Value	<i>No value set</i>
Cache Value Lookup Cache Size	100
filename	<code>\${now():toNumber()}-\${filename}</code>

- **Propietate berria sortu** — adib. 'filename'
- Balio dinamikoa Expression Language-rekin:
`${now():toNumber()}-${filename}`
- Emaiza: filename = 1715942314000-original.txt (timestamp aurrizkia + jatorrizko izena)
- PutFile-ean konfliktua (failure) egonez gero, izen berriak ekiditen du gainidazketa

— KONFLIKTUAK

Fluxu osoa — gatazketan

- GetFile → PutFile #1 (success ohikoa) → amaiera arrunta
- PutFile #1 'failure' → UpdateAttribute (filename berriztu)
- UpdateAttribute → PutFile #2 (gatazka-karpeta)
- **Datu-galerarik EZ** — fitxategi guztiak helmugaren batean kokatzen dira



05

2. Kasua — CSV iragazi

Sarrerako CSV — formatua eta adibidea


```
●●● ventas.csv text

1 ProductID;Date;Zip;Units;Revenue;Country
2 725;1/15/1999;41540;1;115.5;Germany
3 850;2/03/1999;75000;3;245.0;France
4 425;3/21/1999;28013;1;87.25;Spain
5 725;4/12/1999;75008;5;577.5;France
6 910;5/05/1999;10115;2;230.0;Germany
7 850;6/30/1999;69001;4;392.0;France
8
9 # Iragazketaren xedea:
10 #   Country = 'France' ETA Units > 1
11 # Helburua: Frantziako salmentak unitate bat baino gehiago
12 # duten erregistroak SOILIK pasatzea.
13
14 # Bereizlea: ; (puntu eta koma) — ohikoa Europar formatuan
15 # Lehen lerroa: GOIBURUA (zutabe-izenak)
```

— SPLITRECORD

SplitRecord — CSV banatu

- **RECORD READER** — CSVReader (Controller Service): ';' bereizlea, lehen lerroa GOIBURU
- **RECORD WRITER** — CSVRecordSetWriter
- **RECORDS PER SPLIT** — 1 (errenkada bakoitza FF independente)
- **Eraitza: CSV-eko erregistro bakoitzaren ARABERA FF berri bat** — 'splits' konexioan ateratzen dira



QueryRecord — SQL iragazketa CSV-an

... queryrecord.sql

sql


```
1 -- QueryRecord propietate pertsonalizatua: FrantziaGehiago1
2 -- Propietatearen IZENA bilakatzen da irteera-harreman berri
3 -- (output relationship) – konexio berri bat sortu daiteke.
4
5 select *
6 from FLOWFILE
7 where Country = 'France'
8    and Units > 1;
9
10 -- 'FLOWFILE' Apache Calcite-ren konbentzio berezia da
11 -- NiFi-an: uneko FF-aren edukia datu-iturri gisa erabiltzen.
12 --
13 -- INCLUDE ZERO RECORD FLOWFILES = false
14 -- → emaitzarik gabeko kontsultek ez dute FF-rik sortzen
15 -- (ilarak garbi mantentzeko)
16 --
17 -- Beste prozesadoreak ere izan dezakete propietate
18 -- pertsonalizatuak: ROUTEONATTRIBUTE adibidez, kondiziodun
19 -- bideraketa egiteko.
```

FrantziaGehiago1 SQL kontsulta: **SELECT * FROM FLOWFILE WHERE COUNTRY = 'France' and Units > 1**

— 2. KASUA

Fluxu osoa —
GetFile → SplitRecord →
QueryRecord →
UpdateAttribute → PutFile

- **GetFile** — sarrera-karpetatik CSV irakurri
- **SplitRecord** — CSV erregistro bakoitza FF independente
- **QueryRecord** — SQL iragazketa (Country='France' AND Units>1)
- **UpdateAttribute** — izen bereko fitxategiekin gatazka kudeatzeko
- **PutFile** — Frantziako salmenta-erregistroak helmugara



2. KASUAREN ALDAERAK:

2. aldaera: SplitRecord 10 errenkadako taldeetan

- **ARAZOA:** SplitRecord-ek FF-asko sortzen ditu (CSV-ko errenkada bakoitzeko bat) — memoria-zama handia
- **SOLUZIO POSIBLEA:** SplitRecord 10 errenkadako taldeetan (FF bat 10 errenkadako)

3. aldaera: SplitRecord saihestu (optimizazioa)

- **ARAZOA:** SplitRecord-ek FF-asko sortzen ditu (CSV-ko errenkada bakoitzeko bat) — memoria-zama handia
- **SOLUZIOA:** GetFile zuzenean QueryRecord-era konektatu — SQL fitxategi OSOAREN gainean exekutatzen da
- **QueryRecord-ek BARNETIK aplikatzen du iragazketa Calcite motorrarekin** — banaketa beharrik gabe
- **Eraitza:** FF KOPURUA murriztu, errendimendua hobetu, memoria-erabilera txikiagoa

06

3. Kasua — Atributuetak eta Linajea

Edit Processor | GenerateFlowFile 2.11.0

SettingsSchedulingProperties

Required field

Property	Value
File Size	i 10B
Batch Size	i 1
Data Format	i Text
Unique FlowFiles	i true
Custom Text	i No value set
Character Set	i UTF-8
Mime Type	i No value set

Edit Processor | GenerateFlowFile 2.11.0

SettingsSchedulingProperti

Scheduling Strategy i*

Timer driven

Concurrent Tasks i*

1

Run Schedule i*

3 min

Execution i*

All nodes

— GENERATEFLOWFILE


GenerateFlowFile — proba-FF sortu

- **FLOW SIZE** — '10 bytes' (sortzen den edukiaren tamaina)
- **BATCH SIZE** — 1 (FF kopurua exekuzio bakoitzeko)
- **DATA FORMAT** — Text (Binary edo Text)
- **UNIQUE FLOWFILES** — true: FF bakoitza ezberdina (UUID-unikoa eduki gisa)
- **RUN SCHEDULE** — '3s' (3 segunduro berriz exekutatu)

— REPLACETEXT


ReplaceText — edukia ordeztu

- **REPLACEMENT STRATEGY** — 'Always Replace' (eduki guztia berridatzi)
Beste estrategiak: 'Regex Replace', 'Literal Replace', 'Append', 'Prepend'
- **REPLACEMENT VALUE** — testua, adib. 'proba' edo Expression
Language: `${now()}`
- **AUTO-TERMINATE failure** — konektatu ez dugun harremana amaitu



— EXTRACTTEXT

ExtractText — edukitik atributura




- **PROPIETATE BERRIA** — adib. 'edukia' (atributu-izena)
- **REGEX BALIOA** — adib. '.*' (eduki guztia atxikitzen)
- **INCLUDE CAPTURE GROUP 0:** false
- FF-aren EDUKIA HARTU eta atributu BERRI batean ipini
- Konexioa: 'matched' (erregistroak parekoa egin denean) vs 'unmatched'

— LOGATTRIBUTE

LogAttribute — atributuak nifi-app.log-en


- FF-aren ATRIBUTU GUZTIAK NiFi-aren log-fitxategian idazten ditu
- **LOG LEVEL** — INFO, DEBUG, WARN, ERROR (gomendatua INFO)
- Output: '/opt/nifi/logs/nifi-app.log' (Docker) edo '\$NIFI_HOME/logs/'
- **TESTING ETA DEBUGGING-RAKO IDEALA** — pipeline-aren egoera monitorizatzeko



— PUTFILE

PutFile — Fitxategian gorde

- **DIRECTORY** — helmuga-karpeta absolutua.
adib: `/opt/nifi/ariketak/03-ariketa-atributuak-linajea/irteera`
- Eraldaketak: jatorrizko fitxategi-izena mantentzen du (filename atributuaren araberakoa)




-
- The screenshot displays the Apache NiFi web interface. At the top, there is a toolbar with various icons for navigation and operations. Below the toolbar, a status bar shows the time as 08:57:06 UTC and the user as nifi. The main area is divided into a left sidebar and a central workspace. The sidebar contains a 'Navigate' section with a plus icon and an 'Operate' section with a minus icon. Below these, there is a section for 'Caso 2' (Process Group) with a unique ID and a set of icons for actions like edit, delete, and refresh. The central workspace shows a data flow diagram with four nodes: 'GenerateFlowFile', 'LogAttribute', 'ReplaceText', and 'ExtractText'. The flow is as follows: 'GenerateFlowFile' (In: 0 (0 bytes), Read/Write: 0 bytes / 110 bytes, Out: 11 (110 bytes), Tasks/Time: 11 / 00:00:00.187) connects to 'LogAttribute' (In: 11 (80 bytes), Read/Write: 0 bytes / 0 bytes, Out: 0 (0 bytes), Tasks/Time: 11 / 00:00:00.092) via a connector labeled 'Name success' and 'Queued 0 (0 bytes)'. 'LogAttribute' connects to 'ReplaceText' (In: 11 (110 bytes), Read/Write: 110 bytes / 80 bytes, Out: 11 (80 bytes), Tasks/Time: 11 / 00:00:00.053) via a connector labeled 'Name success' and 'Queued 0 (0 bytes)'. 'ReplaceText' connects to 'ExtractText' (In: 11 (80 bytes), Read/Write: 80 bytes / 0 bytes, Out: 11 (80 bytes), Tasks/Time: 11 / 00:00:00.037) via a connector labeled 'Name success' and 'Queued 0 (0 bytes)'. The 'LogAttribute' node has a mouse cursor hovering over it.

— 3. KASUA

Fluxu osoa — Generate → Replace → Extract → Log → File

- **GenerateFlowFile** — 3 segunduro FF berri bat sortu
- **ReplaceText** — edukia 'proba' bilakatu
- **ExtractText** — edukia 'edukia' atributura eraman
- **LogAttribute** — atributuak nifi-app.log-en idatzi
- **PutFile** — /opt/nifi/ariketak... karpetan gorde



07

4. Kasua — MongoDB

ListenHTTP — HTTP POST endpoint bilakatu

- **LISTENING PORT** — 8081 (NiFi-aren beste portu bat, ez 8443)
- **BASE PATH** — 'iabd' (URL-aren atal aldakorra)
- Endpoint osoa: `http://localhost:8081/iabd`
- Proba: `'curl --data "testua" http://localhost:8081/iabd'`
- POST eskaera bakoitzak FF berri bat sortzen du, edukia HTTP body-arekin

RouteOnContent — edukiaren arabera bideratu

- **MATCH REQUIREMENT** — 'content must contain match' (edukian agertzen da)
- **Propietate berria 'errorTestua'** — regex pattern, adib. 'ERROR'
- Irteera-harremanak: 'errorTestua' (parekoak) eta 'unmatched' (besteak)
- **Edukian arakatu eta dagokion bideari bidali** — log-iragazketa edo errore-detekziorako oso erabilgarria

Configure Processor | RouteOnContent 1.15.0

Stopped

SETTINGS | SCHEDULING | **PROPERTIES** | COMMENTS


Required field 🔍 +

Property		Value	
Match Requirement	🔍	content must contain match	
Character Set	🔍	UTF-8	
Content Buffer Size	🔍	1 MB	
textoError	🔍	ERROR	🗑️

— MERGECONTENT

MergeContent — FF anitz batu

- **MERGE STRATEGY** — 'Bin-Packing Algorithm' (banaketako FF-ak batuketan)
- **MERGE FORMAT** — 'Binary Concatenation' (edukia katenatu)
- **CORRELATION ATTRIBUTE NAME** — RouteOnContent.Route (bide bereko FF-ak batera batu)
- **MAXIMUM NUMBER OF ENTRIES** — 1000 + MAXIMUM BIN AGE — 300s (emaitza-tarte mugak)
- **RUN SCHEDULE** — 30s (maiztasunez baluerak kalkulatzeko)



— UPDATEATTRIBUTE

ExtractText + UpdateAttribute — metadatuak gehitu

- **ExtractText**-en bidez edukia atributura eraman ondoren:
- Propietate berria 'egoera' = `${RouteOnContent.Route}`
- Atributuetan METADATUAK gehitzen ditugu, MongoDB-an JSON dokumentu aberatsa sortzeko
- **`${variable}` Expression Language** — beste atributu baten balioa hartu

Configure Processor | UpdateAttribute 1.15.0

Stopped

SETTINGS SCHEDULING PROPERTIES COMMENTS

Required field

Property		Value	
Delete Attributes Expression	?	No value set	
Store State	?	Do not store state	
Stateful Variables Initial Value	?	No value set	
Cache Value Lookup Cache Size	?	100	
estado	?	<code>\${RouteOnContent.Route}</code>	

— ATTRIBUTESTOJSON

AttributesToJSON — MongoDB dokumentu

- **ATTRIBUTE LIST** — atributu-zerrenda komaz banatuta, adib. 'edukia,egoera'
- **DESTINATION** — 'flowfile-content' (JSON edukia ordeztuko du)
- Beste aukera: 'flowfile-attribute' (JSON atributu berri batean)
- PutMongo prozesadoreak FF edukia JSON gisa interpretatzen du

Configure Processor | AttributesToJSON 1.15.0

Stopped

SETTINGS | SCHEDULING | **PROPERTIES** | COMMENTS

Required field

Property	Value
Attributes List	contenido,estado
Attributes Regular Expression	No value set
Destination	flowfile-content
Include Core Attributes	false
Null Value	false

— 4. KASUA

Proba egin — curl bidez eta MongoDB-n egiaztatu


```
... proba.sh bash

1 # 1) curl bidez HTTP POST egin NiFi-ari
2 curl --data "testua proba bat" http://localhost:8081/iabd
3
4 # Errore-mezua probatzeko:
5 curl --data "ERROR mezua simulatuta" http://localhost:8081/iabd
6
7 # 2) MongoDB-an egiaztatu mezuak iritsi direla
8 # mongosh shell-etik:
9 #   use iabd
10 #   db["4kasua"].find()
11 #   db["4kasua"].find({egoera: "errorTestua"})
12 #   db["4kasua"].countDocuments({})
13
14 # Emaita-eredu MongoDB-an:
15 #   { _id: ObjectId("..."),
16 #     edukia: "testua proba bat",
17 #     egoera: "unmatched" }
18 #   { _id: ObjectId("..."),
19 #     edukia: "ERROR mezua simulatuta",
20 #     egoera: "errorTestua" }
```

— 4. KASUA

Fluxu osoa —
Listen → Route → Merge →
Extract → JSON → Mongo

- **ListenHTTP** — HTTP POST eskaerak jaso (8081 portuan)
- **RouteOnContent** — edukiaren arabera bideratu ('ERROR' vs besteak)
- **MergeContent** — bide bereko FF-ak batera batu (correlation attribute)
- **ExtractText + UpdateAttribute** — atributuak prestatu
- **AttributesToJSON** — atributu-zerrenda JSON bilakatu
- **PutMongo** — MongoDB 'iabd.4kasua' bilduman gorde



08

Prozesadore nagusiak

Prozesadore-kategoriak — funtzio eta adibideak

KATEGORIA	PROZESADOREAK
Datuen eraldaketa	ReplaceText, JoltTransformJSON, CompressContent
Bideraketa	RouteOnAttribute, RouteOnContent
Datu-baseak	ExecuteSQL, ConvertJSONToSQL, PutSQL
Atributuen erauzketa	EvaluateJsonPath, ExtractText, UpdateAttribute
Sistema-elkarrekintza	ExecuteProcess (SO komandoak)
Datuak eskuratu	GetFile, GetFTP, GetHTTP, GetHDFS

Prozesadore-kategoriak — funtzio eta adibideak

KATEGORIA	PROZESADOREAK
Datuak bidali	PutEmail, PutFile, PutFTP, PutKafka, PutMongo
Zatitu / Batu	SplitText, SplitJson, SplitXml, MergeContent
HTTP eragiketak	GetHTTP, ListenHTTP, PostHTTP
AWS zerbitzuak	FetchS3Object, PutS3Object, PutSNS, PutSQS

09

Jarduerak

1. kasua — fitxategiak mugitu

EGOERA

1. kasua osatua eraiki: GetFile→PutFile, izen pertsonalarekin etiketatuta. Kaptura egin, ilara ikusgai erakutsi, eta fluxuaren JSON definizio-fitxategia deskargatu.

Helburua: NiFi GUI-aren oinarrizko erabilera.

EGINKIZUNAK

- GetFile + PutFile fluxua sortu izen pertsonalarekin
- Fluxuaren kaptura, etiketa argi ikusgai
- Hasierako irakurketa eta transferentzia bitarteko etaparen ilara erakutsi
- Fluxuaren definizio-fitxategia (JSON) deskargatu

2. kasua — CSV iragazketa aldaerekin

EGOERA

2. kasua exekutatu eta hiru aldaeren artean alderaketa:

- 1. aldaera: jatorrizkoa (SplitRecord+QueryRecord)
- 2. aldaera: SplitRecord 10 errenkadako taldeetan
- 3. aldaera: SplitRecord gabe (zuzenean QueryRecord).

Hiru aldaeren JSON definizio-fitxategiak. Helburua: optimizazio-eraginaren behaketa.

EGINKIZUNAK

- **Jatorrizko exekuzioa (Records per Split=1)** — emailzak eta FF kopurua
- **Bigarren aldaera: SplitRecord 10 errenkadako taldeekin** — alderaketa
- Hirugarren aldaera: GetFile → QueryRecord zuzenean (SplitRecord gabe)
- Hiru aldaeren JSON definizio-fitxategi bana

3. kasua aldagetarekin + MongoDB

EGOERA

3. kasuaren aldaera: GenerateFlowFile prozesadoreak FlowFile bat sortuko du 5 segunduro. ReplaceText-ek aurreko edukia mantenduko du eta `[[[ Data: ${now()} ]]]` testua gehituko dio (Append). Ondoren, ExtractText+LogAttribute erabiliz atributuak logean erregistratuko ditu. Azkenik, AttributesToJSON erabiliz *datuak* atributua JSON dokumentu bihurtuko du eta PutMongo erabiliz MongoDB datu-basean gordeko du.

Helburua: pipeline pertsonalizatua + MongoDB integrazioa.

EGINKIZUNAK

- GenerateFlowFile 'Run Schedule' = 5s
- ReplaceText Append estrategiarekin: `'[[[ Data: ${now()} ]]]'` edukira gehitu
- ExtractText atributua 'datuak' izenarekin (ez 'edukia')
- LogAttribute irteera nifi-app.log-en egiaztatu
- AttributesToJSON + PutMongo MongoDB-an gorde
- Fluxuaren definizio-fitxategia deskargatu

4. kasua osatu + fecha atributua (aukerazkoa)

EGOERA

4. kasua osorik inplementatu (HTTP→MongoDB), 'fecha' atributu berria gehitu UpdateAttribute bidez $\${now()}$ balioarekin, eta MongoDB-n gordetzen den JSON-ean fecha eremua barne. Helburua: kasu osoenaren hedapena. (Aukerazkoa)

EGINKIZUNAK

- 4. kasua osorik inplementatu (ListenHTTP→PutMongo)
- UpdateAttribute-en propietate berria: 'fecha' = $\${now()}$
- AttributesToJSON-en Attribute List-ean fecha gehitu
- curl-ekin probatu eta MongoDB-an fecha eremua egiaztatu
- Fluxuaren definizio-fitxategia deskargatu

Gogoan hartu beharrekoak

-
- i* **NiFi = dataflow programazioa** — arrastatu-askatu GUI, kode-lerrorik gabe, 300+ konektore.

 - ii* **FlowFile** — datu-unitate iraunkorra: edukia + atributuak (gako-balio metadaturak).

 - iii* **Prozesadoreak + Ilarak** — irteera-harremanak (success/failure...) konektatu edo auto-terminate.

 - iv* **Data Provenance** — FF bakoitzaren bidaia osoa ikuskatu (auditoria, debugging, compliance).

 - v* **Patroia** — Iturri → eraldaketa → batu/bideratu → JSON → helmuga (Kafka, HDFS, MongoDB).

Galderak, zalantzak, iruzkinak.

APACHE NIFI DOKUMENTAZIOA	nifi.apache.org/docs.html
PROZESADORE ZERRENDA OSOA	nifi.rocks/apache-nifi-processors
EXPRESSION LANGUAGE GIDA	nifi.apache.org/docs/nifi-docs/ html/expression-language-guide.html
JATORRIZKO MATERIALA	Aitor Medrano · CC BY-NC-SA