


Apache NiFi

Aurreratua

Prozesu-taldeak, funnelak, erregistro-bihurketa, datu-base integrazioa eta AEMET datu-lakua (Bronze/Silver/Gold).

Zikloa Adimen Artifiziala eta Big Data

Modulua Big Data Aplikatua



01 DATAFLOW. Apache NiFi aurreratua

01 Prozesu-taldeak — fluxuak modularizatu eta berrerabili

02 Funnelak — fluxu paraleloak bateratu

03 5. kasua — CSV JSON bihurtu (ConvertRecord)

04 6. kasua — MariaDB → MongoDB pipeline-a

05 7. kasua — AEMET datu-lakua (Bronze/Silver/Gold)

06 NiFi REST APIa — fluxuak programatikoki kontrolatu

07 Hiru ariketa praktiko — DF2.1, DF2.2, DF2.3

01 Prozesu- taldeak

Prozesu-taldea (Process Group)

Process Group

Fluxu logikoak KAPSULATZEKO eta ANTOLATZEKO mekanismoa. Sarrera-atakak (Input Port) eta irteera-atakak (Output Port) erabiltzen ditu datuak transferitzeko, irakurgarritasuna hobetuz eta fluxuak BERRERABILTZEA ahalbidetuz.


MODULARIZAZIOA

Programazioko 'funtzio' baten parekoa: inplementazio-xehetasunak ezkutatu, INPUT eta OUTPUT garbiak agerian utzi, eta sub-grafo bera lekuetan berrerabili.

— 1.1 TALDEA SORTU


Process Group ikonoa arrastatu

- Lan-eremuko TRESNA-BARRATIK **Process Group** ikonoa arrastatu
- **Talde berriari IZEN BAT esleitu (deskribatzailea** — adib. '5kasua_csv_json')
- Talde barrura BIKOITZ KLIK egin sartzeko
- BARRUAN ohiko prozesadoreez gain Input Port eta Output Port gehitu daitezke




Talde baten oinarrizko egitura

- **INPUT PORT** — kanpoko FF-ak taldera sartzeko ataria
- **Barneko PROZESADOREEN KATEA** — logika nagusia (adib. GetFile → SplitText → LogAttribute)
- **OUTPUT PORT** — taldetik kanpora ateratzeko ataria
- **Atakek IZENA dute** (adib. 'sarrera', 'irteera') — kanpotik konexioa errazteko



— ATAKAK KONEKTATU

Sarrera eta irteera atakak barruan konektatu




- Talde barruan **SARRERA-ATAKA** gehitu — izena: 'sarrera'
- Lehen prozesadoreari (adib. SplitText) konektatu (success harremana)
- Azken prozesadoretik **IRTEERA-ATAKARA** konektatu — izena: 'irteera'
- Atakak INVALID (gorri) agertuko dira kanpoan konektatu arte (normala)

— 1.2 FLUXUAK INPORTATU

JSON definizio-fitxategia esportatu eta inportatu

- Lan-eremuan ESKUINEKO BOTOIA → 'Download flow definition' → JSON formatuan deskargatu
- Beste lan-eremu batean talde berria arrastatu → BERRERABILTZeko IKONOA (jasotako fitxategiarena)
- TALDE OSOA inportatu daiteke: prozesadoreak, konexioak, kontroladore-zerbitzuak BARNE
- **NIFI 2.0-tik PLANTILLAK desagertu dira** — hau da BERRERABILTZeko mekanismo bakarra orain



Add Process Group

Process Group Name


Enter a name or select a file to upload

Browse

CANCEL ADD

— LAN-EREMUA

Prozesu-taldeak dituen fluxuaren ikuspegia




- MAILA NAGUSIAN talde anitz agertzen dira KUTXATXO izendunak gisa
- Talde bakoitzaren **BARRUKO ESTATISTIKAK** kutxatxo-azalean ageri — In/Out/Read/Write/Queued
- TALDEEN ARTEKO KONEXIOAK kanpoko atakak elkarren artean lotzen ditu
- Hierarkia: talde batek **BESTE TALDEAK** izan ditzake (nested) — konplexutasuna geruzaka ezkutatuz

— KONEXIOAK

Taldeen arteko fluxu-loturak

- Talde batetik bestera konektatzeko: lehen taldearen OUTPUT PORT-etik bigarrenaren INPUT PORT-era
- Konexioak ETIKETATU daitezke ataka-izenarekin
- Atakek BIK BIRA harreman behar dute (barruan + kanpoan) RUNNING egoteko
- DEBUGGING: ilara baten gainean eskuineko botoia → 'List queue' → FF-en edukia ikuskatu



02 Funnelak


Funnel

Funnel

Fluxu PARALELO ANITZ BAKARRERA biltzen dituen osagaia. Konexioak ZENTRALIZATZEN ditu eta lehentasunak modu BATERATUAN definitzeko aukera ematen du. Helmuga-prozesadorea aldatzen bada, soilik funnel-eko konexioa behar da aldatu.

BATERAGAILUA

$N \rightarrow 1$ konektore — N iturri, irteera bakar. Helmuga aldatzeko: 1 konexio bakarrik berridatzi, ez N .



— FUNNEL


Funnel — fluxu paraleloak bateratu

- Toolbar-eko FUNNEL IKONOA arrastatu lan-eremura
- **Konfigurazio gabe** — IZENIK GABEA, propietaterik gabea, hutsa
- N iturri-prozesadore funnel-aren SARRERAN konektatu
- Funnel-aren IRTEERA helmuga-prozesadore BAKARRARI konektatu

— ADIBIDEA

GenerateFlowFile prozesadoreak funnel-era konektatu


- **Hiru GenerateFlowFile prozesadore** — bakoitza konfigurazio desberdinekin
- **Hirurak FUNNEL BERARI** konektatuak — success harremana
- **Funnel-etik LogAttribute bakarrera** — guztien loga zentro bakar batean
- Probatutako patroia: N IZTURRI → FUNNEL → 1 HELMUGA



— FUNNEL PATROI OSOA

N iturri → funnel → helmuga bakar

- TOPOLOGIA OSOA: hainbat iturriak → funnel → helmuga zentralizatua
- KONFIGURAZIO ZENTRO BAKARRA: **back-pressure**, **lehentasuna**, **file age** — guztiak funnel-aren irteera-konexioan
- HELMUGA-ALDAKETA: konexio bakarra berridatzi (N iturri-konexio EZ)
- GARBITASUN BISUALA: diagrama irakurtarriagoa, mantentze-erraza



NiFi 2.0 — plantillak desagertu dira

- **NIFI 1.X** — TEMPLATES zeuden (XML-formatuan esportatuak)
- NIFI 2.0-tik plantillak DESAGERTU dira erabat
- BERRERABILTZEKO BIDE BAKARRA: prozesu-taldeak JSON formatuan esportatu
- JSON-ak GIT-EAN bertsionatu daitezke edo NIFI REGISTRY-AN gorde (NiFi-aren bertsio-kontroleko tresna ofiziala)
- **NIFI REGISTRY** — instantzia-ARTEKO deploy + ROLLBACK automatizatu

03

5. Kasua — CSV JSON bihurtu

5. kasuaren helburua eta fluxua

- **HELBURUA:** CSV fitxategiak JSON-era bihurtu ConvertRecord prozesadorearekin
- **FLUXUA:** GetFile → ConvertRecord → UpdateAttribute → PutFile
- **BIHURKETA:** CSVReader (sarrera) → JsonRecordSetWriter (irteera) — Controller Service-ak
- **FITXATEGI-IZENA** aldatu: .csv extensioa .json-ekin ordezkatu (UpdateAttribute)
- **GUZTIA PROZESU-TALDE BATEAN** — sarrera eta irteera-atakekin (DF2.1 ariketako eskakizuna)

— CONVERTRECORD

ConvertRecord — CSV reader + JSON writer

- **RECORD READER: CSVReader (Controller Service)** — Balio-bereizlea ';', Lehen lerroa goiburu: TRUE
- **RECORD WRITER: JsonRecordSetWriter (Controller Service)** — konfigurazio GEHIGARRIRIK GABE
- **AUTO-TERMINATE FAILURE** — ahaztuko ditugu errore-kasuak (didaktiko)
- Eraitza: CSV osoa JSON array bihurtuta FF-aren edukian

Configure Processor | ConvertRecord 1.15.0

Stopped

SETTINGS | SCHEDULING | PROPERTIES | COMMENTS

Required field

Property	Value
Record Reader	CSVReader
Record Writer	JsonRecordSetWriter
Include Zero Record FlowFiles	true

— UPDATEATTRIBUTE

UpdateAttribute — filename .csv → .json

- PROPIETATEA: filename
- BALIOA: \${filename:substringBefore('.csv')}.json
- **Expression Language** — substringBefore('.csv') funtzioa erabili extension-aurreko zatia hartzeko
- Emaidza: 'datuak.csv' → 'datuak.json' (PutFile-k izen berriarekin idatziko du)

Configure Processor | UpdateAttribute 1.15.0

Stopped


SETTINGS SCHEDULING PROPERTIES COMMENTS

Required field

Property	Value
Delete Attributes Expression	No value set
Store State	Do not store state
Stateful Variables Initial Value	No value set
Cache Value Lookup Cache Size	100
filename	\${filename:substringBefore('.csv')}.json

— 5. KASUAREN FLUXUA

GetFile → ConvertRecord →
UpdateAttribute → PutFile



- **GETFILE** — sarrera-karpetatik CSV fitxategiak hartu
- **CONVERTRECORD** — CSV → JSON bihurtzea
- **UPDATEATTRIBUTE** — filename atributua .csv → .json
- **PUTFILE** — irteera-karpetan JSON fitxategia idatzi
- **Guztia PROZESU-TALDE BATEAN** — Input/Output Port atakekin (ariketako eskakizuna)


04

6. Kasua — MariaDB → MongoDB

— ARKITEKTURA

MariaDB → NiFi → MongoDB

- **MARIADB (iabd-mysql-nifi)** — retail_db datu-basea, customers/orders/order_items tauladuna
- **NIFI** — bitartekaria: SQL kontsulta, datu-eraldaketa, MongoDB-rako bidalketa
- **MONGODB (iabd-mongodb-nifi)** — iabd datu-basea, bilduma berriak sortzen dira
- **GUZTIA DOCKER COMPOSE-EN** — proba egiteko ingurune isolatu eta birsorgarriak




Docker compose — ingurune osoa abiarazi

- Docker compose erabiliko dugu ingurune osoa komando berean abiarazteko:

●	<u>iabd-nifi-mysql-mong</u>	-	-	-
●	iabd-mysql-nifi	d83f57d103f2	mysql:latest	3306:3306 ↗
●	iabd-mongodb-nifi	e962875e5877	mongo:latest	27017:27017 ↗
●	iabd-nifi	e67d9a967e39	apache/nifi:latest	8443:8443 ↗

Docker compose — ingurune osoa abiarazi

■ Karpeta prestatu:



— 4.1 INGURUNEA

Docker compose

— Docker-compose.yml

```
docker-compose.yml
C: > nifi > ariketak > 06-ariketa-mariadb-mongodb > docker-compose.yml
1  services:
2      nifi:
3          container_name: iabd-nifi
4          ports:
5              - "8443:8443"
6          volumes:
7              - ./mysql-connector-j-8.0.31.jar:/opt/mysql-connector-j-8.0.31.jar
8              - C:/nifi/ariketak:/opt/nifi/ariketak
9          image: apache/nifi:latest
10         environment:
11             SINGLE_USER_CREDENTIALS_USERNAME: nifi
12             SINGLE_USER_CREDENTIALS_PASSWORD: nifinifinifi
13             NIFI_JVM_HEAP_MAX: 2g
14         links:
15             - mongodb
16             - mysql
17         mysql:
18             image: mysql:latest
19             container_name: iabd-mysql-nifi
20             restart: always
21             ports:
22                 - "3306:3306"
23             environment:
24                 TZ: Europe/Madrid
25                 MYSQL_ROOT_PASSWORD: iabd
26                 MYSQL_DATABASE: retail_db
27                 MYSQL_USER: iabd
28                 MYSQL_PASSWORD: iabd
29         mongodb:
30             container_name: iabd-mongodb-nifi
31             ports:
32                 - "27017:27017"
33             image: mongo:latest
```

Docker compose — ingurune osoa abiarazi

- Ingurune osoa (NiFi + MariaDB + MongoDB) abiarazi:

```
docker compose -p iabd-nifi-mysql-mongodb up -d
```

- MariaDB-ra retail_db datu-basea inportatu:

Cmd

```
docker exec -i iabd-mysql-nifi mysql -uiabd -piabd retail_db <  
create_db.sql
```

Docker compose — ingurune osoa abiarazi

■ Egiaztapena (MariaDB-ko taulak):

```
docker exec -it iabd-mysql-nifi mysql -uiabd -piabd retail_db  
  
show tables;
```

■ Egiaztapena (MongoDB-ra konexioa — oraindik HUTSA):

```
docker exec -it iabd-mongodb-nifi mongosh  
  
use iabd  
show collections  
db.getCollection("6kasua").find().limit(5)  
db.getCollection("6kasua").countDocuments()
```

— 4.2 DBCPConnectionPool

DBCPConnectionPool — MariaDB Controller Service

- DATABASE CONNECTION URL: jdbc:mysql://iabd-mysql-nifi/retail_db
- DATABASE DRIVER CLASS NAME: com.mysql.cj.jdbc.Driver
- DATABASE DRIVER LOCATION: /opt/mysql-connector-j-8.0.31.jar
- USERNAME / PASSWORD: iabd / iabd
- **CONNECTION POOL** — konexio-poltsa ManTENTzen du (SQL bakoitzeko konexio berri bat irekitzea saihestuz)

Controller Service Details | DBCPConnectionPool 1.19.1

SETTINGS | PROPERTIES | COMMENTS

Required field

Property	Value	
Database Connection URL	? jdbc:mysql://localhost/retail_db	
Database Driver Class Name	? com.mysql.cj.jdbc.Driver	
Database Driver Location(s)	? /opt/mysql-connector-j-8.0.31.jar	
Kerberos User Service	? No value set	
Kerberos Credentials Service	? No value set	
Kerberos Principal	? No value set	
Kerberos Password	? No value set	
Database User	? iabd	
Password	? Sensitive value set	
Max Wait Time	? 500 millis	
Max Total Connections	? 8	
Validation query	? No value set	
Minimum Idle Connections	? 0	
Max Idle Connections	? 0	

OK

— 4.3 EXECUTESQLRECORD

ExecuteSQLRecord — SQL kontsulta exekutatu

- DATABASE CONNECTION POOLING SERVICE: aurreko DBCPConnectionPool
- SQL SELECT QUERY: SELECT * FROM customers
- RECORD WRITER: JsonRecordSetWriter (Output Grouping: 'One Line per Object')
- Emaiza: FF BATEAN customers tauladun OSOA, JSON lerro-bidez (ndjson)
- **SCHEDULING** — '0 sec' (eskuz exekutatu) edo cron-expression (programatua)

Configure Processor | ExecuteSQLRecord 1.19.1

Stopped

SETTINGS

SCHEDULING

PROPERTIES

RELATIONSHIPS

COMMENTS

Required field

Property	Value
Database Connection Pooling Service	DBCPConnectionPool
SQL Pre-Query	No value set
SQL select query	select * from customers;
SQL Post-Query	No value set
Max Wait Time	0 seconds
Record Writer	JsonRecordSetWriter
Normalize Table/Column Names	false
Use Avro Logical Types	false
Default Decimal Precision	10
Default Decimal Scale	0
Max Rows Per Flow File	0
Output Batch Size	0
Fetch Size	0

CANCEL

APPLY

4.4 SplitText — lerro bakoitza FF bihurtu

- **LINE SPLIT COUNT: 1** — lerro bakoitza FF independente
- **HEADER LINE COUNT: 0** — JSON-EN ez dago goibururik
- **PutMongo (klasikoa) erabili nahi denerako behar da** — dokumentu BAT PER FF eskatzen du
- **ALTERNATIBA MODERNOAGOA:** SplitText KENDU eta PutMongoRecord erabili (record-mailan banaketa egiten du barne)
- **OUTPUT** — FF-multzo bat 'splits' harremanean, bakoitza dokumentu JSON bakar bat

— 4.5 MONGODB

MongoDBControllerService — MongoDB konexioa

- MONGODB URI: mongodb://iabd-mongodb-nifi
- AUTHENTICATION: NONE (demo-rako; produkzioan USERNAME/PASSWORD)
- **CONNECTION POOL** — MongoDB-rako kudeaketa automatikoa
- Beste prozesadoreek (PutMongo, PutMongoRecord) Controller Service hau erreferentziatzen dute
- **ENABLE** — Controller Service-a aktibatu sortzearen ondoren (botoia)

Controller Service Details | MongoDBControllerService 1.19.1

SETTINGS

PROPERTIES

COMMENTS

Required field

Property		Value	
Mongo URI	?	mongodb://localhost	
Database User	?	No value set	
Password	?	No value set	
SSL Context Service	?	No value set	
Client Auth	?	NONE	

— 4.6 PUTMONGO

PutMongo — FF zuzenean dokumentu

Configure Processor | PutMongo 119.1

Stopped

SETTINGS SCHEDULING PROPERTIES RELATIONSHIPS COMMENTS

Required field

Property	Value
Client Service	MongoDBControllerService
Mongo URI	No value set
Mongo Database Name	iabd
Mongo Collection Name	caso6
SSL Context Service	No value set
Client Auth	NONE
Mode	insert
Upsert	false
Update Query Key	No value set
Update Query	No value set
Update Mode	With whole document
Write Concern	ACKNOWLEDGED

CANCEL APPLY

- CLIENT SERVICE: aurreko MongoDBControllerService
- MONGO DATABASE NAME: iabd
- MONGO COLLECTION NAME: 6kasua
- MODE: insert (alternative: update, upsert)
- **FF-aren EDUKIA = JSON dokumentu OSOA** — beraz SplitText behar da aurretik (lerro bat per FF)

2. ALDAERA:

PutMongoRecord — record-formatuan gorde

- CLIENT SERVICE: MongoDBControllerService
- MONGO DATABASE NAME: iabd
- MONGO COLLECTION NAME: 6kasua-record
- RECORD READER: JsonTreeReader (Controller Service)
- **ABANTAILA: SplitText KENDU** — FF batean dokumentu anitz, BATCH INSERT bakar batean MongoDB-ra (askoz azkarragoa)

Configure Processor | PutMongoRecord 1.19.1

Stopped

SETTINGS SCHEDULING PROPERTIES RELATIONSHIPS COMMENTS


Required field

Property	Value
Client Service	MongoDBControllerService
Mongo URI	No value set
Mongo Database Name	iabd
Mongo Collection Name	caso6b
SSL Context Service	No value set
Client Auth	NONE
Write Concern	ACKNOWLEDGED
Record Reader	JsonTreeReader
Batch Size	100
Ordered	False
Bypass Validation	True
Update Key Fields	No value set

CANCEL APPLY

— FLUXU ALTERNATIBOA

ExecuteSQLRecord → PutMongoRecord (zuzenean)



- EXECUTESQLRECORD-EK NDJSON sortzen du (dokumentu anitz FF batean)
- PUTMONGORECORD-EK NDJSON irakurtzen du JsonTreeReader-rekin
- **SplitText DESAGERTZEN da** — bi prozesadorez osatutako pipeline garbiagoa
- Errendimendu HOBEA: batch bidezko txertaketa, memoria txikiagoa, FF gutxiago
- Produkzio-praktika gomendagarria datu-base integrazioan

05

7. Kasua — AEMET Datu-lakua


Medallion architecture — Bronze / Silver / Gold



- **BRONZE:** datu **GORDINAK**, iturriaren jatorrizko formatuan
HARTU → GORDE (EZ ERALDATU)
- **SILVER:** datu **GARBITUAK** eta **NORMALIZATUAK**
Eskema bateratua + kalitate-egiaztapenak
- **GOLD:** datu **AGREGATUAK** eta **OPTIMIZATUAK**
Analitikarako prest (*Parquet*, zutabeka antolatutako formatua)

- **DUAL-STORAGE:**
 - **File:** data-lake historikoa + batch analitika
 - **MongoDB:** kontsulta operatibo azkarrak
- **Abantaila: REPROCESSING-A**
Silver eta Gold geruzak **Bronze-tik berreraiki** daitezke

5.1 Bronze geruza — REST → File



- **InvokeHTTP**: AEMET API-ari **GET** eskaria egin (60 segundoro)
 - **URL**: AEMET API-aren **endpoint-a** (*datu meteorologikoak*)
- **UpdateAttribute**: metadatuak gehitu: fecha + filename
 - **FILENAME**: timestamp bidezko izen bakarra: adibidez, *2026-05-18_08-23-15.json*
- **PutFile**: JSON gordina Windows-eko 'bronze' karpetan gorde

NiFi Docker instalazioari bi NAT gehitu


- NiFi kontenedorea **geratu**:
docker stop iabd-nifi
- Deskargatu 2.11 bertsio zehatzak eta **C:\nifi\nars** karpetan kopiatu:
[nifi-parquet-nar-2.11.0.nar](#)
[nifi-hadoop-libraries-nar](#)
- NAR-ak NiFi kontenedorean kopiatu:
docker cp "C:\nifi\nars\nifi-hadoop-libraries-nar-2.11.0.nar" iabd-nifi:/opt/nifi/nifi-current/lib/
docker cp "C:\nifi\nars\nifi-parquet-nar-2.11.0.nar" iabd-nifi:/opt/nifi/nifi-current/lib/
- NiFi kontenedorea **abiarazi**:
docker start iabd-nifi
- Egiaztatu barruan daudela:
docker exec iabd-nifi sh -c "ls -lh /opt/nifi/nifi-current/lib/*parquet* /opt/nifi/nifi-current/lib/*hadoop-libraries*"

AEMET REST API

```
1 {
2   "origin": {
3     "productor": "Agencia Estatal de Meteorología - AEMET. Gobierno de España",
4     "web": "https://www.aemet.es",
5     ...
6   },
7   "title": "elTiempo.net | El tiempo en Elche/Elx (Alacant/Alicante)",
8   ...
9   "municipio": {
10     "CODIGOINE": "0306500000",
11     "ID_REL": "1030651",
12     "COD_GEO": "03320",
13     "CODPROV": "03",
14     "NOMBRE_PROVINCIA": "Alacant/Alicante",
15     "NOMBRE": "Elche/Elx",
16     "POBLACION_MUNI": 228647,
17     "SUPERFICIE": 32606.7487,
18     "PERIMETRO": 91751,
19     ...
20   },
21   "fecha": "2023-03-10",
22   "stateSky": {
23     "description": "Nubes altas",
24     "id": "17"
25   },
26   "temperatura_actual": "24",
27   "temperaturas": {
28     "max": "27",
29     "min": "15"
30   },
31   "humedad": "24",
32   "viento": "18",
33   "precipitacion": "0",
34   "lluvia": "",
35   ...
36 }
```


— BRONZE PIPELINE

InvokeHTTP → UpdateAttribute → PutFile



- **InvokeHTTP**: AEMET REST API-ari GET eskaria (60 segundoro)
 - URL: <https://api.el-tiempo.net/json/v3/provincias/03/municipios/03065>
- **UpdateAttribute**: metadatuak gehitu: **fecha** + **filename** (*timestamp*)
 - fecha: `${now():format('yyyy-MM-dd_HH-mm-ss')}`
 - filename: `${now():format('yyyy-MM-dd_HH-mm-ss')}.json`
- **PutFile** — JSONa Windows-eko **bronze/** karpetan gorde.
 - `/opt/nifi/ariketak/07-ariketa/bronze`
- **Datu-formatua**: JSON gordina, AEMETen jatorrizko egiturean (*eraldatu gabe*)
- **Append-only**: timestamp bakoitzeko objektu berria → **historikoa mantendu**

5.2 Silver geruza

EvaluateJSONPath — JSON eremuak atributura erauzi

Edit Processor | EvaluateJsonPath 2.11.0

SettingsSchedulingProperties

Required field +

Property	Value
Destination	<i>i</i> flowfile-attribute
Return Type	<i>i</i> auto-detect
Path Not Found Behavior	<i>i</i> ignore
Null Value Representation	<i>i</i> empty string
Max String Length	<i>i</i> 20 MB
hezetasuna	<i>i</i> \$.humedad
hiria	<i>i</i> \$.municipio.NOMBRE
temperatura	<i>i</i> \$.temperatura_actual

- Helburua: Bronze JSONetik eremu interesgarriak erauzi
- Destination: flowfile-attribute
Balioak FF-aren atributuetara esleitu). Atributuak sortu, JSON edukia aldatu gabe.
- Propietate dinamikoak:
 - hiria = \$.municipio.NOMBRE
 - tenperatura = \$.temperatura_actual
 - hezetasuna = \$.humedad
- JSON PATH: JSONaren barruko datuak hautatzeko sintaxia:
 - \$.eremua
 - \$.array[0]
 - \$.array[*].eremua

— SILVER PIPELINE


AttributesToJSON — atributuetatik Silver JSONa sortu

- **Attributes List:** **fecha,hiria,temperatura,hezetasuna**
- **Destination:** **flowfile-content** (FF-aren edukia ordeztu)
- **Include Core Attributes:** **false** (NiFi-ren atributu automatikoak ez sartu (*uuid, filename...*))
- **Eraitza:** aukeratutako atributuekin **JSON berria:** {"hiria": "...", "temperatura": ..., "hezetasuna": ...}
- **SILVER:** beharrezko eremuak bakarrik → **datu trinkoagoak eta erabilgarriagoak**

Edit Processor AttributesToJSON 2.11.0	
Settings	Scheduling
Properties	
Required field +	
Property	Value
Attributes List	<i>i</i> fecha,hiria,temperatura,hezetasuna
Attributes Regular Expression	<i>i</i> No value set
Destination	<i>i</i> flowfile-content
Include Core Attributes	<i>i</i> false
Null Value	<i>i</i> false
JSON Handling Strategy	<i>i</i> Escaped
Pretty Print	<i>i</i> false

SILVER PIPELINE

Silver fluxu osoa — Fitxategi sistema + MongoDB paraleloan



- **Silver bihurketa:** **EvaluateJSONPath** → **AttributesToJSON**
Bronze JSONetik → intereseke eremuak dituen **Silver JSONera**
- **Bi adar paralelo:** Silver JSON bera **PutFile** eta **PutMongo** prozesadoreetara bidali
- **PutFile** — JSONa Windows-eko **silver/** karpetan gorde.
 - /opt/nifi/ariketak/07-ariketa/silver
- **PutMongo:** **iabd** datu-baseko **7kasua-silver** bilduman gorde
- **Idazketa independenteak:** helmuga batek huts egin dezake besteak arrakasta izan arren (failure batek ez du bestea blokeatzen)

5.3 Gold geruza. MergeContent: Silver mezuak bateratu

Processor Details | MergeContent 2.11.0

SettingsSchedulingPropertiesRe

Required field

Property	Value
Merge Strategy	Bin-Packing Algorithm
Merge Format	Binary Concatenation
Attribute Strategy	Keep Only Common Attributes
Correlation Attribute Name	No value set
Minimum Number of Entries	10
Maximum Number of Entries	10
Minimum Group Size	0 B
Maximum Group Size	No value set
Bin Termination Check	No value set
Max Bin Age	No value set
Maximum Number of Bins	5
Delimiter Strategy	Text
Header	[
Footer	]
Demarcator	,

- Merge Strategy: **Bin-Packing Algorithm**
- Merge Format: **Binary Concatenation**
- Minimum / Maximum Entries: **10** — gutxienez/gehienez 10 FlowFile bateratu FlowFile bakarrean
- Delimiter Strategy: **Text** — FlowFile-en artean [,] gehitu
- Helburua: Silver-eko mezu txikiak **multzokatu**, ondorengo agregazioa eta **Parquet bihurketa** eraginkorragoak izan daitezzen

UpdateAttribute: Parquet fitxategi-izena esleitu

Edit Processor | UpdateAttribute 2.11.0

Settings Scheduling **Properties**

Required field +

Property	Value
Delete Attributes Expression	<i>No value set</i>
Store State	Do not store state
Stateful Variables Initial Value	<i>No value set</i>
Cache Value Lookup Cache Size	100
filename	<code>\${now():format('yyyy-MM-dd_HH-mm-ss')}</code>

- **Helburua:** PutFile-ek **filename** atributua fitxategiaren izen gisa erabiltzea
- **Propietatea:** **filename**
- **Balioa:** `${now():format('yyyy-MM-dd_HH-mm-ss')}`.parquet
- **Timestamp:** fitxategi bakoitzari **denbora-identifikatzailea** esleitu eta gainidazketak saihestu
- **Produkzioan:** dataren araberako **partizio-egitura** erabil daiteke: `year=2026/month=05/day=18/...`

QueryRecord — Gold-eko SQL agregazioa

... queryrecord-gold.sql

sql

```
1  -- Gold-eko agregazio nagusia
2  -- 10 Silver mezutatik hiri bakoitzeko batez bestekoak
3
4  select hiri,
5         max(fecha)      as fecha,
6         avg(temperatura) as temperatura,
7         avg(hezetasuna) as hezetasuna
8  from FLOWFILE
9  group by hiri;
10
11 -- 'FLOWFILE' = uneko FF-aren edukia
12 --
13 -- Record Reader: JsonTreeReader (NDJSON sarrera)
14 -- Record Writer: ParquetRecordSetWriter (Parquet irteera)
15 --
16 -- Emaita: hiri bakoitzeko batez bestekoak dituen
17 -- Gold datu agregatua, Parquet formatuan
```

— GOLD PIPELINE

QueryRecord: Gold agregazioaren konfigurazioa

■ **Record Reader:** **JsonTreeReader** (NDJSON sarrera irakurri → Silver-etik datorrena)

■ **Record Writer:** **ParquetRecordSetWriter** (Parquet irteera → **zutabe-formatuan**)

■ **Propietate dinamikoa:** SQL kontsulta

Propietatearen izenak **irteera-harreman berria** sortzen du

■ **Adibidea:** **tempMedia** propietatea

tempMedia harremana → **PutFile**-era konektatu

■ **Auto-terminate:** **original** eta **failure**

(ariketa honetan, fluxua sinplifikatzeko)

Edit Processor QueryRecord 2.11.0		
Settings	Scheduling	Properties
Required field +		
Property	Value	
Record Reader	 JsonTreeReader	
Record Writer	 ParquetRecordSetWriter	
Include Zero Record FlowFiles	 false	
Default Decimal Precision	 10	
Default Decimal Scale	 0	
tempMedia	 SELECT hiria, MAX(fecha) as fecha, A...	

— GOLD PIPELINE

JsonTreeReader: timestamp formatua

Controller Service Details	
Settings	Properties
Required field	
Property	Value
Schema Access Strategy	 Infer Schema
Schema Inference Cache	 No value set
Starting Field Strategy	 Root Node
Max String Length	 20 MB
Parsing Strategy	 Standard
Date Format	 No value set
Time Format	 No value set
Timestamp Format	 yyyy-MM-dd HH:mm:ss

- **Timestamp Format:** yyyy-MM-dd HH:mm:ss
- **fecha** eremua: Silver-eko data testua (string) → SQL timestamp bihurtu
- **Helburua:** **MAX(fecha)** agregazioan datak kronologikoki konparatu
- **Formatua:** NiFi-k definitutako data/ordu formatu-patroia
- **Beste aukerak:** **Date Format** eta **Time Format** ere konfiguragarriak

PutFile: Gold geruza fitxategian gorde

- **Directory:** `/opt/nifi/ariketak/07-ariketa/gold`
- **Conflict Resolution Strategy:** `replace`
Izen bereko fitxategia existitzen bada, gainidatzi
- **Create Missing Directories:** `true`
Direktorioa existitzen ez bada, automatikoki sortu
- **Fitxategi-izena:** FlowFile-aren **filename** atribututik automatikoki hartzen du (aurreko *UpdateAttribute-k* sortua)
- **Edukia:** **Parquet** (*QueryRecord*-eko *ParquetRecordSetWriter*-ek sortutako eduki binarioa zuzenean fitxategian gordetzen da.

Edit Processor | PutFile 2.11.0

Settings Scheduling **Properties**

Required field +

Property	Value
Directory	<i>i</i> /opt/nifi/ariketak/07-ariketa-aemet-da...
Conflict Resolution Strategy	<i>i</i> replace
Create Missing Directories	<i>i</i> true
Maximum File Count	<i>i</i> No value set
Last Modified Time	<i>i</i> No value set
Permissions	<i>i</i> No value set
Owner	<i>i</i> No value set
Group	<i>i</i> No value set

Gold MongoDB-ra: ParquetReader

- Client Service: **MongoDBControllerService**
- Mongo Database: **iabd**
- Mongo Collection: **7kasua-gold**
- Record Reader: **ParquetReader** (Gold-eko Parquet edukia irakurri eta erregistro bihurtu)
- Helburua: erregistro bakoitza **MongoDB dokumentu gisa** gorde
- Bihurketa: **Parquet** → **Records** → **MongoDB dokumentuak**, NiFi-ren **Record API** bidez

Edit Processor | PutMongoRecord 2.11.0

SettingsSchedulingPropertiesR

Required field +

Property	Value
Client Service	<i>i</i> MongoDBControllerService <i>⋮</i>
Mongo Database Name	<i>i</i> iabd
Mongo Collection Name	<i>i</i> 7kasua-gold
Record Reader	<i>i</i> ParquetReader <i>⋮</i>
Batch Size	<i>i</i> 100
Ordered	<i>i</i> False
Bypass Validation	<i>i</i> False
Update Key Fields	<i>i</i> No value set

Bronze → Silver → Gold (fluxu osoa)

■ BRONZE: **InvokeHTTP** → **UpdateAttribute** → **PutFile**

JSON gordina fitxategi-sisteman gorde: **/opt/nifi/ariketak/07-ariketa/bronze/**

■ SILVER: **EvaluateJSONPath** → **AttributesToJSON**

→ Silver JSONa bi helmugatan gorde, **bi adar paralelotan**:

- **PutFile**: **/opt/nifi/ariketak/07-ariketa/bronze/**
- **PutMongo**: **MongoDB**

■ GOLD: **MergeContent** → **UpdateAttribute** → **QueryRecord**

→ Datuak agregatu eta Parquet formatuan sortu, bi helmugatan gorde, bi adar paralelotan:


- **PutFile**: **/opt/nifi/ariketak/07-ariketa/gold/**
- **PutMongoRecord + ParquetReader**: **MongoDB**

■ Geruzen artean: fluxu jarraitua (*Bronze* → *Silver* → *Gold*)

■ **Prozesu-talde bakarra**: fluxu osoa Process Group batean antolatuta → **JSON definizio gisa esportagarria**

— 7. KASUA OSOA

Bronze → Silver → Gold (fluxu osoa)



06

NiFi REST APIa

— DEFINIZIOA

NiFi REST API

NiFi REST API

NiFi-k REST zerbitzuak eskaintzen ditu '/nifi-api/<zerbitzua>' ereduaren arabera, fluxuak PROGRAMATIKOKI kontrolatzeko: prozesadoreak sortu, konexioak ezarri, ilarak monitorizatu eta taldeen egoera aldatu.

AUTOMATIZAZIOA

GUI-tik eskuz egiten den GUZTIA API-bidez egin daiteke — CI/CD-INTEGRAZIOA, custom dashboards, eta cross-instance sync ahalbidetuz.


Endpoint nagusiak — /nifi-api/...

- **/access/token (POST)** — autentifikazio-tokena eskuratu (lehenengo deia)
- **/flow/process-groups/{id} (PUT)** — talde-egoera aldatu (RUNNING / STOPPED)
- **/processors (GET/POST)** — prozesadoreak sortu eta konfiguratu
- **/connections (GET/POST)** — konexioak ezarri prozesadoreen artean
- **/controller-services (GET/POST)** — Controller Service-ak kudeatu (DBCP, MongoDB, etab.)
- **/flowfile-queues/{id} (GET)** — ilarako edukia monitorizatu (queue depth, byte-count)

— UUID IDENTIFIKATZAILE

Prozesu-taldearen UUID NiFi GUI-an aurkitu

- **Prozesu-taldea hautatu (klik bakar)** — eskuinaldeko panela agertzen da
- **OPERATE PALETA** panelean UUID-a agertzen da
- Edo: URL-an dator parametroan (browser address-bar-ean ikus)
- **REST API-rako derrigorrezkoa** — izenez ez, UUID-z identifikatzen dira baliabideak
- **ALTERNATIBA: /flow/process-groups/root GET** — ID hierarkia osoa lortzen du



Talde-egoera aldatu — token + PUT

```
●●● start-process-group.sh bash

1 #!/bin/bash
2 # Apache NiFi REST API — prozesu-talde bat abiatu
3 # Ingurune-aldagaiak edo bertan zehaztu
4 NIFI_URL="https://localhost:8443"
5 USER="nifi"
6 PASS="nifinifinifi"
7 PG_UUID="abc12345-67ef-..."
8
9 # 1) Autentifikazio-tokena eskuratu
10 TOKEN=$(curl -sk -X POST "$NIFI_URL/nifi-api/access/token" \
11   -d "username=$USER&password=$PASS")
12
13 # 2) Taldea abiatu — RUNNING egoerara
14 curl --tlsv1.2 -sk \
15   -H "Authorization: Bearer $TOKEN" \
16   -H "Content-Type: application/json" \
17   -X PUT \
18   -d "{\"id\":\"$PG_UUID\",\"state\":\"RUNNING\"}" \
19   "$NIFI_URL/nifi-api/process-groups/$PG_UUID"
```

07

Jarduerak praktikoak

5. kasua — CSV JSON bihurtu prozesu-taldean

EGOERA

5. kasua (CSV → JSON ConvertRecord-ekin) PROZESU-TALDE batean enbalatu. Taldearen izena: '5kasua<zureizena>' (adib. '5kasua_irene'). Taldearen muga sarrera-ataka (Input Port, 'sarrera') eta irteera-ataka (Output Port, 'irteera') gehitu. Fluxua barruan: GetFile → ConvertRecord → UpdateAttribute → PutFile. Exekutatu, egiaztatu JSON irteera, eta fluxuaren JSON-definizioa deskargatu.

EGINKIZUNAK

- Prozesu-taldea izen egokiarekin ('5kasua<izena>')
- Input Port eta Output Port taldearen muga ('sarrera', 'irteera')
- Lau prozesadoreen kateak barruan (GetFile, ConvertRecord, UpdateAttribute, PutFile)
- CSVReader eta JsonRecordSetWriter Controller Service-ak konfiguratuak
- JSON irteera-fitxategi-zerrenda (egiaztatua)
- Fluxuaren JSON-definizio fitxategia (Download flow definition)

6. kasua — MariaDB → MongoDB bi bildumatan

EGOERA

6. kasua osatu — retail_db datu-baseko customers, orders eta order_items tauladunak MongoDB-an gorde BI ALDAERA EZBERDINETAN: 1. bilduma SplitText + PutMongo klasikoa erabiliz; 2. bilduma PutMongoRecord (record-API) zuzenean erabiliz. Bi aldaeren JSON-definizio fitxategiak entregatu, konparaketa-oharrarekin (errendimendua, diseinu-konplexutasuna).

EGINKIZUNAK

- DBCPConnectionPool Controller Service (MariaDB-rako)
- MongoDBControllerService aktibatuta
- **ExecuteSQLRecord prozesadorea** — 3 tauladunetarako (banaka edo SQL-anitzekin)
- 1. ALDAERA: SplitText (Line Split Count=1) + PutMongo → 6kasua-classic bildumara
- 2. ALDAERA: PutMongoRecord (JsonTreeReader-ekin) → 6kasua-record bildumara
- MongoDB-an find() egiaztapena bi bildumetan
- BI FLUXU-DEFINIZIO JSON-fitxategiak deskargatuta + BI ALDAERAREN KONPARAKETA-OHARRA (errendimendua)

7. kasua — AEMET Datu-lakua osoa (aukerazkoa)

EGOERA

AEMET datu-laku osoa inplementatu hiru geruzetan (Bronze/Silver/Gold). Bronze: 30 segundoro AEMET API-ari eskaria + S3-n gorde. Silver: JSON iragazketa + S3 + MongoDB-n paraleloan. Gold: 3 minuturo agregazioa (hiri bakoitzeko batez bestekoa) + Parquet S3-ra + MongoDB-ra. Fluxu osoa prozesu-talde batean enbalatu eta JSON-definizioa deskargatu.

EGINKIZUNAK

- Bronze: InvokeHTTP (30s) + UpdateAttribute (fecha, filename) + PutS3Object (iabd-nifi/bronze)
- Silver: EvaluateJSONPath + AttributesToJSON + PutS3Object (iabd-nifi/silver) + PutMongo (7kasua-silver) paraleloan
- Gold: MergeContent (10 mezu, 3 min) + UpdateAttribute (Parquet izena) + QueryRecord (SQL agregazioa) + PutS3Object (iabd-nifi/gold) + PutMongoRecord (7kasua-gold) paraleloan
- AWS-Credentials Provider Service + MongoDB Controller Service + ParquetReader/Writer-ak
- Pipeline OSOA prozesu-talde batean ('7kasua_aemet')
- JSON-definizio fitxategia deskargatuta
- Egiaztapenak: S3 bucket-ean iabd-nifi/{bronze,silver,gold}/* fitxategiak; MongoDB-an 7kasua-silver eta 7kasua-gold bildumak datuekin

Gogoan hartu beharrekoak

-
- i* **Prozesu-taldeak** — fluxu logikoak kapsulatu, Input/Output Port-ekin; NiFi 2.0-tik JSON-bidez birrerabilgarri.

 - ii* **Funnelak** — N iturri → 1 helmuga; konexioak zentralizatu, mantentze-erraza.

 - iii* **Record API** (ConvertRecord, ExecuteSQLRecord, QueryRecord, PutMongoRecord) — SPLIT-EZ patroia, batch-eraginkorra.

 - iv* **Medallion architecture** (Bronze/Silver/Gold) + DUAL-STORAGE (S3 + MongoDB) — produkzio-data-lakuaren estandarra.

 - v* **NiFi REST API** — automatizazio, CI/CD, monitorizazio external; UUID-bidez baliabide-identifikazio stable.
-

Galderak, zalantzak, iruzkinak.

APACHE NIFI REST API DOKUMENTAZIOA	nifi.apache.org/docs/nifi-docs/rest-api
PROCESS GROUP BEST PRACTICES	nifi.apache.org/docs.html
MEDALLION ARCHITECTURE (DATABRICKS)	databricks.com/glossary/medallion-architecture
JATORRIZKO MATERIALA	Aitor Medrano · CC BY-NC-SA